Ideia do projeto de Ciência de Dados

Preço do café × dólar × clima

Álvaro

23 de setembro de 2026

A ideia em uma frase

Coletar automaticamente o preço de *commodities* (focando no café), juntar com dados de dólar e de chuva/temperatura, e analisar como essas coisas se relacionam ao longo do tempo.

Por que isso é interessante?

- O café é negociado em dólar, então quando o dólar sobe, o preço em reais tende a subir também. Mas quanto? E na hora, ou dias depois?
- Café depende muito do clima. Seca ou geada nas regiões produtoras (tipo a geada de 2021 aqui em Minas) derrubam a safra e o preço dispara.
- Minas é o maior produtor de café do Brasil, então o tema tem tudo a ver com a gente.
- Os dados existem e são públicos, só que estão espalhados. Juntar tudo num lugar só já é metade do trabalho.

Como a gente faria

1. Pegar os dados

- **Crawler (robô que lê o site):** um script em Python que entra todo dia no `https://www.noticiasagricolas.com.br/cotacoes/` e salva as cotações. Dá pra deixar ele rodando sozinho pelo GitHub Actions.
- **Histórico:** o crawler só pega daqui pra frente, e até o fim do semestre seriam poucos meses. Então o histórico de preços a gente puxa do CEPEA, que tem anos de dados prontos. Para essa parte tbm pensei em pegar dados desde 2020 e cruzar os dados.
- **Dólar:** API do Banco Central, que é bem simples de usar.
- **Clima:** chuva e temperatura das regiões de café pela API da NASA POWER ou pelo INMET.

2. Arrumar os dados

Cada fonte vem num formato diferente, então precisa limpar e juntar tudo numa tabela só, organizada por data. Algumas coisas a resolver:

- Não tem cotação em fim de semana e feriado, mas tem chuva todo dia;
- Dados faltando e valores estranhos;
- Criar colunas novas úteis, tipo "chuva acumulada nos últimos 90 dias" ou "dólar de 5 dias atrás", porque o efeito geralmente não é imediato.

3. Analisar e fazer gráficos

Essa é a parte principal. A ideia é responder perguntas como:

- Como o preço do café evoluiu nos últimos anos?
- Existe época do ano em que ele sobe ou cai (safra e entressafra)?
- O preço acompanha o dólar? Com quanto tempo de atraso?
- Meses de pouca chuva são seguidos de alta no preço?
- O que aconteceu com o preço na geada de 2021?

Os gráficos seriam feitos com `matplotlib`, `seaborn` e `plotly`, e dá até pra montar um painelzinho no `Streamlit`.

4. Machine learning (parte pequena)

O PDF do professor pede ML, então a gente coloca algo simples no final: uma regressão linear e uma Random Forest pra ver quais fatores (dólar, chuva, temperatura) mais "explicam" o preço. Não é pra fazer um modelo que prevê o futuro com perfeição, é mais uma ferramenta de análise.

O que precisa ter no pré-projeto

O professor pede: introdução, descrição do problema, objetivos, metodologia (extração, tratamento, visualização e ML), repositório, conclusão, parte escrita e slides. A apresentação é de 10 a 15 minutos. Essa ideia cobre tudo isso tranquilo.

Divisão de tarefas (sugestão)

- **Pessoa 1:** crawler e coleta de dados (site, CEPEA, Banco Central, clima);
- **Pessoa 2:** tratamento e junção dos dados;
- **Juntos:** análise, gráficos, ML, texto e slides.

Tudo fica num repositório no GitHub, com o código, os dados e os notebooks.

Pontos pra gente decidir

- Focar só no café ou incluir outra *commodity* (soja, milho, boi)?
- Quais regiões usar pro clima (Sul de Minas, Cerrado Mineiro...)?
- Quantos anos de histórico analisar?