Ciência dos dados

Higor Alexandre Duarte Mascarenhas

Quem é o professor?

- Graduado em Engenharia da Computação (UEMG)
- Mestre em Modelagem Matemática Computacional (CEFET-MG)
- Doutorando em Modelagem Matemática Computacional (CEFET-MG)

- Área de atuação: análise de dados

- Email: higoralexandre@cefetmg.br

Ementa da disciplina

- Introdução a ciência dos dados;
- Natureza dos dados;
- Coleta, tratamento e visualização de dados;
- Ambientes e aplicações em ciência dos dados.

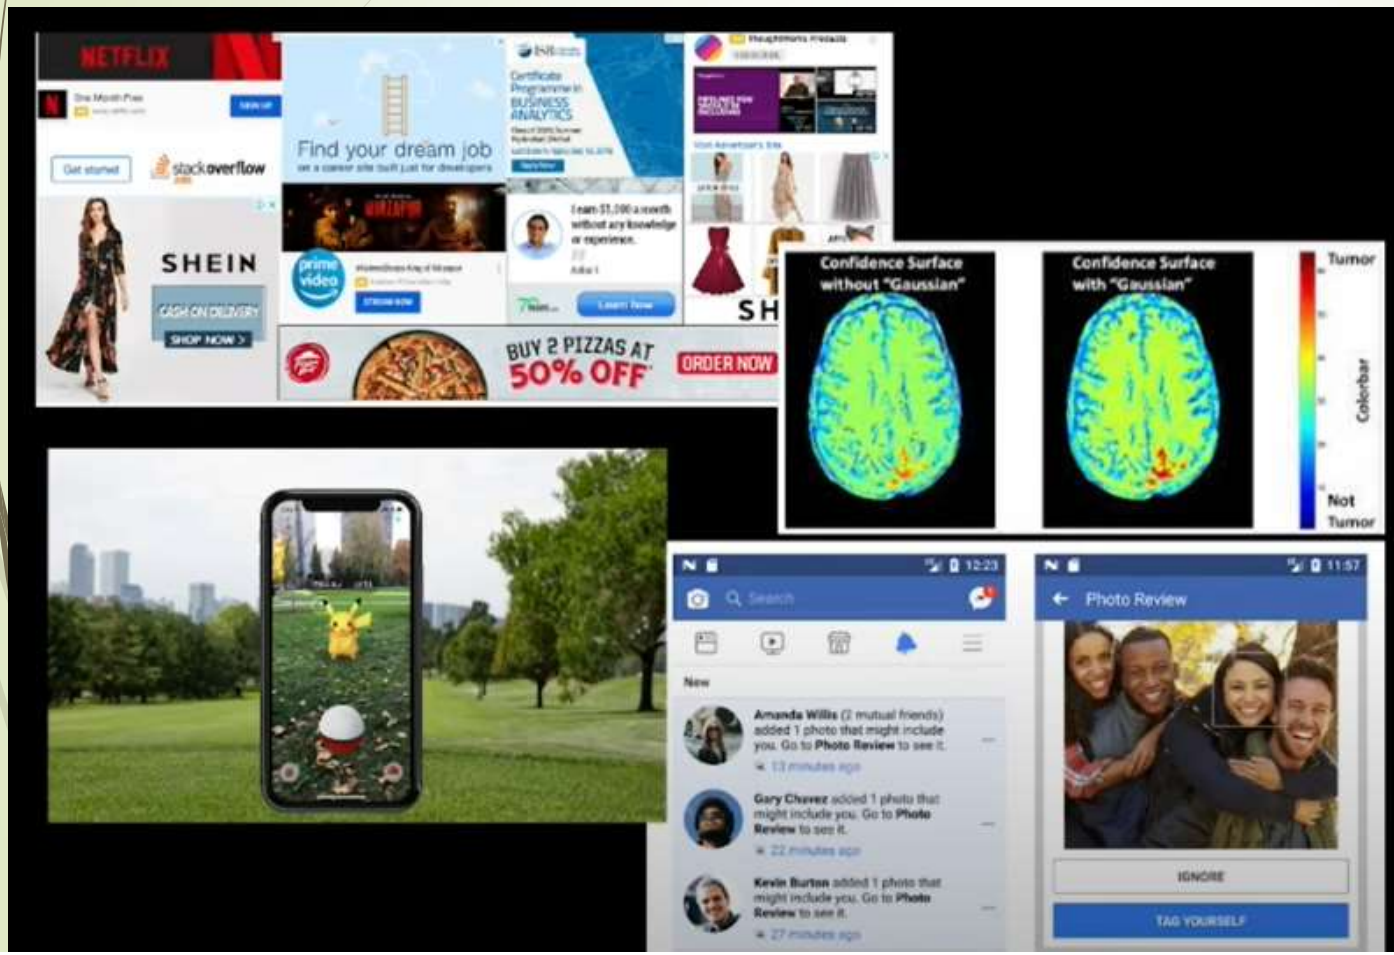
Divisão dos pontos

- 40 pontos em listas e trabalhos
- 20 pontos pré projeto
- 40 pontos projeto final



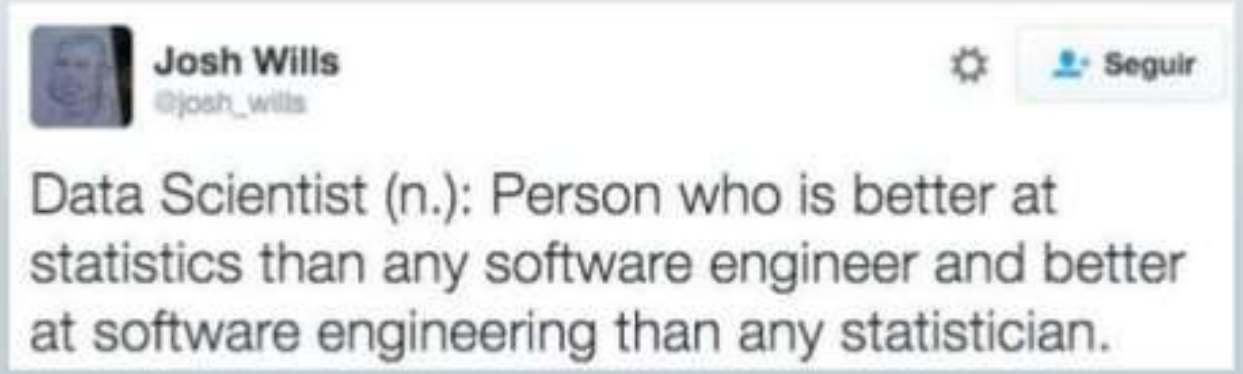
- 90% dos dados que há no mundo hoje foram criados apenas nos últimos dois anos (Fonte de 2021)

Principais aplicações da ciência de dados



- Detecção de fraude
- Recomendação de produtos
- Identificação de problemas de saúde
- Otimização de rotas
- Reconhecimento de fala
- Resposta a pesquisas de internet
- Comportamento de personagens em jogos
- Carros autônomos
- Precificação
- Previsão de demanda
- Segmentação de clientes
- +++

Cientista de Dados



Pessoa que é melhor em estatística que qualquer engenheiro de software e melhor em engenharia de software do que qualquer estatístico.

Funções típicas dos cientistas de dados

- Coletar grandes quantidades de dados não-estruturados e transformá-los em um formato mais utilizável;
- Resolver problemas de negócios usando técnicas orientadas por dados;
- Trabalhar com uma variedade de linguagens de programação, incluindo SAS, R e Python;
- Ter uma sólida compreensão de estatística, incluindo testes e distribuições;
- Estar sempre atualizado sobre técnicas analíticas, como machine learning, análise de texto entre outros;
- Comunicar e colaborar tanto com TI quanto com a gerência;
- Procurar por ordem e padrões nos dados, além de identificar tendências que podem ajudar no resultado financeiro de uma empresa.

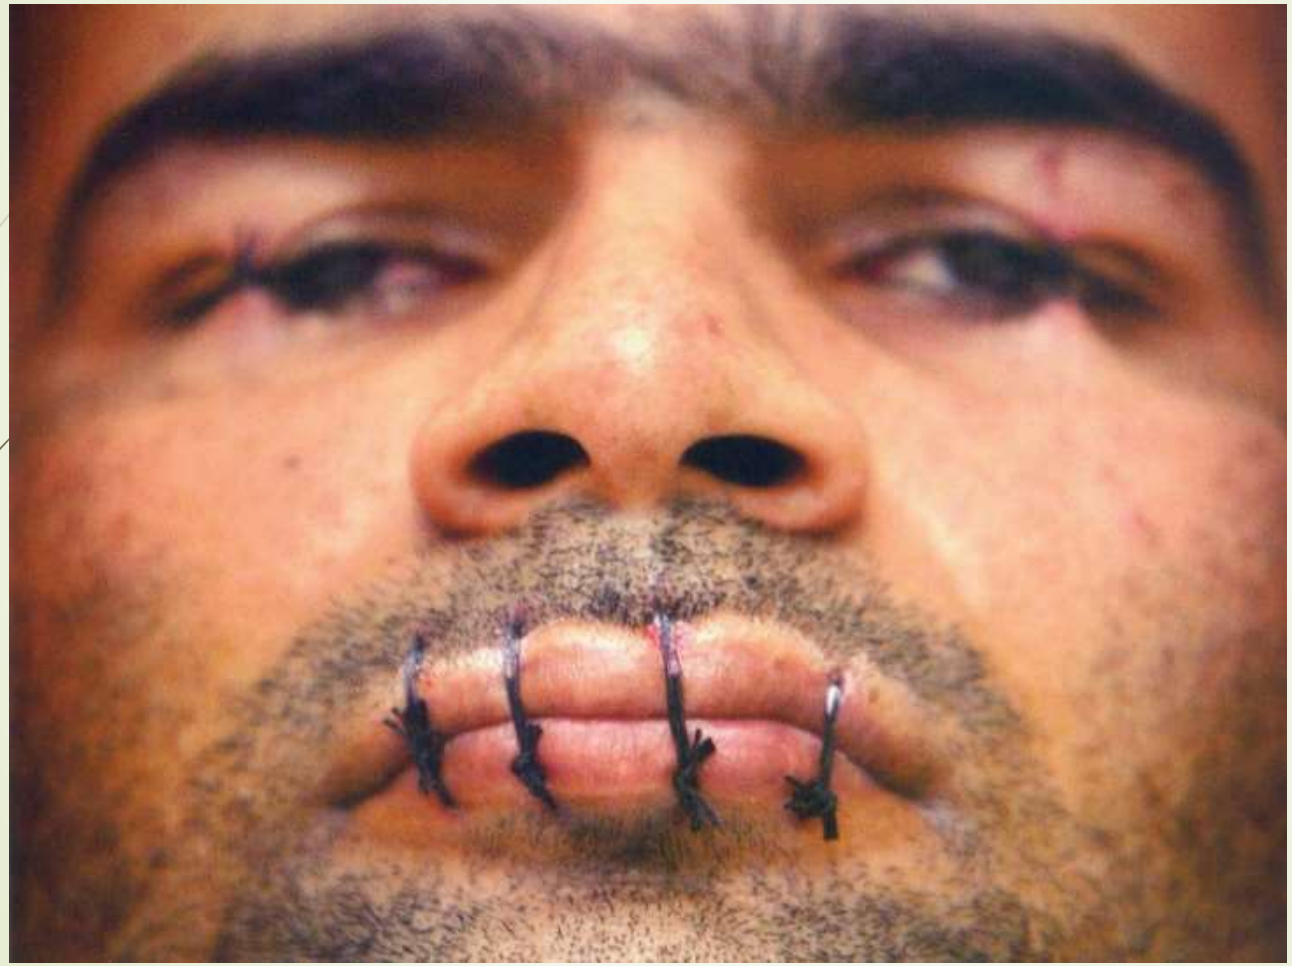
Analista de dados




Tempos de
revolução


Comprar TV = + 1 consumidor


200
bilhões de
horas
Assistindo TV

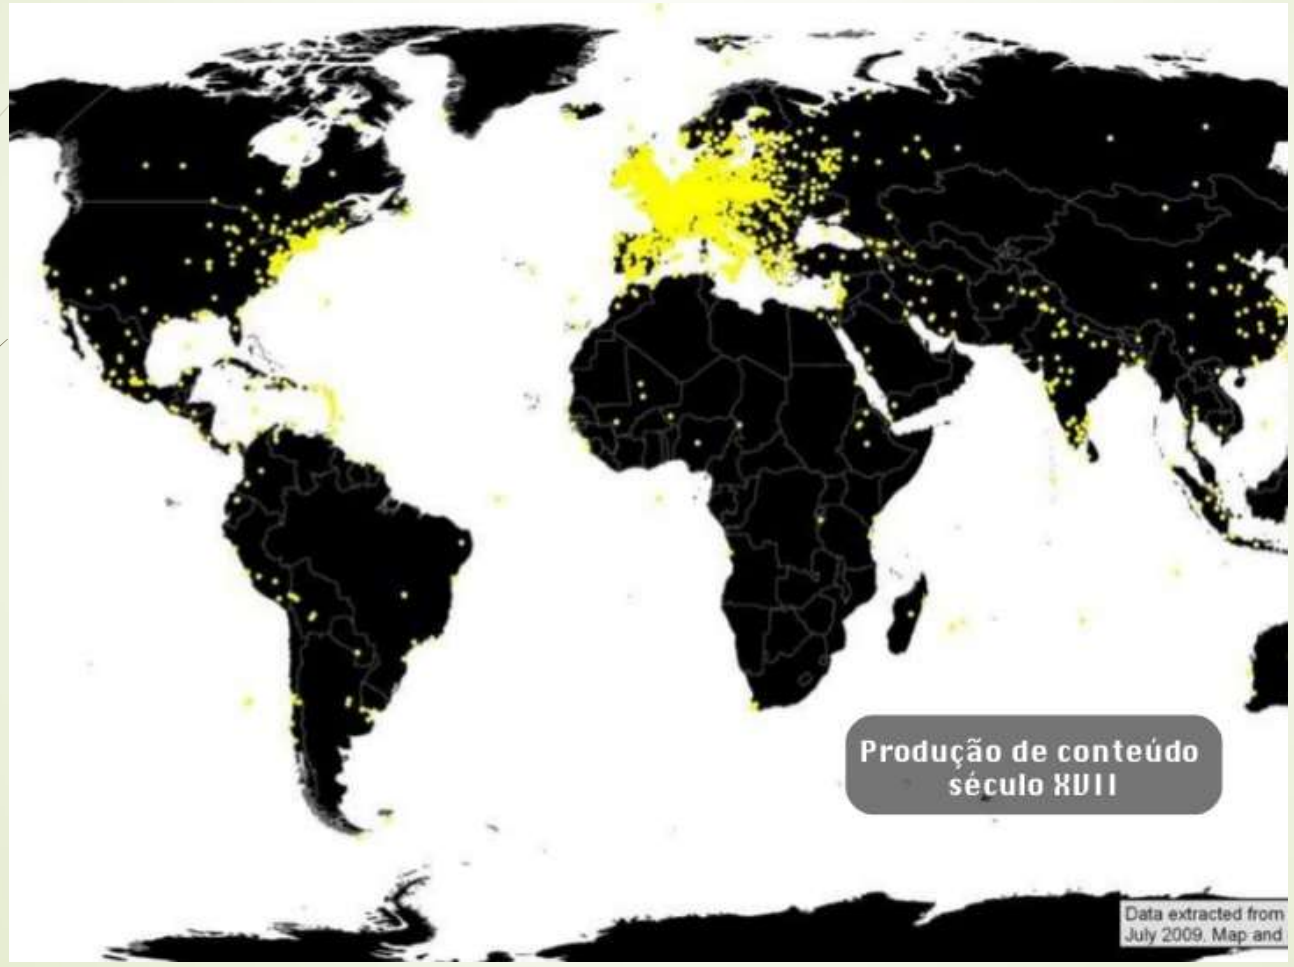


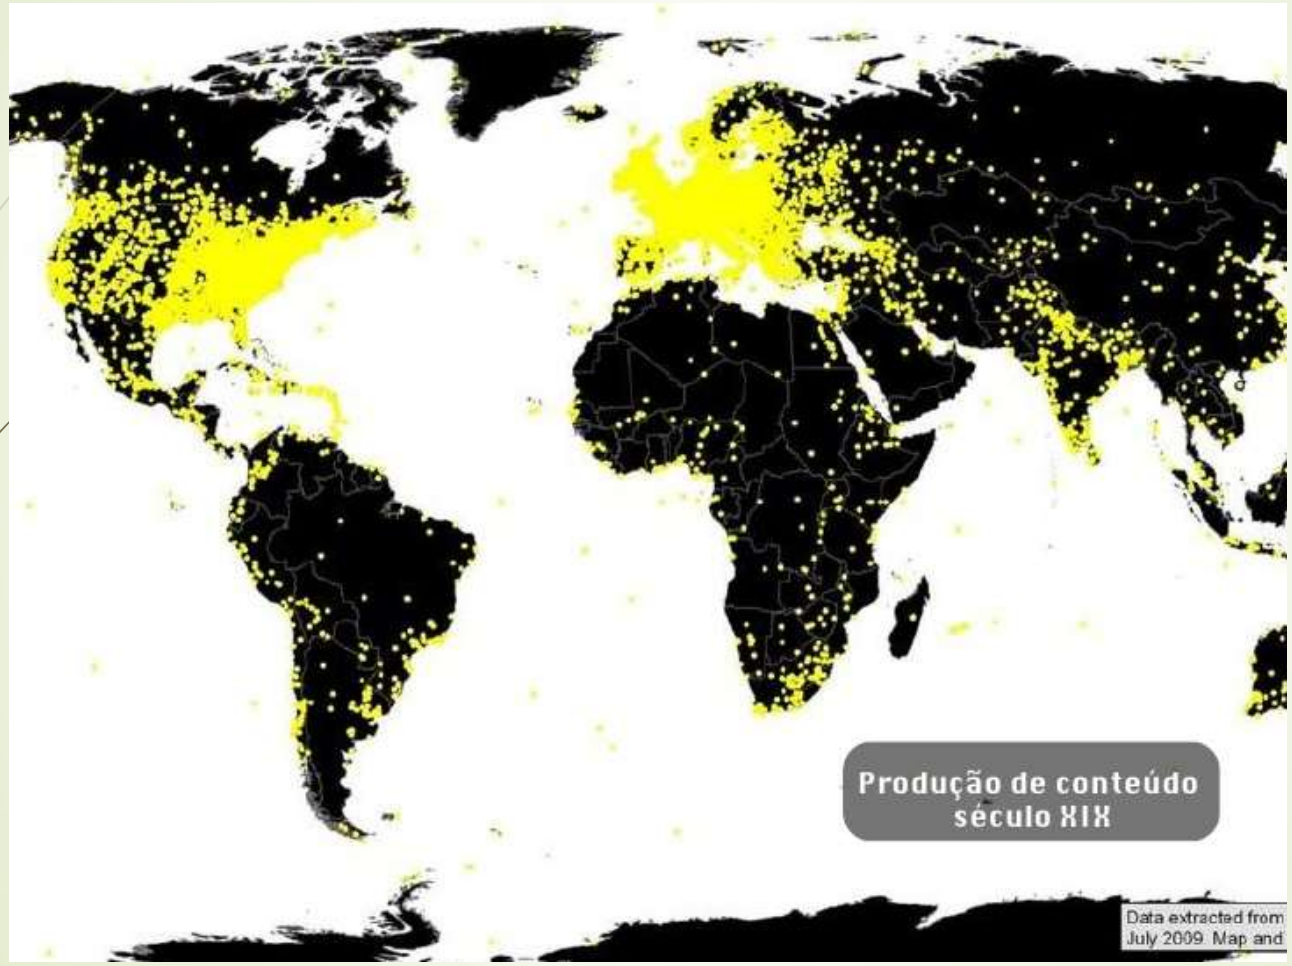

Tempos de
revolução

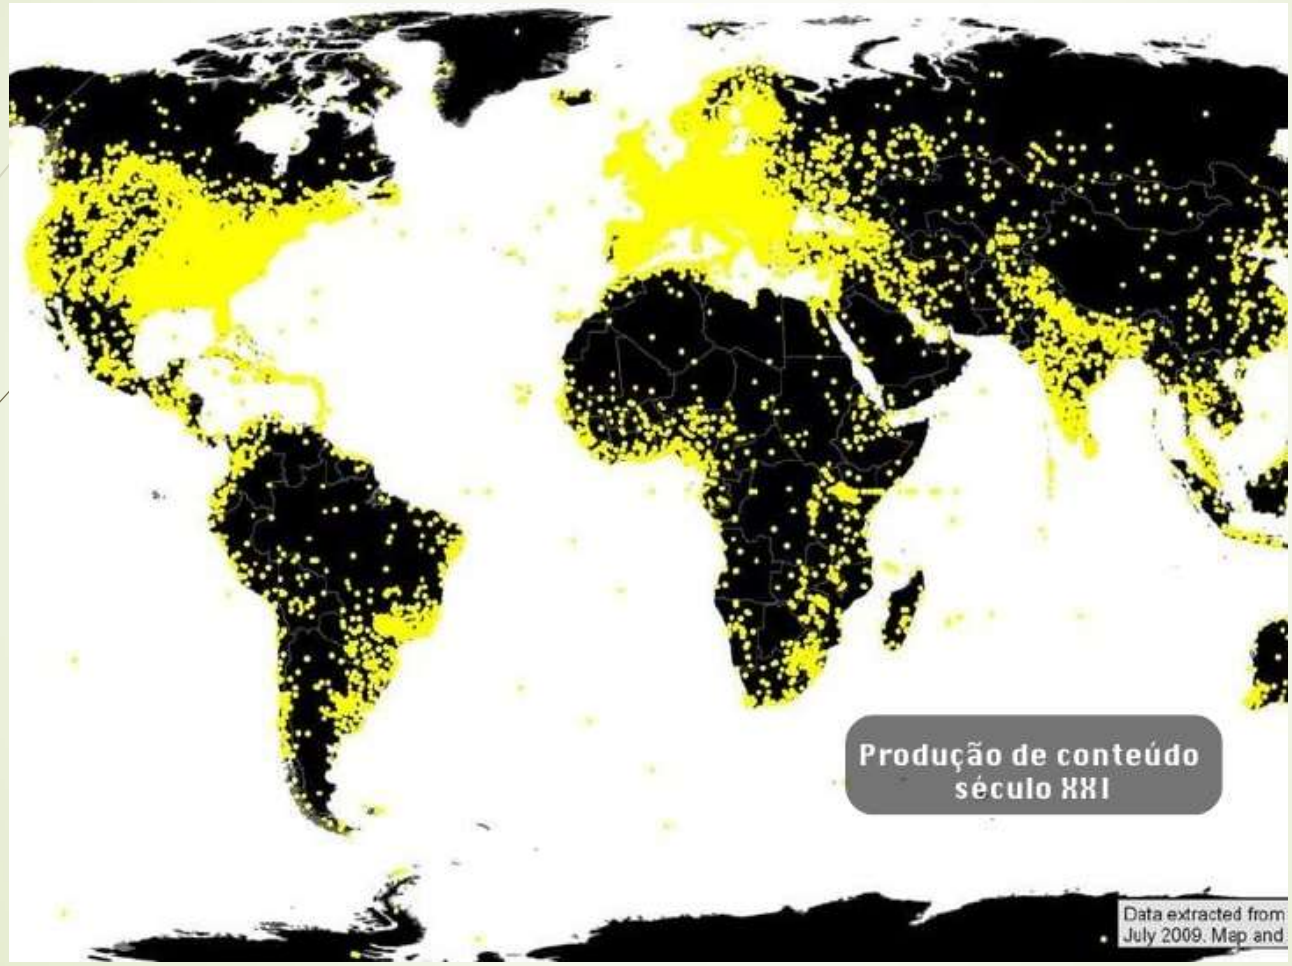



“Um mundo
novo?”


Comprar Computador
ou celular =+ 1
produtor

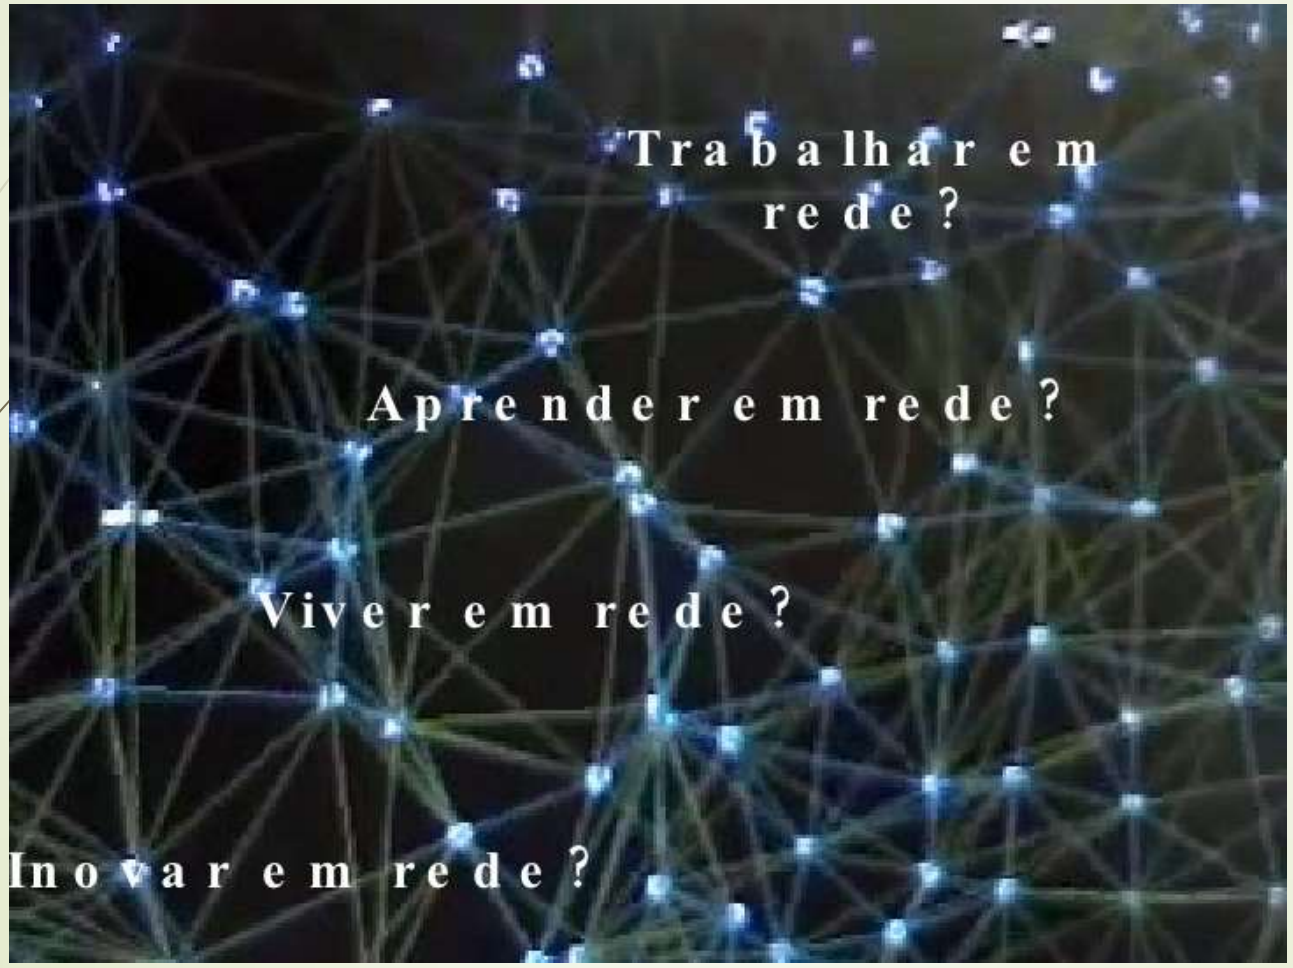

Produção de conteúdo
século XVII
Data extracted from
July 2009. Map and


Produção de conteúdo
século XIX
Data extracted from
July 2009 Map and

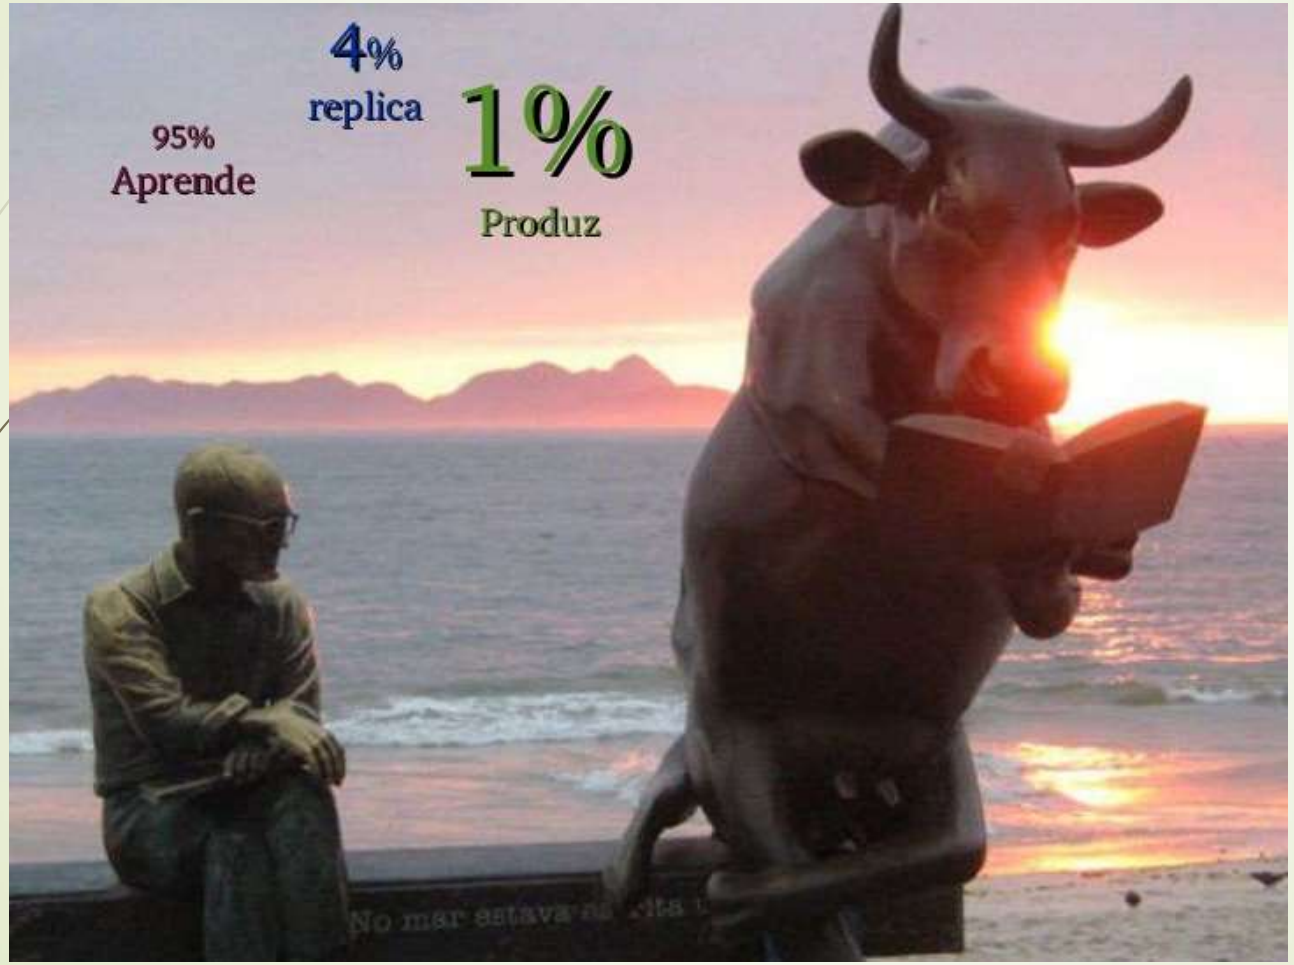

Produção de conteúdo
século XXI
Data extracted from
July 2009. Map and


Antigamente, para se obter uma multidão era preciso que muitas pessoas estivessem fisicamente juntas no mesmo lugar.


Revolução Francesa nos deu Liberdade?
Revolução verde nos deu comida?
Revolução do conhecimento nos deu rede?


Trabalhar em rede?
Aprender em rede?
Viver em rede?
Inovar em rede?


Um mundo em
transiçao


4%
replica
95%
Aprende
1%
Produz



- Fonte 2021


DADOS DA
INTERNET NO BRASIL
2018
MARKETINGSEMGRAVATA.COM.BR
210.1 milhões de brasileiros
139.1 mi usuários de internet
66% de penetração



- 2021



- 2021


1 computador
a cada 3 segundos



2005 na apresentação do Papa Bento XVI

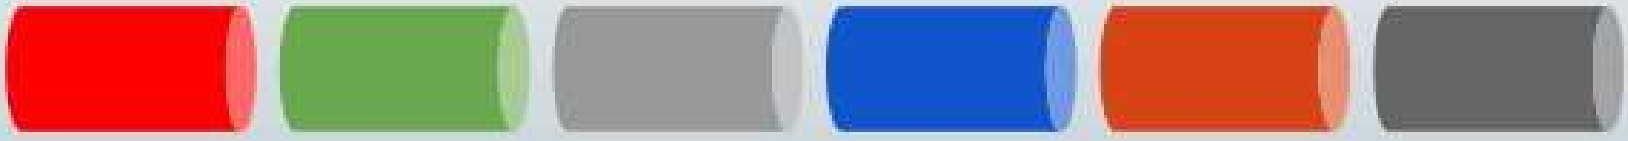


2013 na apresentação do Papa Francisco



Facebook social graph
4-degrees of separation [Backstrom-Boldi-Rosa-Ugander-Vigna, 2011]

Volume de dados



Total de dados sendo capturados e gravados pelas indústrias dobra a cada 1.2 anos.

A Google sozinha processa em média 40 mil queries por segundo.

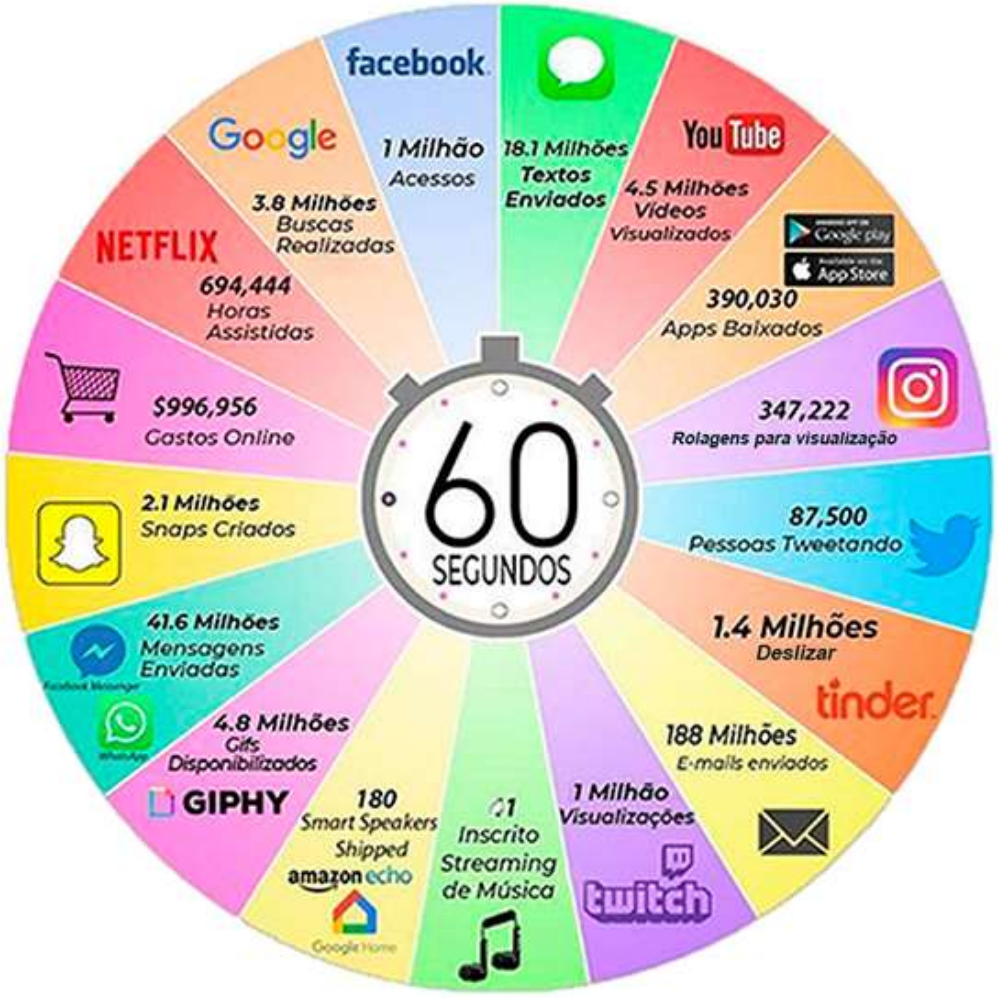
A cada minuto são enviados 204 milhões de emails.

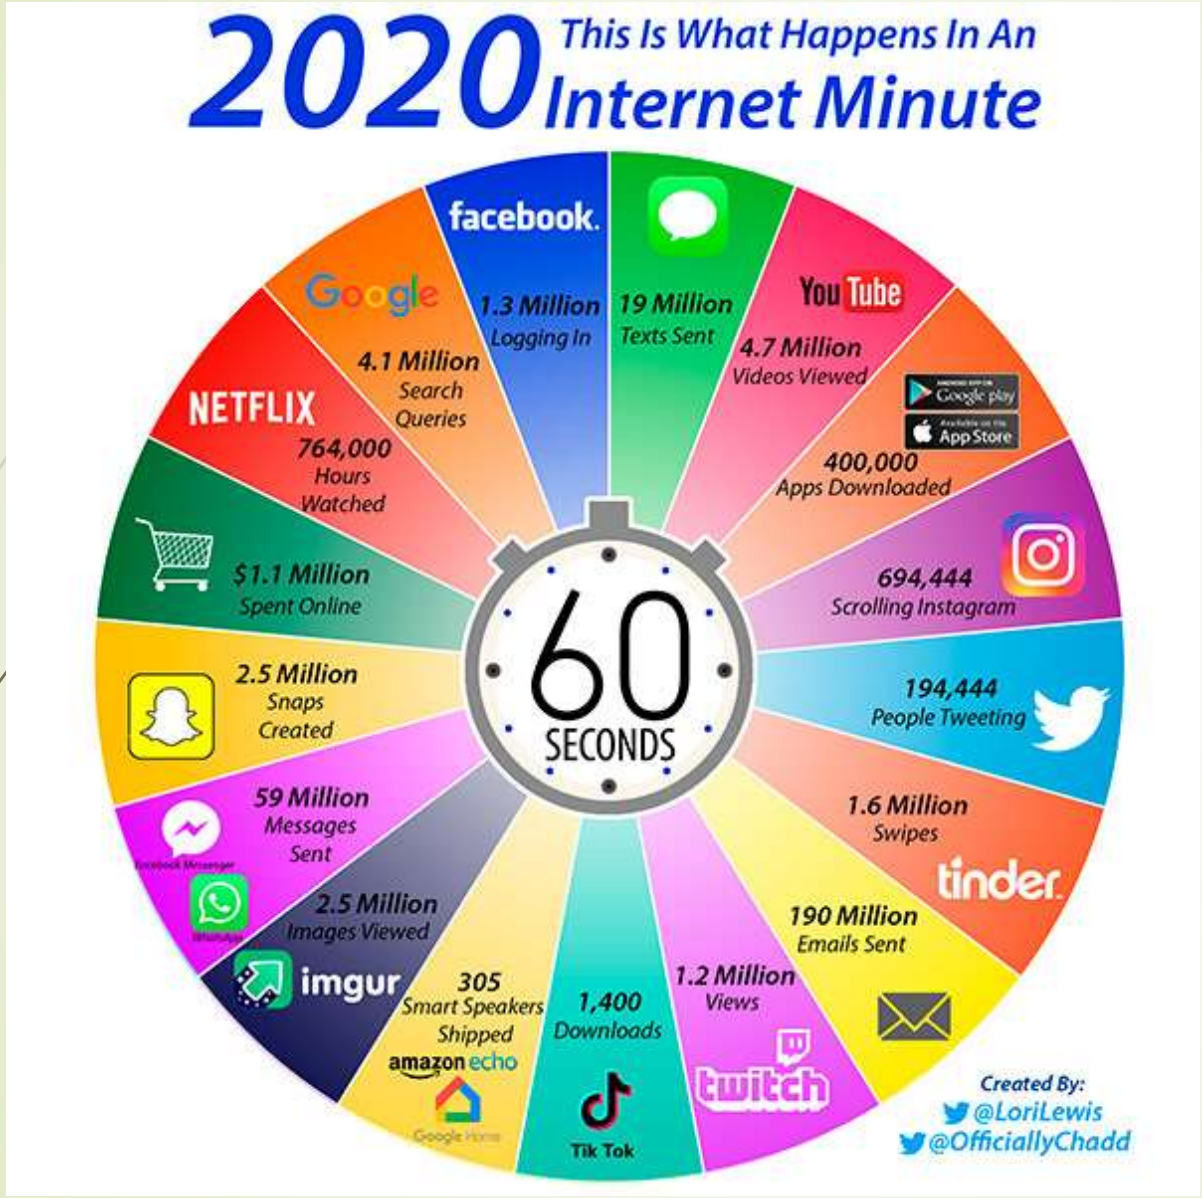
Youtube recebe 100 horas de vídeo a cada minuto.

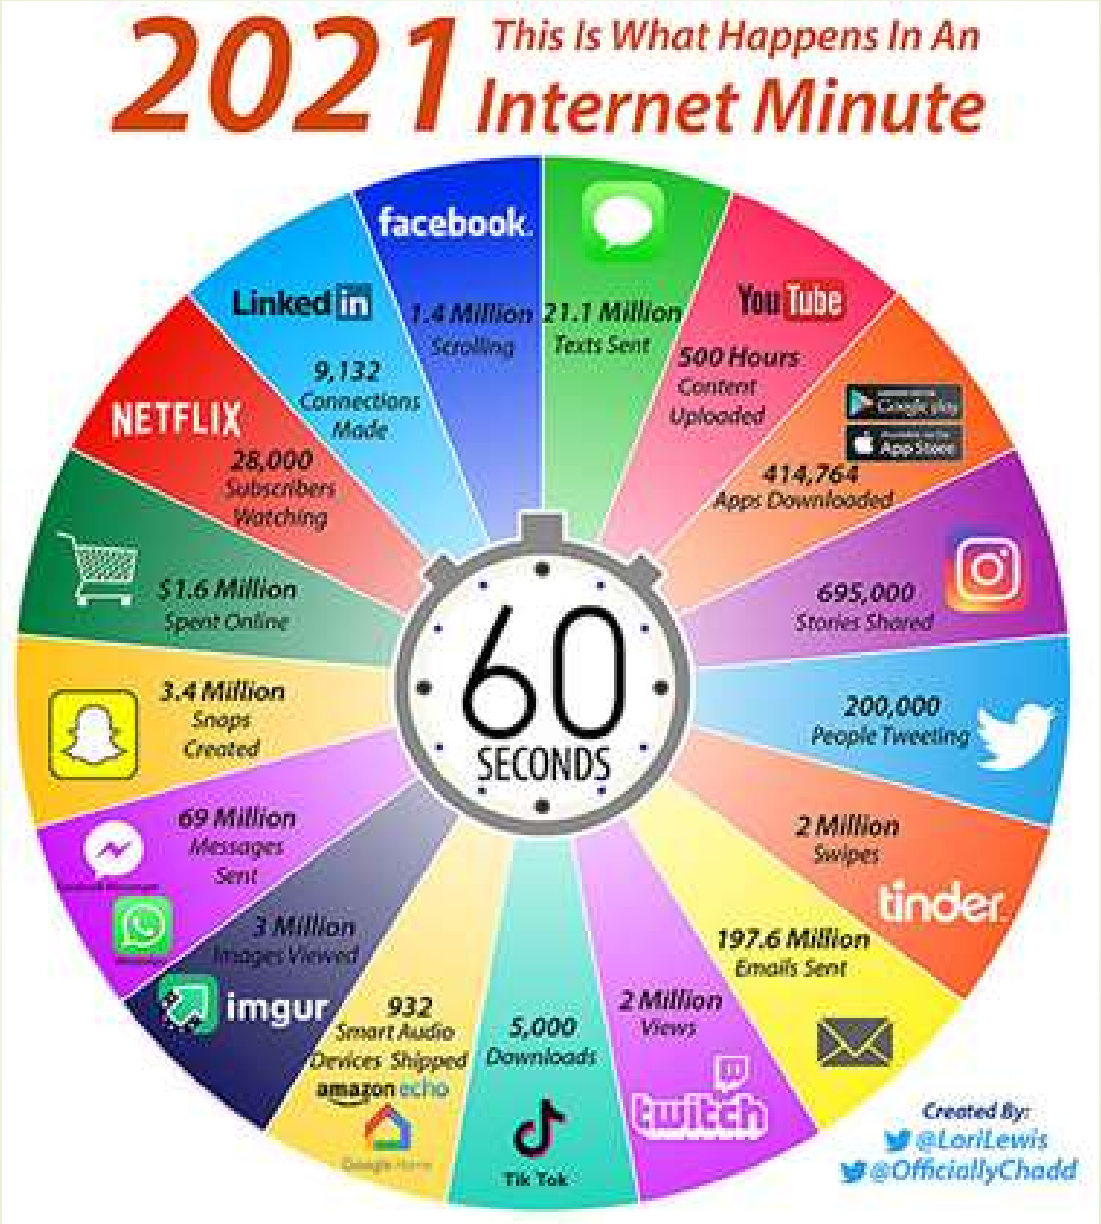
A cada minuto são gerados 1.8 milhões de likes no Facebook e enviados 278 mil tweets.

Se você gravasse todo conteúdo criado em 1 dia em DVD's, você poderia empilhá-los e alcançar a lua. Obs: 2 vezes.

2019 O QUE ACONTECE EM 60 SEGUNDOS NA INTERNET




2020 This Is What Happens In An Internet Minute
facebook.
1.3 Million
Logging In
19 Million
Texts Sent
YouTube
4.7 Million
Videos Viewed
400,000
Apps Downloaded
694,444
Scrolling Instagram
194,444
People Tweeting
1.6 Million
Swipes
tinder
190 Million
Emails Sent
1.2 Million
Views
twitch
1,400
Downloads
Tik Tok
305
Smart Speakers
Shipped
amazon echo
2.5 Million
Images Viewed
imgur
59 Million
Messages
Sent
2.5 Million
Snaps
Created
$1.1 Million
Spent Online
NETFLIX
764,000
Hours
Watched
Google
4.1 Million
Search
Queries
60
SECONDS
Created By:
@LoriLewis
@OfficiallyChadd


2021 This Is What Happens In An Internet Minute
facebook
1.4 Million Scrolling
21.1 Million Texts Sent
YouTube
500 Hours Content Uploaded
414,764 Apps Downloaded
695,000 Stories Shared
200,000 People Tweeting
2 Million Swipes
tinder
197.6 Million Emails Sent
2 Million Views
twitch
5,000 Downloads
Tik Tok
932 Smart Audio Devices Shipped
amazon echo
3 Million Images Viewed
imgur
69 Million Messages Sent
3.4 Million Snaps Created
$1.6 Million Spent Online
NETFLIX
28,000 Subscribers Watching
LinkedIn
9,132 Connections Made
60 SECONDS
Created By:
@LoriLewis
@OfficiallyChadd

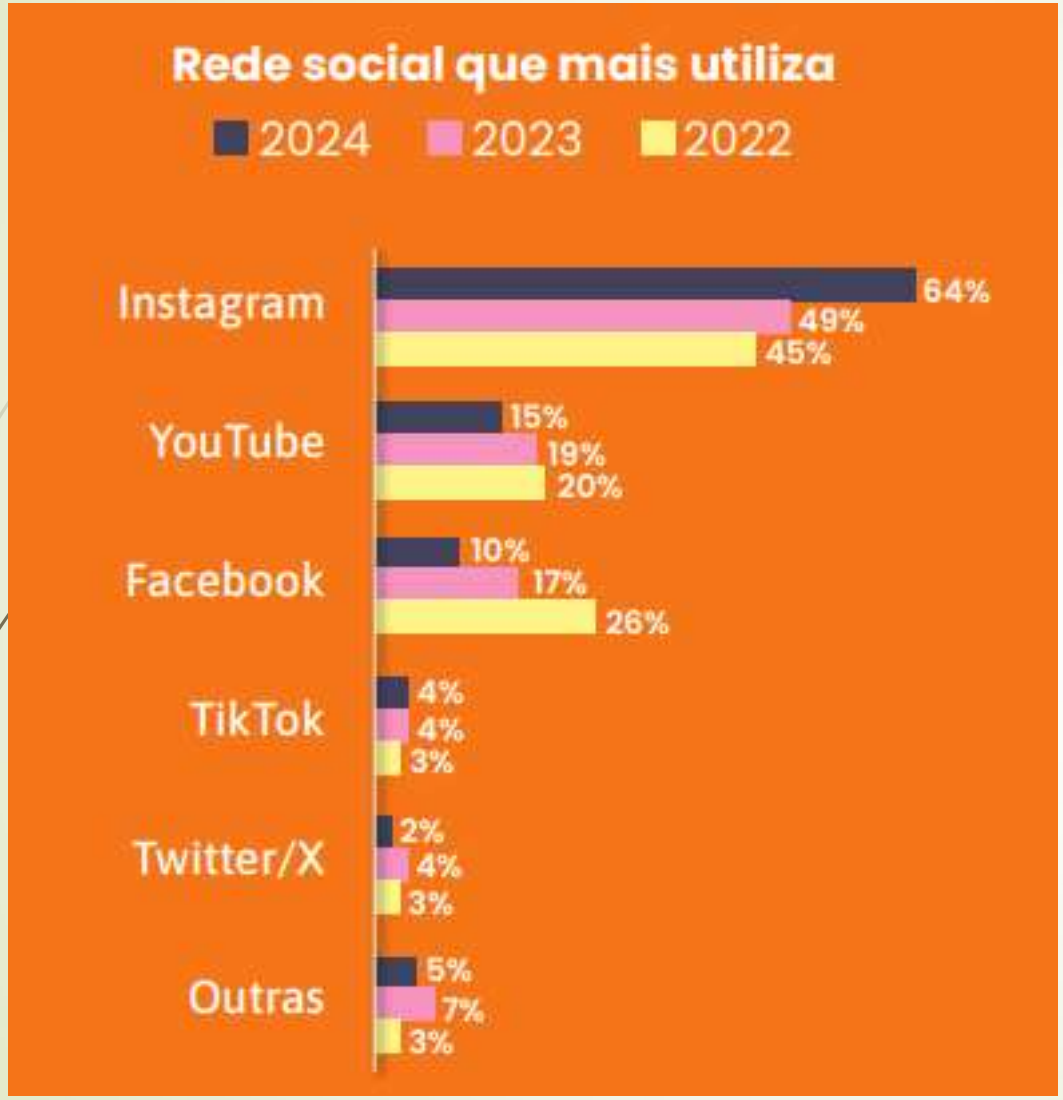

THE INTERNET IN 2023 EVERY MINUTE
60 SECONDS
22,831 visits to ChatGPT
241.2M emails sent
18.8M text messages sent
2.4M Google searches
694,000 video hours viewed
347,222 tweets
3.47M snaps created
10.4M viewing minutes
11,035 fake accounts removed
6.3M total Zoom meeting minutes
34,247 Slack messages
11,834 chats on Microsoft Teams
6.94M emoji sent
3.02M photos created with smartphones
271,309 iOS & Android app downloads
Created by: eDiscovery Today & LTMG

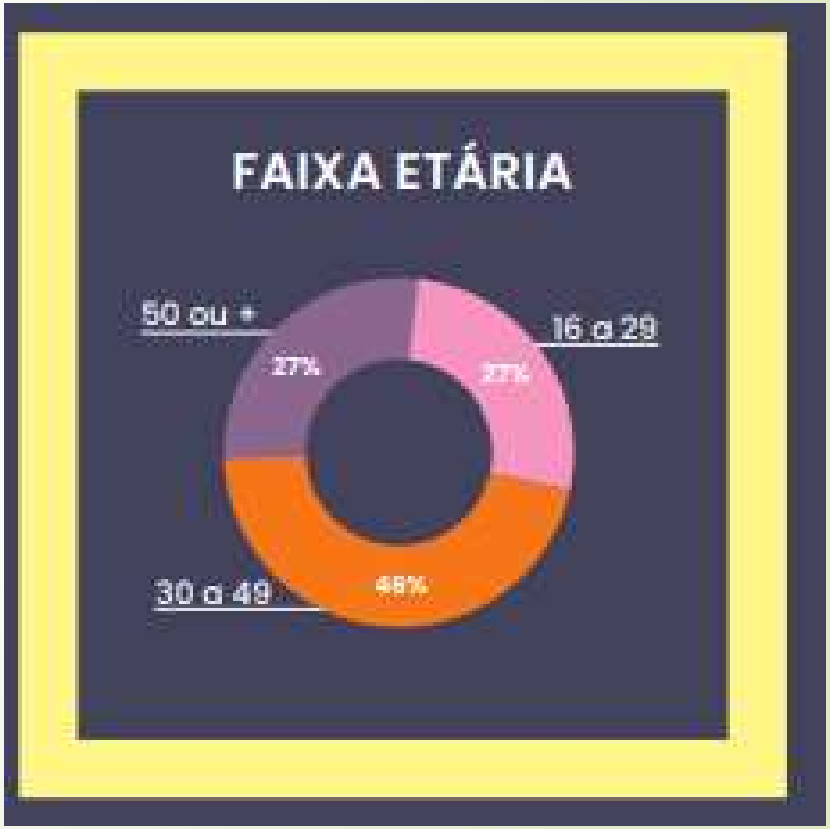

EVERY MINUTE OF THE DAY
DOMO
GOOGLE AI'S GEMINI
RECEIVES 8,574 VISITORS
TIKTOK
USERS UPLOAD 16,000 VIDEOS
NETFLIX
SUBSCRIBERS STREAMED 362,962 HOURS
PEOPLE DO 5.9M GOOGLE SEARCHES
SIRI
ANSWERS 1,041,666 QUESTIONS
18.8M TEXT MESSAGES SENT
3,472,222 YOUTUBE VIDEO VIEWS
138.9M REELS PLAYED ON FACEBOOK + INSTAGRAM
251.1M EMAILS SENT
9,000 MEMBERS APPLY FOR JOBS ON LINKEDIN
229M MEETING MINUTES RECORDED ON MSFT TEAMS
SNAPCHAT USERS SEND 3.3M SNAPS
CYBER WEEK SHOPPERS SPENT $43.6M GLOBALLY
288 PEOPLE DOWNLOAD ZOOM
AMERICANS TAKE 1,151,176,000 STEPS
DOORDASH DINERS PLACE $126,763 IN ORDERS
1.04M MESSAGES SENT ON SLACK
FORTNITE USERS WATCH 1,563 HOURS OF LIVE STREAMS
4,080 RECORDS COMPROMISED IN DATA BREACHES
TRAVELERS BOOK 852 AIRBNB STAYS

2025

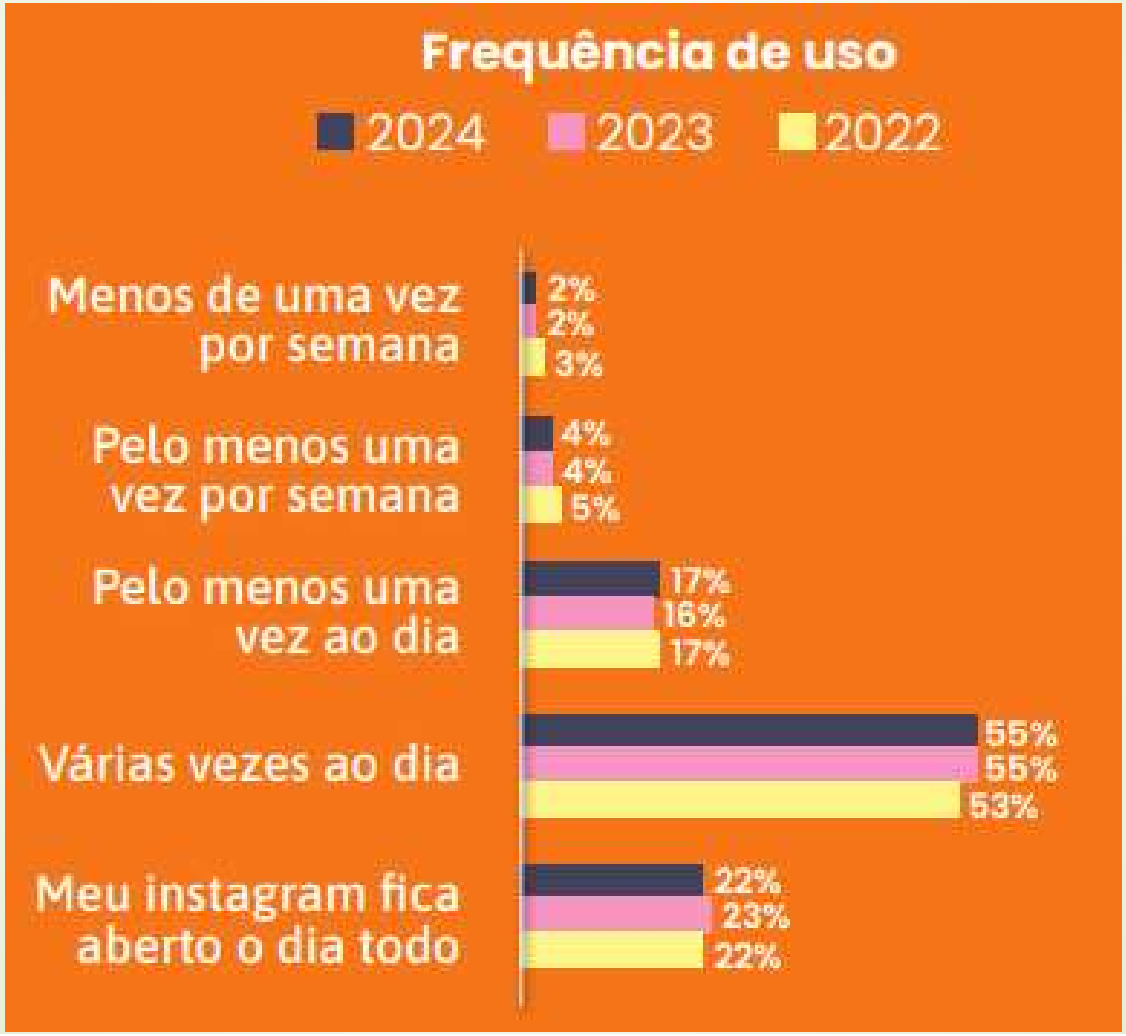
Em 2021...

- A média de usuários ativos no **Instagram** diariamente era de **400 milhões**;
- A média de usuários ativos no **Stories** diariamente era de **250 milhões**;
- O Instagram era utilizado por **48.8% das marcas**;
- A média de fotos postadas diariamente era de **95 milhões**;
- **32%** de toda a internet estava no Instagram;
- Posts com pelo menos uma **hashtag** tinha em média um aumento de **12.6%** no engajamento.


Rede social que mais utiliza
2024
2023
2022
Instagram
64%
49%
45%
YouTube
15%
19%
20%
Facebook
10%
17%
26%
TikTok
4%
4%
3%
Twitter/X
2%
4%
3%
Outras
5%
7%
3%

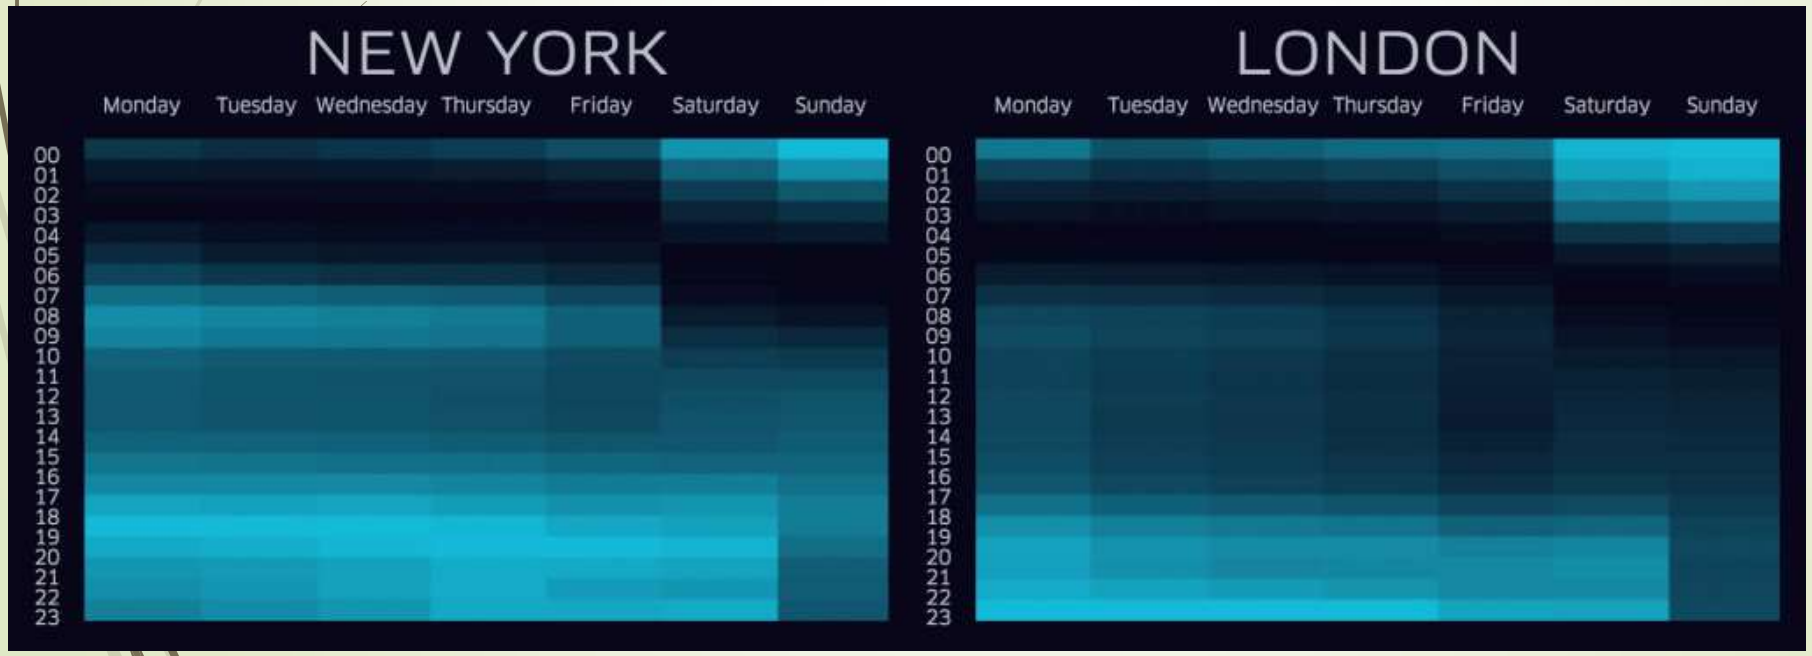

FAIXA ETÁRIA
50 ou +
16 a 29
27%
27%
30 a 49
46%

Instagram


Frequência de uso
2024
2023
2022
Menos de uma vez por semana
2%
2%
3%
Pelo menos uma vez por semana
4%
4%
5%
Pelo menos uma vez ao dia
17%
16%
17%
Várias vezes ao dia
55%
55%
53%
Meu instagram fica aberto o dia todo
22%
23%
22%

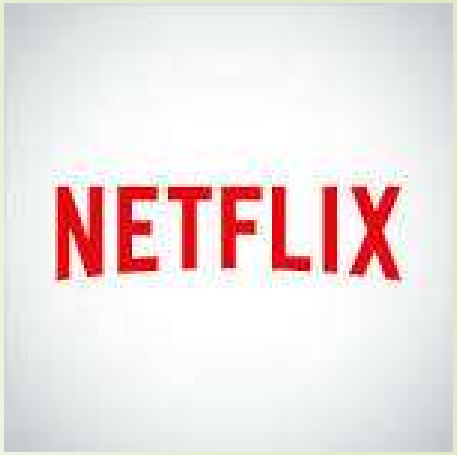
UBER

- A Uber armazena e analisa dados de cada viagem com a finalidade de **prever a demanda por carros, definir a tarifa e alocar recursos suficientes**.





- “Temos dados sobre como as pessoas estão usando música em suas vidas. É altamente emocional. **Podemos dizer quando alguém terminou um namoro**. As pessoas criaram playlists para enviar ao seu futuro ex. Nós sabemos quando as pessoas estão correndo, estudando, tentando ir dormir “
- “quando alguém cria uma lista de reprodução intitulada “*Odeio o Bob*”, sabemos o que está acontecendo ali”



- Pontos para extração de dados.

- o momento em que você pausa, volta ou adianta uma cena;
- quanto tempo depois de pausar a cena você retorna (ou não) ao conteúdo;
- em que dia e horário você mais assiste aos episódios;
- qual dispositivo é utilizado para assistir aos programas;
- os hábitos de rolagem pela tela inicial do serviço;
- a avaliação do que foi consumido.



- Assim como a filosofia não é sobre palavras, Big Data não é sobre dados. Big Data é sobre o **valor** e **Veracidade** que podem ser extraídos dos dados.

1 - Bancos/crédito e Seguradoras	Histórico de transações. Ficha cadastral. Referências externas como o serviço de proteção ao crédito (SPC). Índices micro e macro econômicos. Dados geográficos e demográficos.	Aprovação de crédito. Flexibilização de taxas. Análise de mercado. Previsão de inadimplência. Detecção de fraudes. Identificação de novos nichos. Análise de risco de crédito.
2 - Segurança	Histórico de visitação. Ficha cadastral. Textos de notícias e de conteúdo da WEB.	Detecção de padrões de comportamentos físico ou digital que oferecem algum tipo de risco.
3 - Saúde	Prontuário médico. Dados geográficos e demográficos. Sequenciamento de genomas.	Diagnóstico preditivo (previsão). Análise de dados genéticos. Descoberta de doenças e tratamentos. Mapa da saúde baseada em dados históricos. Efeitos adversos de medicamentos/tratamentos.
4 - Óleo, gás e eletricidade	Dados de sensores distribuídos.	Otimização dos recursos de produção Predição/detecção de falhas e fraudes.

5 - Varejo	Histórico de transações. Ficha cadastral. Percurso de compra em loja física e/ou virtual. Dados geográficos e demográficos. Dados de publicidade. Reclamações de clientes.	Aumento do faturamento pela otimização do mix de produto com base no padrão de comportamento durante de compra. Análise de faturamento (as-is, tendências), do alto volume de clientes e transações, crédito, perfil por regiões. Aumento de satisfação/fidelização dos clientes.
6 - Produção	Dados dos sistema de gestão/produção ERPs. Dados de mercado.	Otimização da produção em relação as vendas. Diminuição do tempo/quantidade de estocagem. Controle de qualidade.
7 - Organizações representativas	Ficha cadastral declientes. Dados de eventos. Processo comercial em sistema de CRM.	Sugerir combinações ótimas de perfis de empresa, clientes, fornecedores para alavancagem de negócios. Identificação de oportunidades de sinergias.

8 - Marketing	Índices micro e macroeconômicos. Pesquisa de mercado. Dados geográficos e demográficos. Conteúdo gerado pelos clientes. Dados dos concorrentes.	Segmentação de mercado. Otimização a alocação dos recursos em publicidade. Descoberta de nichos de mercado. Desempenho de marca/produto. Identificação de tendências.
9 - Educação	Histórico escolar e frequências. Dados geográficos e demográficos.	Classificação de perfis de aprendizado com vistas a personalização da educação. Análise preditiva de evasão escolar.
10 - Financeiro/Econômico	Lista de ativos e seus valores. Histórico de transações. Índices micro e macroecnômicos.	Identificar o valor ótimo de compra de ativos complexos com muitas variáveis de análise (veículos, imóveis, ações e etc.). Determinação de tendências nos valores de ativos. Descoberta de oportunidades de arbitragem.
11 - Logística	Dados dos produtos. Rotas e pontos de entrega.	Otimização de fluxos de mercadorias. Otimização de estoques.

12 - E-commerce	Cadastro do cliente. Histórico das transações. Conteúdos gerados pelos clientes.	Aumento do faturamento por recomendações automáticas de produtos relacionados ao seu perfil e o perfil do produto. Aumento da satisfação/fidelização dos clientes.
13 - Games, redes sociais e plataformas (freemium)	Histórico de acessos. Cadastro dos usuários. Dados geográficos e demográficos.	Aumentar a taxa de conversão de usuários gratuitos para usuários pagantes pela detecção do comportamento e preferências dos usuários.
14 - Recrutamento (RH)	Cadastro das pessoas. Histórico profissional e currículos. Conexões em redes sociais.	Avaliação de perfil da pessoa para determinado cargo. Critérios para contratação, promoção e demissão. Melhor alocação dos recursos.


Idioma: Português
eleicoes-sem-fake@dcc.ufmg.br
ELEIÇÕES SEM FAKE UFMG
Início
Sistemas
Na Mídia
Divulgação Científica
Contato
PROJETO
Eleições Sem Fake
Várias mudanças no ecossistema de notícias vêm favorecendo campanhas de desinformação e disseminação de notícias falsas. Nosso grupo de pesquisa desenvolveu uma série de sistemas que visam trazer transparência para o espaço midiático e mitigar os problemas criados por essas mudanças. Nosso objetivo é contribuir para que a desinformação não desvirtue as eleições brasileiras de 2022.



https://brasil.io



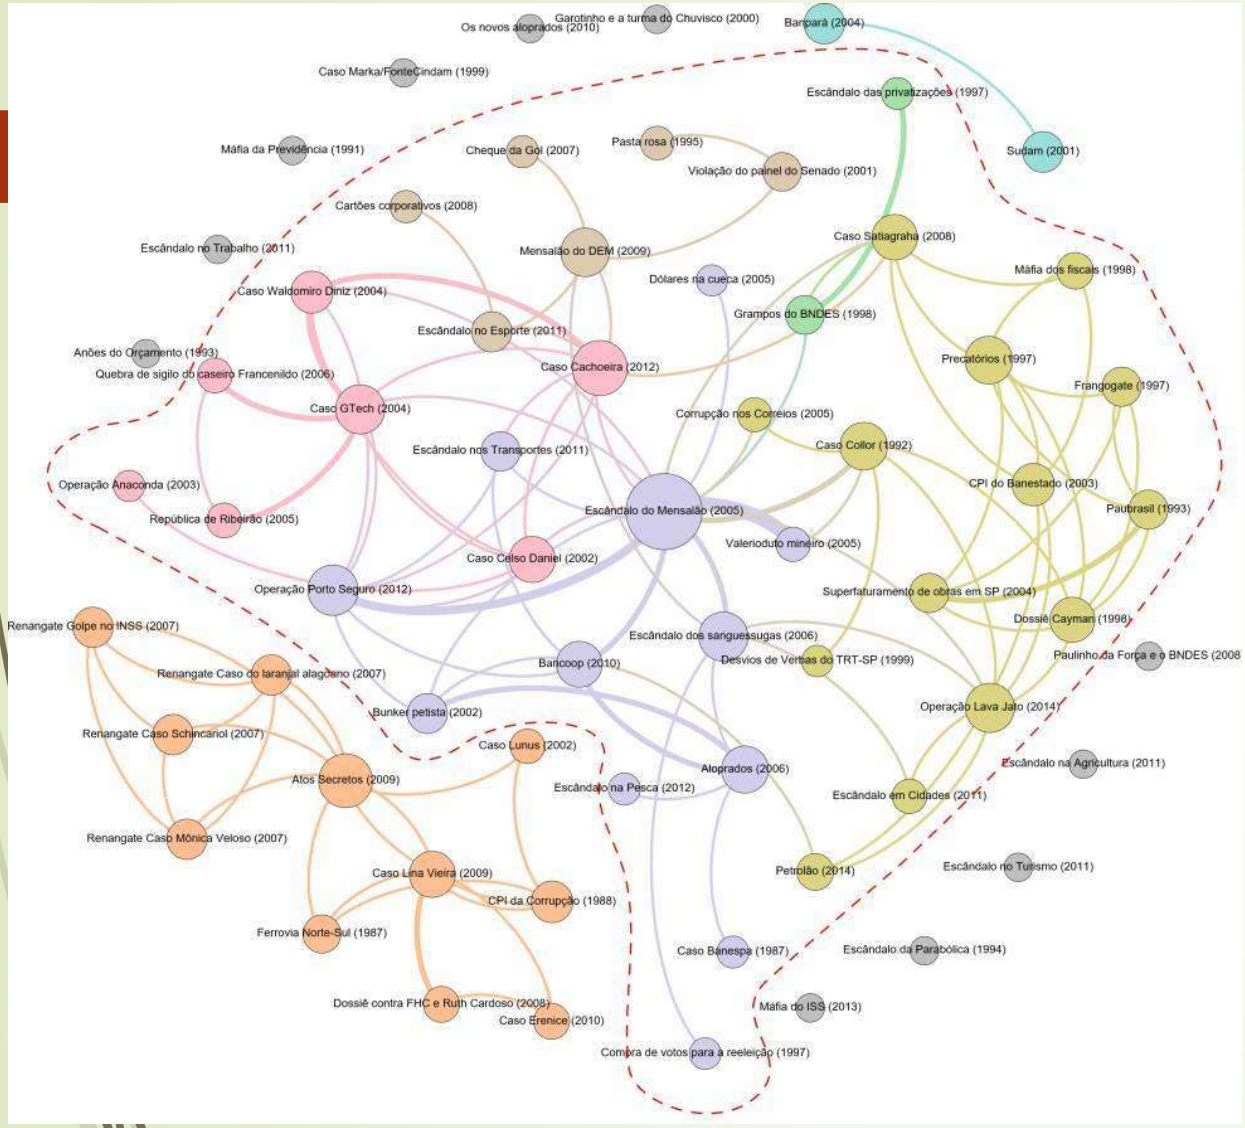
https://brasil.io

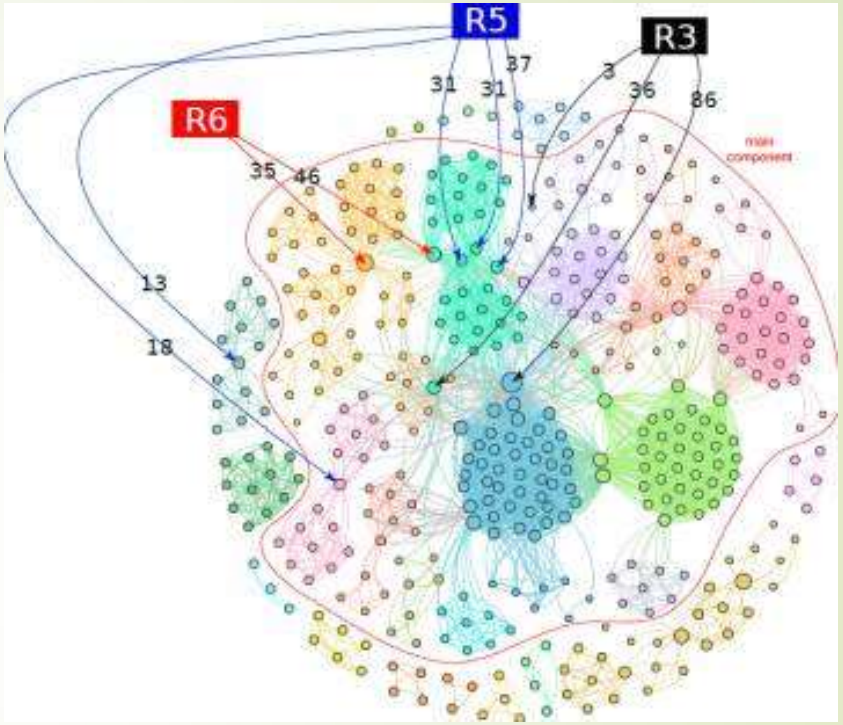


https://brasil.io

Em 2018


DETECTOR
DE FICHA DE POLÍTICO
DESCUBRA A VERDADEIRA FACE DOS POLÍTICOS.
INSTITUTO RecLameAQUI
FOTOGRAFE O ROSTO DO POLÍTICO E DESCUBRA SE ELE TEM ALGUM PROBLEMA COM A JUSTIÇA.
INSTITUTO RecLameAQUI
FUNCIONA ONDE O POLÍTICO ESTIVER.
Comerciais de TV, debates. Santinhos, cartazes. Anúncios de jornal. Vídeos na internet. Comícios.
INSTITUTO RecLameAQUI
NO BANCO DE DADOS DO DETECTOR DE CORRUPÇÃO CONSTAM OS SEGUINTES POLÍTICOS:
Governadores, Vice-Governadores e Deputados Federais (Eleitos desde 2014);
Senadores (Eleitos desde 2010);
Presidentes e Vice-Presidentes (Vivos);
Candidatos a Presidente e Governadores (Com base no Datafolha e Ibope).
INSTITUTO RecLameAQUI



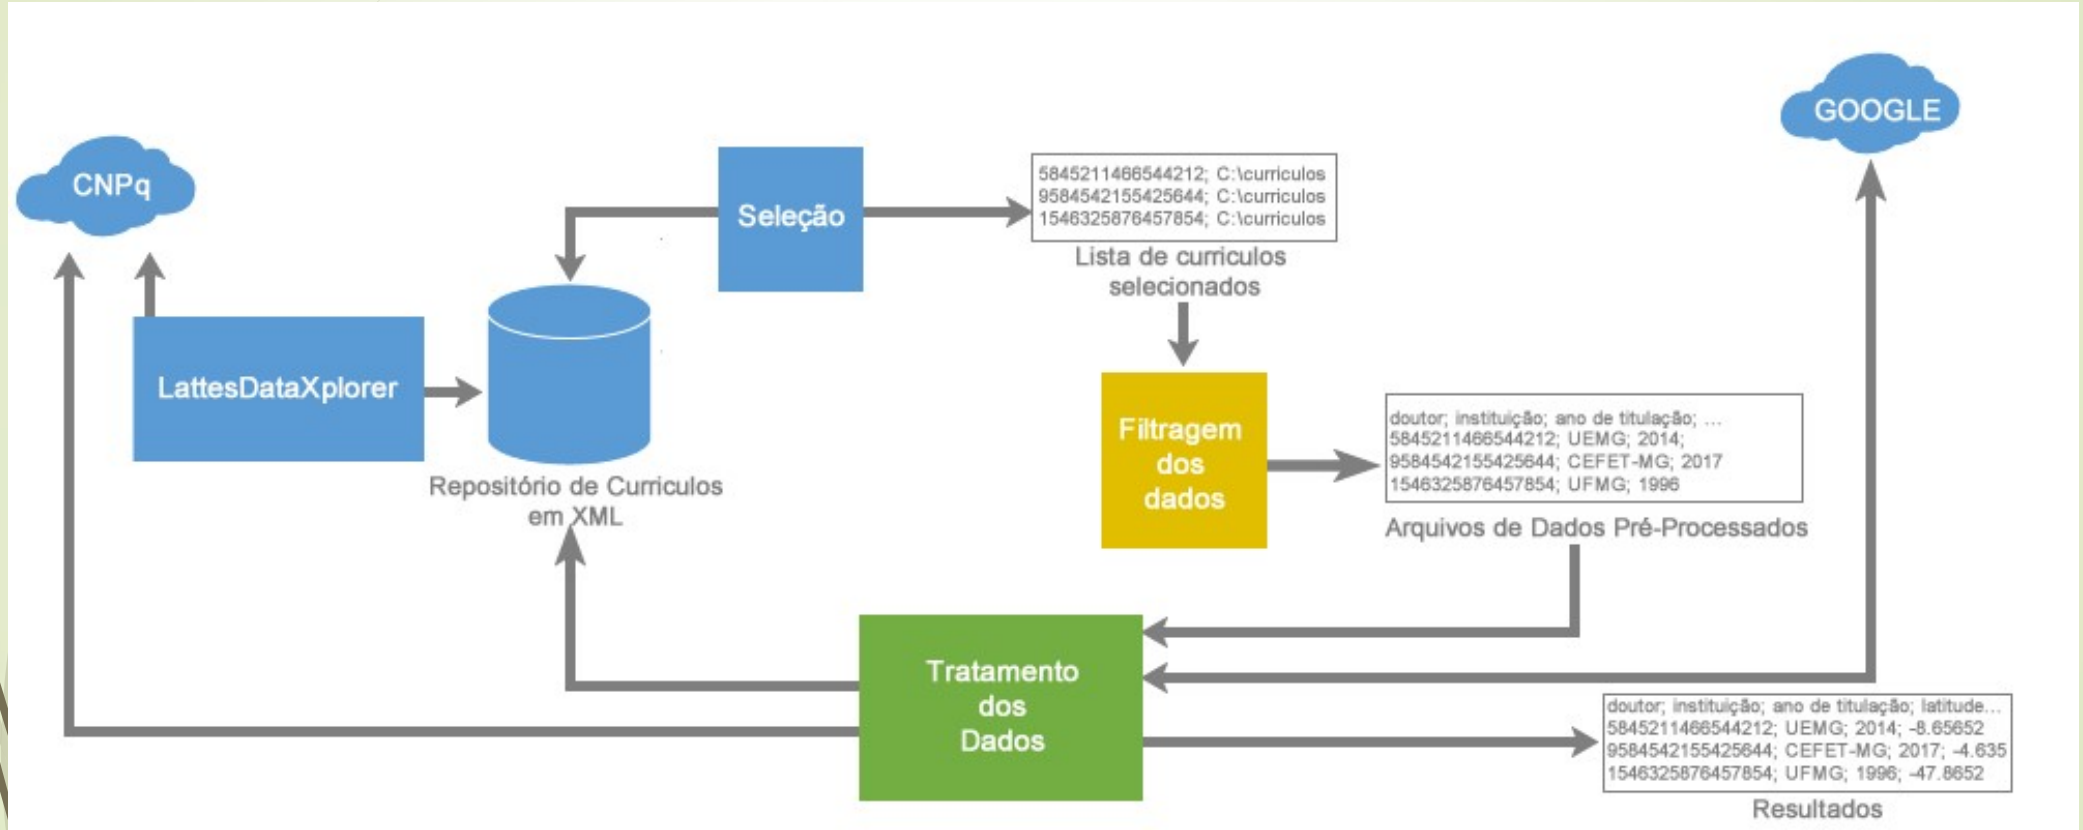


RIBEIRO, Haroldo V. et al. The dynamical structure of political corruption networks. **Journal of Complex Networks**, 2018.


Ir para o conteúdo 1 Ir para o menu 2 Ir para a busca 3 Ir para o rodapé 4
MAPA DO SITE ALTO CONTRASTE ACESSIBILIDADE
Departamento de
Polícia Rodoviária Federal
MINISTÉRIO DA JUSTIÇA E SEGURANÇA PÚBLICA
Canais de Atendimento | Telefones e endereços | Área de Imprensa | Dados Abertos | Ouvidoria
VOCÊ ESTÁ AQUI: PÁGINA INICIAL
MULTAS
Consulta e pagamento de multas
Formulário de recursos
Formulário de indicação de condutor infrator
Formulário de restituição de valores
Cópia de decisões
Pedido de advertência
Estudo Técnico Radar
Notificação por edital
Lista de radares
Dados Abertos são dados publicados em um formato legível por máquina e sem restrição de licenças, patentes ou mecanismos de controle, de modo a estarem livremente disponíveis para serem utilizados e redistribuídos à vontade. A política de Dados Abertos governamental, pauta que vem ganhando cada vez mais atenção no âmbito do Poder Público, trata da disseminação de informações públicas na Internet, a fim de que possam ser reutilizadas por toda a sociedade. Vários órgãos já possuem a cultura de divulgação de dados e a tendência é que haja cada vez mais interesse e envolvimento das entidades nesse processo.
Caso necessite de dados que não se encontram no rol das informações disponibilizadas aqui, entre em contato com ascom@prf.gov.br para orientações.
Arquivos em formato .CSV
Os arquivos disponibilizados na área dos dados abertos estão compactados (zipados) para diminuição do tamanho real e também no formato CSV (comma-separated values).
Clique aqui e acesse conteúdo explicativo de método abrir os arquivos CSV em editores de planilhas (Microsoft Office Excel e LibreOffice).
Acidentes ACESSE AQUI
Infrações de trânsito ACESSE AQUI
Dicionário de dados - Acidentes ACESSE AQUI
Dicionário de dados - Infrações ACESSE AQUI
Ativar o Windows
Acesse as configuraçõe

Desafios


Dados não estruturados
Processamento necessário
Visualização da informação
Privacidade de dados


CNPq
LattesDataXplorer
Repositório de Curriculos em XML
Seleção
5845211466544212; C:\curriculos
9584542155425644; C:\curriculos
1546325876457854; C:\curriculos
Lista de curriculos selecionados
Filtragem dos dados
doutor; instituição; ano de titulação; ...
5845211466544212; UEMG; 2014;
9584542155425644; CEFET-MG; 2017
1546325876457854; UFMG; 1996
Arquivos de Dados Pré-Processados
GOOGLE
Tratamento dos Dados
doutor; instituição; ano de titulação; latitude...
5845211466544212; UEMG; 2014; -8.65652
9584542155425644; CEFET-MG; 2017; -4.635
1546325876457854; UFMG; 1996; -47.8652
Resultados

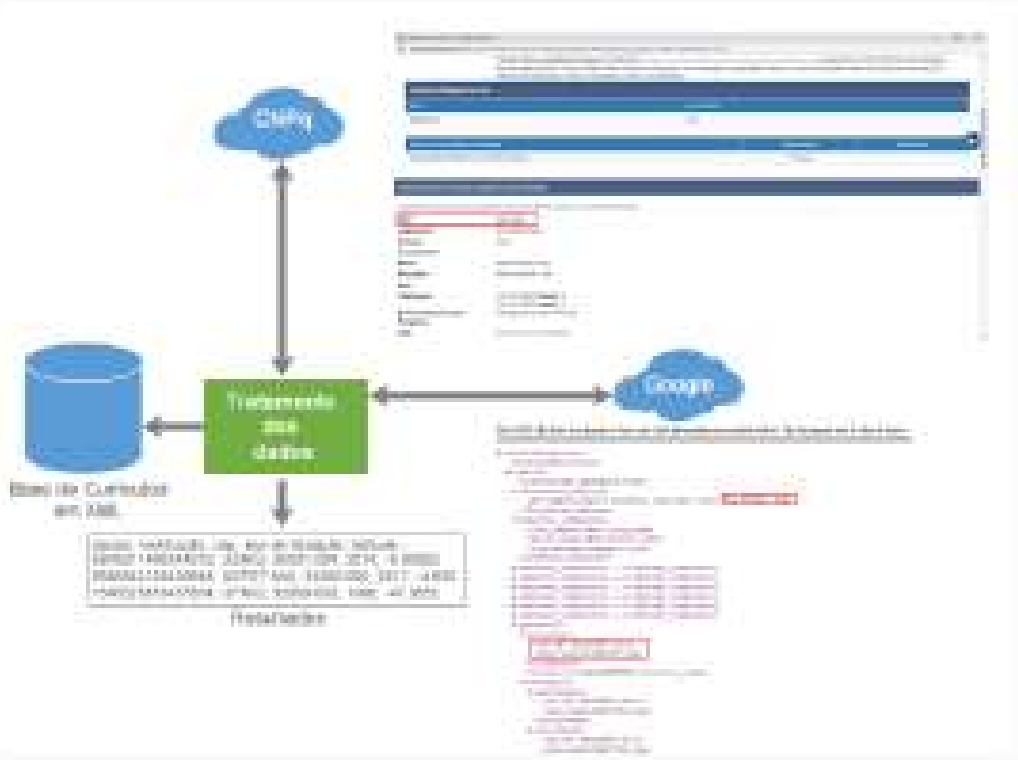
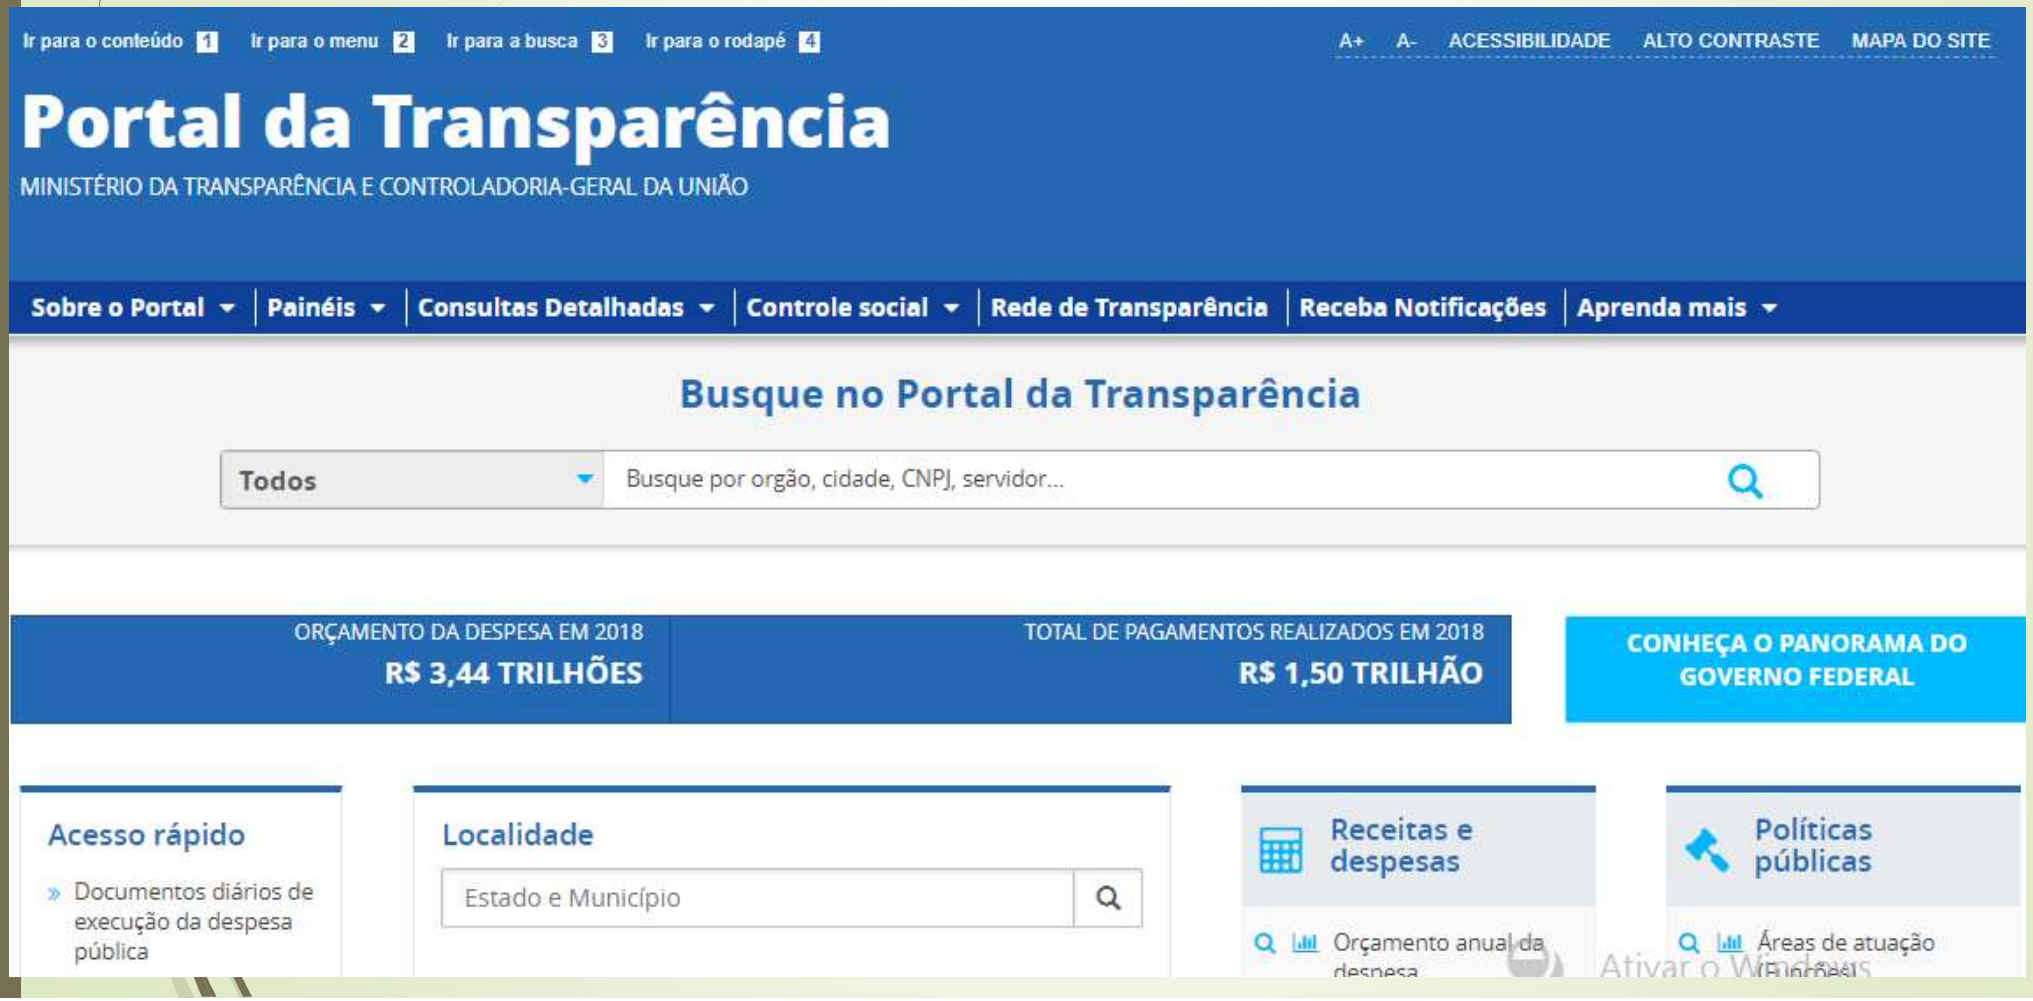


Figura 3: Tratamento dos dados.

- Obtenção de CEP da instituição;
- Busca pela localização geográfica;
- Extração da classificação dos periódicos;
- Limpeza e agrupamento de dados;
- Normalização dos dados.

Fontes que podem ser utilizadas para efetuar a extração e análise de dados...



Fontes que podem ser utilizadas para efetuar a extração e análise de dados...



Fontes que podem ser utilizadas para efetuar a extração e análise de dados...



https://www.infomoney.com.br/negocios/inovacao/noticia/7954187/brasileiro-cria-robos-que-fazem-videos-e-publicam-no-youtube-sozinhos (criação de robôs para publicar vídeos no youtube)

https://www.bol.uol.com.br/noticias/2019/03/05/cameras-de-reconhecimento-facial-acham-criminoso-no-carnaval-de-salvador.html (cameras de Salvador notificam que um criminoso está por perto e auxilia a polícia a prender o sujeito)

https://thispersondoesnotexist.com/image (cria imagens de pessoas que não existem)


Não podemos usar
velhos mapas
para encontrar novos caminhos!
Gil Giardelli

