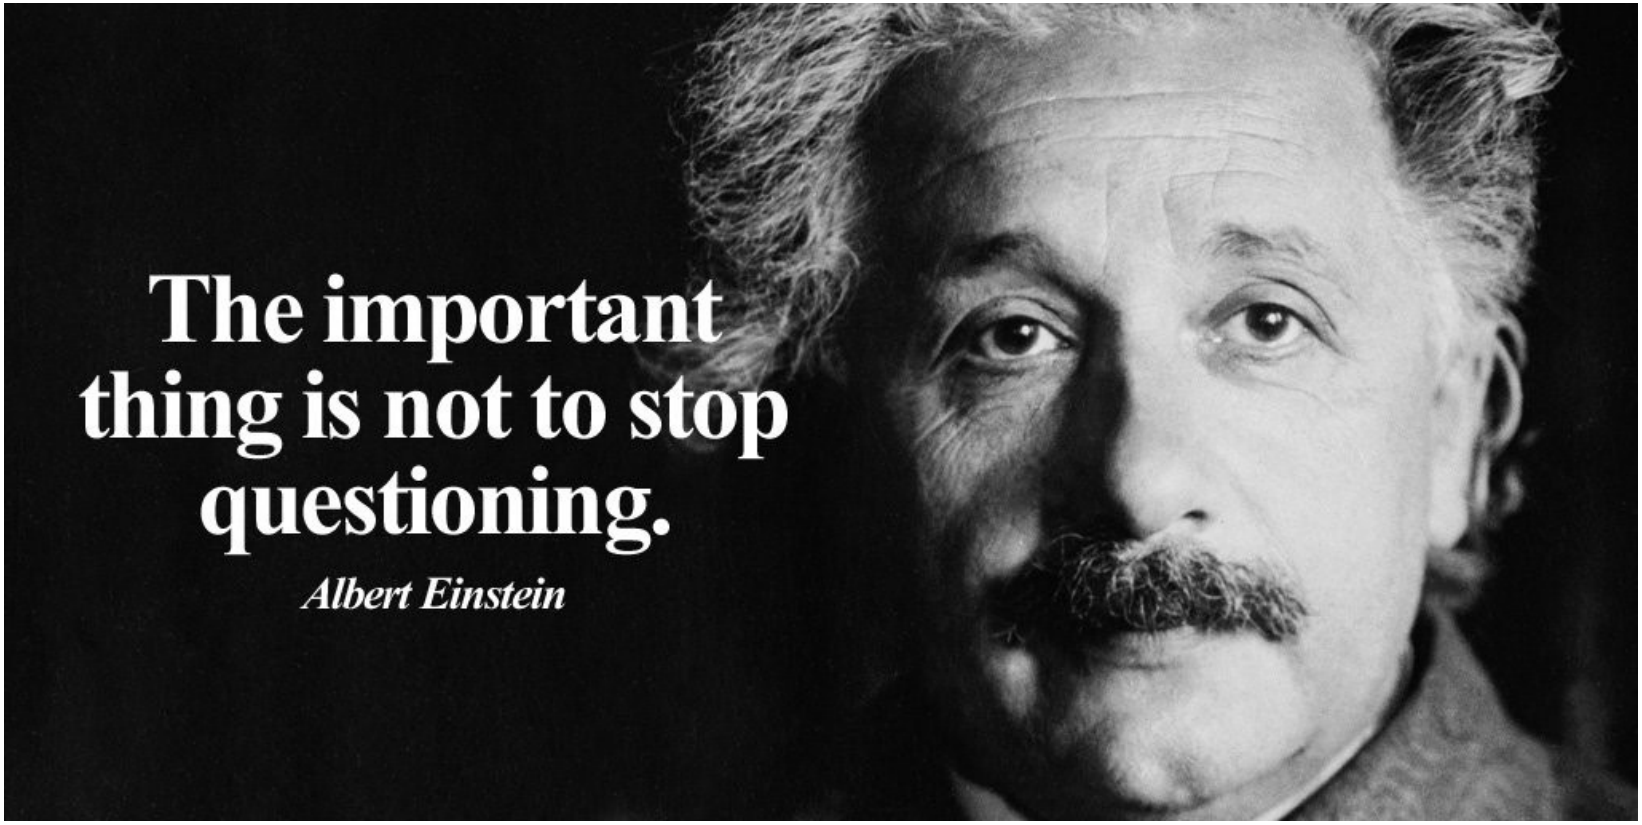
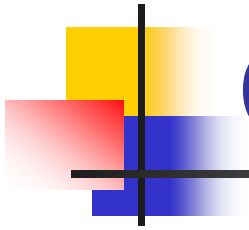


Natureza dos Dados

Adaptado de C. Batista

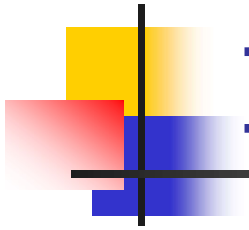
Ciência de dados





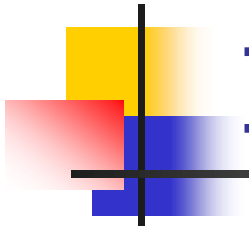
Ciência de dados

- Ciência de dados é uma área interdisciplinar voltada para o estudo e a análise de dados, que visa a extração de conhecimento, detecção de padrões e/ou obtenção de insights para possíveis tomadas de decisão.
- Ela estuda o dado desde a produção até o descarte.



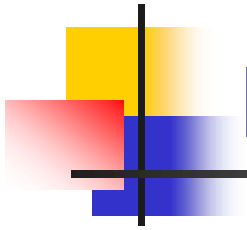
Introdução

- Revisando SGBD
  - Qual o propósito de um SGBD?
    - Independência de dados-programa
    - Persistência de dados
    - Concorrência
    - Recuperação de falhas
    - Processamento de consultas
    - Controle de integridade
    - Controle de Segurança
    - Distribuição dos dados



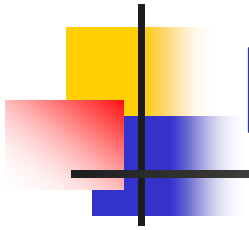
Introdução

- Revisando SGBD
  - Características:
    - Esquema pré-definido
    - Esquema pouco muda uma vez definido
    - Estrutura rígida
    - Níveis de abstração
    - Linguagem de alto nível declarativa para definição e manipulação dos dados (DDL e DML)



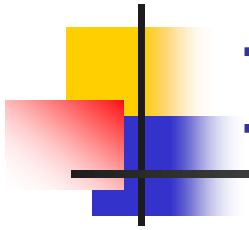
Dado – Informação - Conhecimento

- Dado é o menor e mais simples elemento de um sistema, correspondendo a uma unidade indivisível, objetiva e que tem o papel de registrar um fato.
- Informação é um conjunto de dados de um contexto.
- Conhecimento: é uma informação que devidamente tratada, muda o comportamento de um sistema.



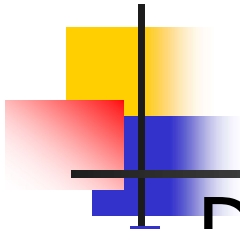
Big Data

- Termo utilizado para nomear um paradigma caracterizado por grandes conjuntos de dados, que aplicativos tradicionais não são capazes de lidar;
- Identificado geralmente por 3V's (Volume, variedade, velocidade);
- Todo processo de manipulação e análise de dados fica mais complexo e caro quando se trata de Big Data.



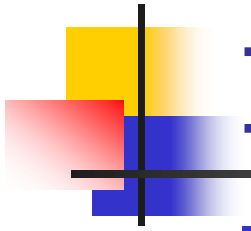
Introdução

- Dados
  - Estruturados
  - Semi-estruturados
  - Não-estruturados



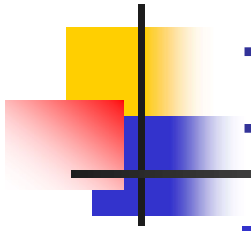
Introdução

- Dados Estruturados
  - São os dados armazenados no SGBD's com esquema rígido, planilhas com clareza estrutural.
  - Ex.: Create table Empregado (matricula int, nome varchar(30), salario float);
  - A estrutura é conhecida a priori, então os comandos de inserção, seleção, atualização e remoção usam esta estrutura para manipular os dados
  - Neste caso a integração com a Web se dá através do uso de um protocolo de conectividade, por exemplo JDBC.



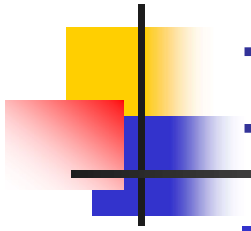
Introdução

- Dados Não-Estruturados
  - São dados que não possuem nenhuma estrutura, tais como um texto, uma imagem, um video. Portanto, do ponto de vista do SGBD estes dados são considerados como uma caixa preta (ou seja, difícil de serem manipulados).
  - (fluxo de bytes).



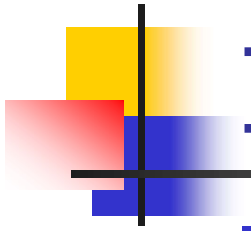
Introdução

- Dados Semi-Estruturados
  - São conhecidos pela ausência de esquema e por serem auto-descritivos.
  - Apresentam uma representação estrutural heterogênea
  - Ex: arquivos tabulares em planilhas (formatos csv, tsv), arquivos em XML.



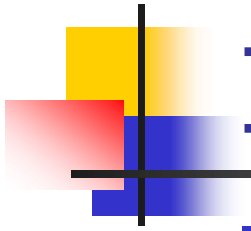
Introdução

- Dados Semi-Estruturados
  - Possuem as seguintes características:
    - Definição à posteriori
    - Estrutura irregular (ex. curriculum vitae)
    - Estrutura implícita
    - Estrutura parcial
    - Estrutura extensa
    - Estrutura evolucionária
    - Distinção entre estrutura e dados não é clara



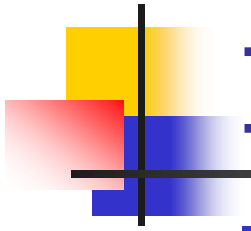
Introdução

- Dados Irregulares
  - Livros podem ser descritos por uma estrutura de partes e capítulos ou podem ser descritos somente por capítulos
  - A descrição de uma disciplina pode variar em termos de atributos de um departamento para outro
    - faltam atributos ou possuem atributos a mais



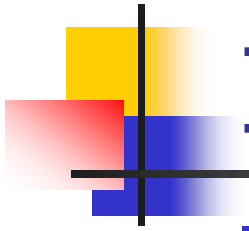
Introdução

- Dados Incompletos
  - Nem todo endereço tem caixa postal
  - Nem todo livro tem apêndice ou prefácio



Introdução

- Dados Incompletos
  - Sua estrutura não é previamente conhecida, pode não existir à parte
  - São auto-descritivos, i.e., embute a própria estrutura



Introdução

- Auto Descrição

  pares atributo-valor

  {name: “John Smith”, tel: 3456, age: 32}

  valor de atributo pode também conter estrutura

  {name: {first:“John”, last: “Smith”}, tel: 3456, age: 32}

  rótulos de atributo não necessariamente únicos

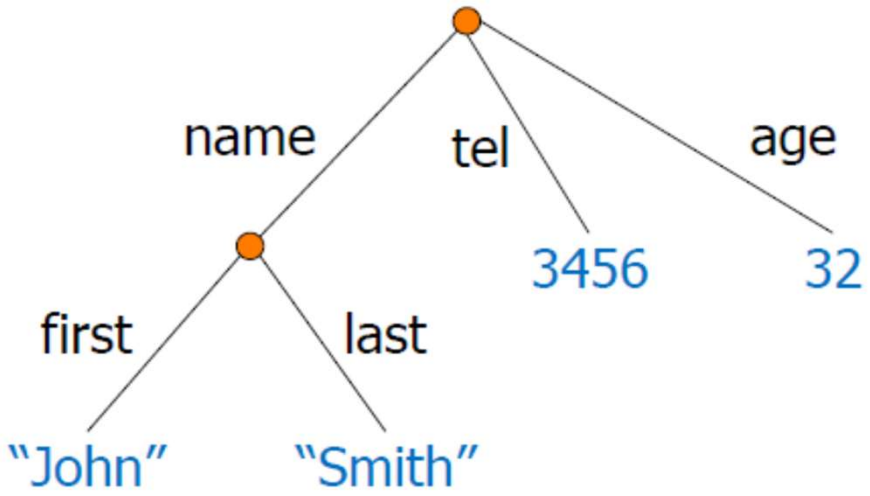
  {name: “John Smith”, tel: 3456, tel: 7891}

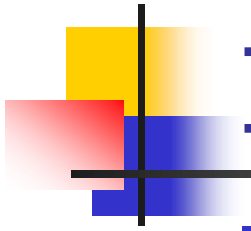
Introdução

- Representação Gráfica

nós representam objetos conectados por arestas que os descrevem

Ex.: {name: {first:"John", last:"Smith"}, tel: 3456, age: 32}

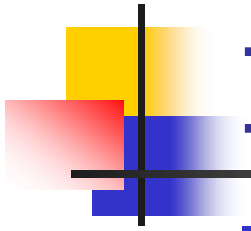




Introdução

- Situações Típicas

- Quando os dados não podem ser restritos a um esquema
  - Difícil definir uma estrutura... Ex: contratos
- Quando não há compromisso com o conteúdo
  - Pode-se ter muitos dados faltando... Ex. Leis
- Quando as fontes de dados são heterogêneas e é preciso integrar dados...
  - Descrições equivalentes mas distintas...



Introdução

- Exemplos
- Arquivos BibTex
- Têm estrutura, mas ela não é regular
- Alguns atributos não aparecem, apesar de obrigatórios

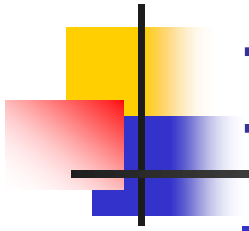
```
@article{Gettys90,
   author = {Jim Gettys and Phil Karlton and Scott McGregor},
   title = {The {X} Window System, Version 11},
   journal = {Software Practice and Experience},
   volume = {20},
   number = {S2},
   year = {1990},
   postscript = "papers/gettys90.ps.gz",
   abstract = {A technical overview of the X11 functionality}
}
```

Introdução

- Exemplos
- Guia de restaurantes

```
Guide
Restaurant
Name "Blues on the Bay"
Category "Vegeterian"
Entree
Name "Black bean soup"
Price "10.00"
Entree
Name "Asparagus Timbale"
Price "22.50"
Location
Street "1890 Wharf Ave"
City "San Francisco"

Restaurant
Name "McDonald's"
Category "Fast Food"
Price "cheap"
Nearby "Blues on the Bay"
```



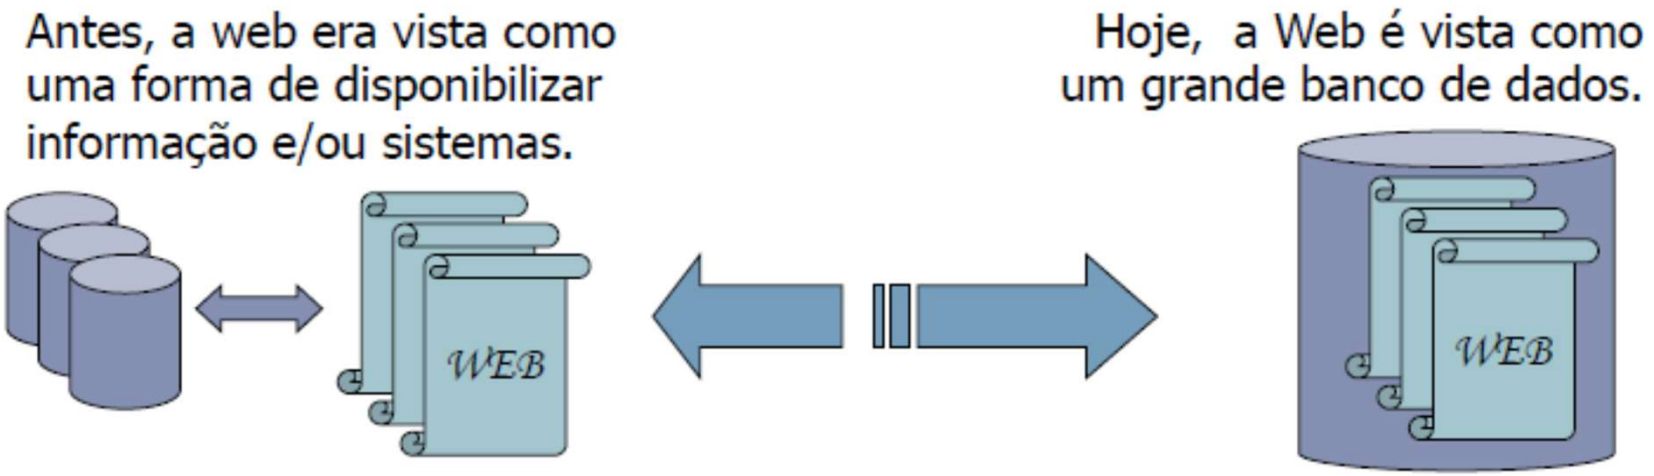
Introdução

- Exemplos
- Arquivos JSON

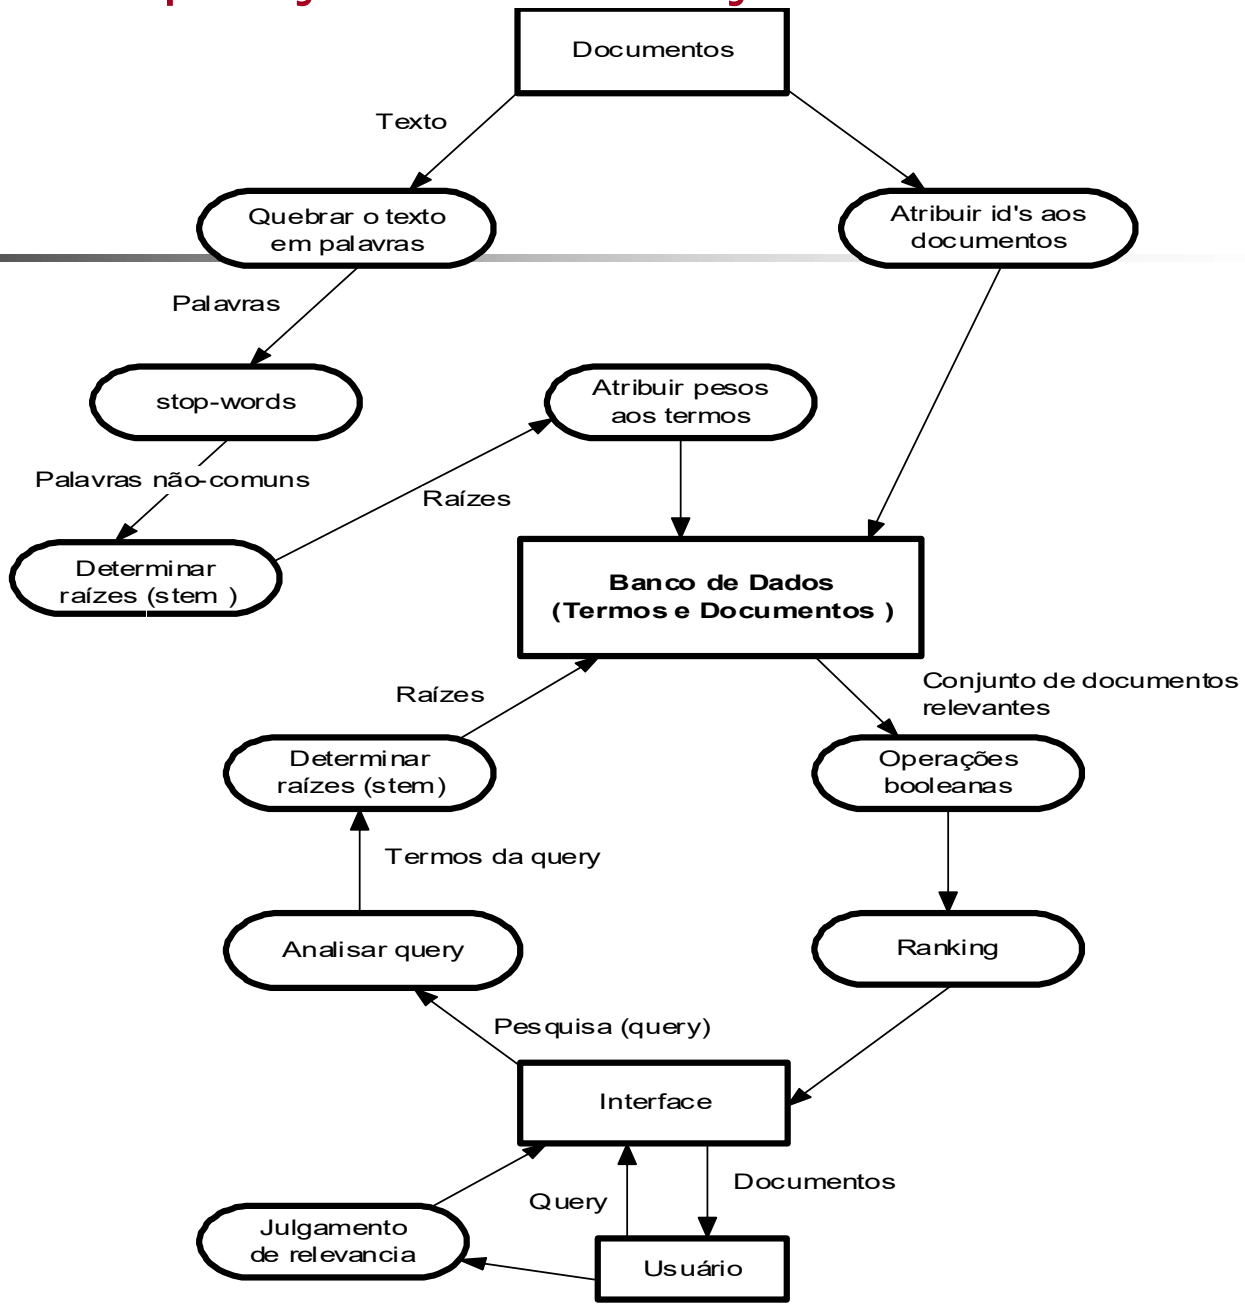
```
{ "Aluno" : [
   { "nome": "João", "nota": [ 8, 9, 7 ] },
   { "nome": "Maria", "nota": [ 8, 10, 7 ] },
   { "nome": "Pedro", "nota": [ 10, 10, 9 ] }
   ]
 }
```

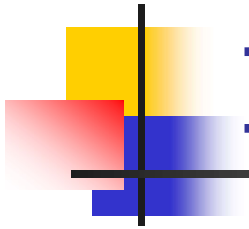
Introdução

- Web e Dados Semi Estruturados



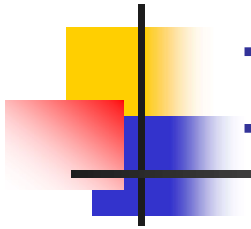
Sistema de Recuperação de Informação





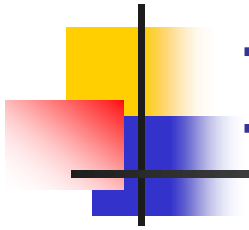
Introdução

- **Parâmetros de qualidade da recuperação:**
  - **Revocação** (Retorno) R: total de itens significantes recuperados.
    - R = (número de itens relevantes recuperados) / (número de itens relevantes no sistema)
  - **Precisão** (Cobertura) P: total de itens significantes entre os recuperados.
    - P = (número de itens relevantes recuperados) / (número de itens recuperados)



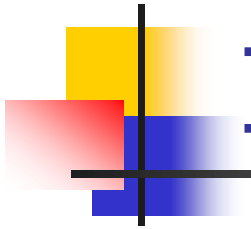
Introdução

	Objetos	*Operações*	*Tamanho BD*
SRI	Documentos	Recuperação probabilística	Pequeno a muito grande
SGBD	Tabela	Recuperação determinística	Pequeno a muito grande



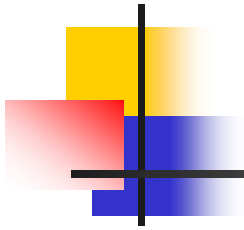
Introdução

- Documentos HTML
- Voltados para consumo humano
- Muitos são gerados automaticamente por aplicações
  - ⇨ Necessidade de um novo paradigma na Web



Introdução

- Existem várias aplicações consumindo documentos HTML
- O padrão XML na Web torna a troca de dados entre aplicações mais simples
  - XML gerado por aplicações
  - XML consumido por aplicações
  - Troca de dados:
    - Entre plataformas
    - Entre empresas



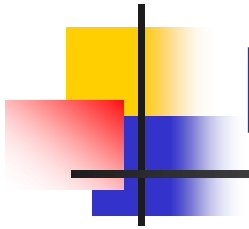
Busca na Web

- Problema:

  Como melhorar os resultados das nossas buscas na Web?

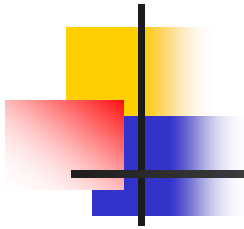
Tecnicamente:

Como maximizar Recall e Precision?



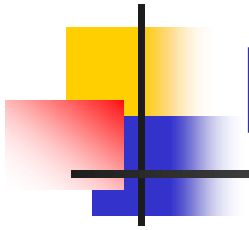
Busca na Web

- Desafios:
  - Escala
  - Diversidade
  - Mudança constante



Dados semi-estruturados ?

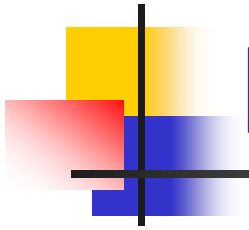
- Dados semi-estruturados: dados heterogêneos e irregulares, auto-descritivos.
- Banco de dados: originalmente, sistemas fechados, dedicados a gestão de dados regulares, cuja estrutura pouco evolui no tempo
- Novas aplicações requerem mais flexibilidade de representação e estão constantemente evoluindo o esquema
- Os modelos relacionais e de objetos chegaram a seus limites (?)



Dados estruturados

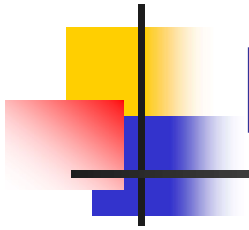
- São dados de um arquivo ou de um banco de dados relacional, em que sua estrutura é conhecida a priori
- Ex.:

```
Create table empregado
( matricula int,
   nome varchar(30),
   salario float,
   depto int
)
```



Dados não-estruturados

- São dados em que não há nenhuma estrutura os definindo.
- São normalmente armazenados em arquivos
- Ex.:
  - um texto em pdf
  - uma imagem em jpg
  - um video ou áudio

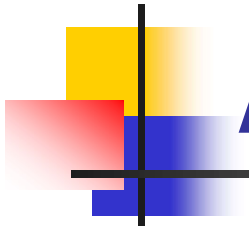


Dados semi-estruturados

- São dados em que uma parte há estrutura e em outra não há nenhuma estrutura definida.
- O esquema da parte estruturada está contido junto com o dado
- Ex.: Um email (parte estruturada:

  <to>, <subject>, <date>, etc.

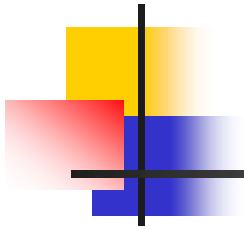
  Parte não estruturada: o corpo da mensagem)



A Web hoje...

- documentos HTML (em sua maioria)
- voltada para uso humano
- gerado automaticamente por aplicações
- fácil de alcançar qualquer Web page, de qualquer server, em qualquer plataforma

O Segredo do sucesso de HTML

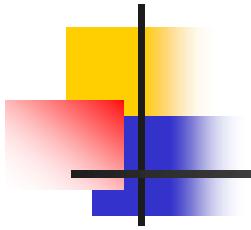


HTML é **simples**: todo mundo pode escrever HTML

HTML é **textual**: é legível, pode-se usar qualquer editor, ...

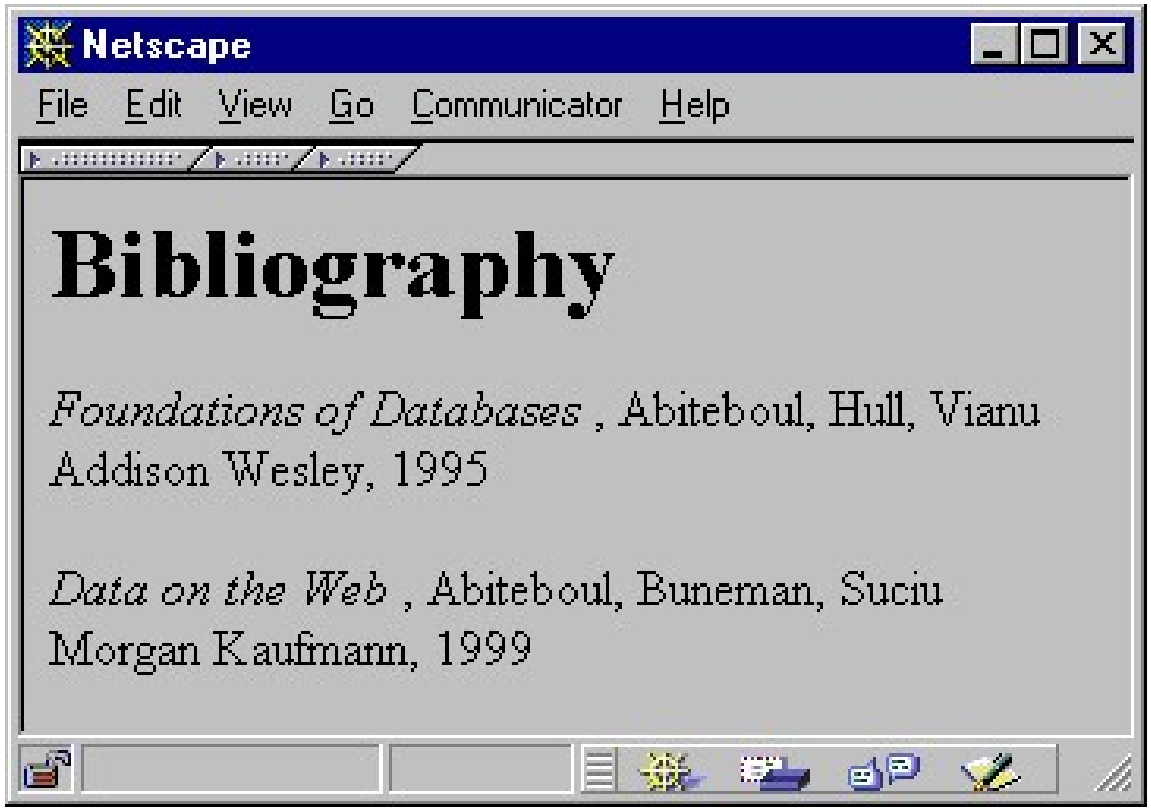
HTML é **transportável** em qualquer plataforma (o browser é a aplicação universal)

HTML conecta pedaços de informação através de **hypertext links**

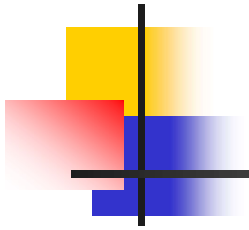


HTML

```
<h1> Bibliography </h1>
<p> <i> Foundations of Databases </i>
      Abiteboul, Hull, Vianu
      <br> Addison Wesley, 1995
<p> <i> Data on the Web </i>
      Abiteoul, Buneman, Suciu
      <br> Morgan Kaufmann, 1999
```

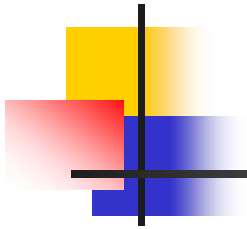


HTML descreve a apresentação



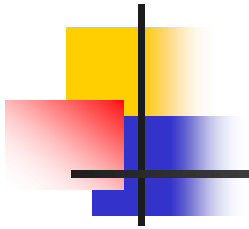
HTML ...

- Um conjunto pré-definido e limitado de tags, definidas por uma
- Estas tags possuem semânticas variadas:
  - `h1`,..,`h6`, `title`, `address`, ... dando as indicações estruturais
  - `center`,`hr`,`b`,`i`,`big`,`small`,... servem para descrever a apresentação.



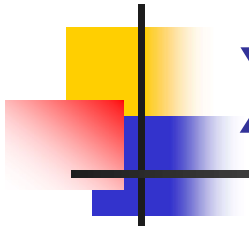
Limites da Web ...

- aplicações não devem consumir HTML
- tecnologia de wrapper HTML é instável (modifica-se a página => modifica-se o wrapper)
- companhias se fundem, formam parcerias; necessitam de interoperabilidade de forma rápida



- As mais recentes aplicações
  - Comércio Eletrônico
  - Bibliotecas digitais
  - sistemas distribuídos
  - ...

  precisaríamos de um "super HTML"



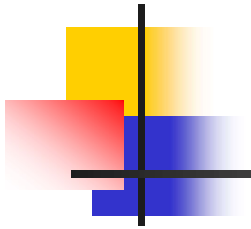
XML ?

- eXtensible Markup Language
- Uma linguagem de descrição de documentos, definida por um organismo internacional W3C
- Um conjunto de tecnologias derivadas
- O esperanto da Web

Web: Mudança de paradigma

...

- Novo padrão Web XML:
  - XML gerado por aplicações
  - XML consumido por aplicações
- troca de dados
  - entre plataformas: interoperabilidade na empresa
  - entre empresas

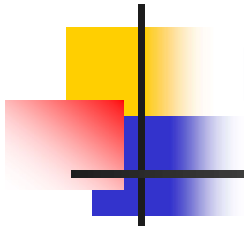


XML

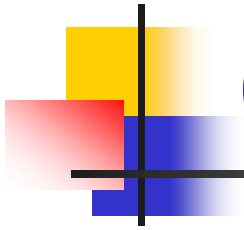
```
<bibliography>
        <book>    <title> Foundations… </title>
                  <author> Abiteboul </author>
                  <author> Hull </author>
                  <author> Vianu </author>
                  <publisher> Addison Wesley </publisher>
                  <year> 1995 </year>
        </book>
        …
</bibliography>
```

XML descreve o conteúdo

XML: uma resposta única a necessidades variadas

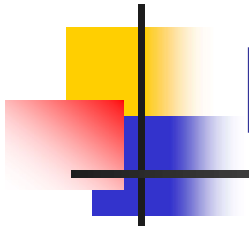


- HTML é usada como a lingagem universal de apresentação de documentos na Web, mas não é uma linguagem adaptada para descrever *a estrutura* destes documentos
- Os sistemas de bases de dados atuais são muito rígidos para manipular dados cuja estrutura é *irregular* e evolui com o tempo.



Os segredos de XML

- Como HTML:
  - simples, legível, fácil de aprender
  - universal e transportável
  - suportado pela W3C (indústria absorve!)
- Mas, Além de HTML
  - flexível : podemos representar qualquer tipo de informação
  - estensível: pode-se representar informação de qualquer forma



Diferenças

- XML não é um substituto para HTML.
- XML e HTML foram projetados com objetivos diferentes:
  - XML foi projetado para transportar e armazenar dados, com foco no que os dados são;
  - HTML foi projetado para exibir dados, com foco em como os dados aparecem;
  - HTML é sobre a exibição de informações, enquanto o XML é sobre carregar informações.

Diferenças

```
<!DOCTYPE HTML PUBLIC "-//W3C//DTD HTML 4.0 Transitional//EN">
<HTML>
  <HEAD><TITLE>A bibliography on Databases</TITLE>
  <META content="text/html; charset=windows-1252" http-
equiv=Content-Type>
  <META content="MSHTML 5.00.2314.1000" name=GENERATOR>
  </HEAD>
  <BODY>
      <h1> Bibliography </h1>
      <p> <i> Foundations of Databases </i> Abiteboul, Hull, Vianu <br>
          Addison Wesley, 1995
      <p> <i> Data on the Web </i> Abiteoul, Buneman, Suciu <br>
          Morgan Kaufmann, 199

  </BODY>
</HTML>
```

HTML: Conjunto pré-definido de elementos (tags) para especificação das dimensões de estrutura e apresentação de um documento



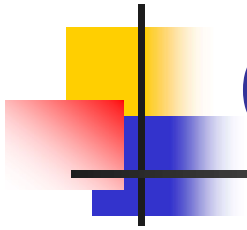
Diferenças

XML: Elementos (tags) definidos pelo usuário da linguagem e servindo para descrever o conteúdo e a estrutura.

Fonte XML

```
<bibliography>
    <book>   <title> Foundations... </title>
             <author> Abiteboul </author>
             <author> Hull </author>
             <author> Vianu </author>
             <publisher> Addison Wesley </
  publisher>
             <year> 1995 </year>
    </book>
    ...
</bibliography>
```

XML descreve o **conteúdo**!!!

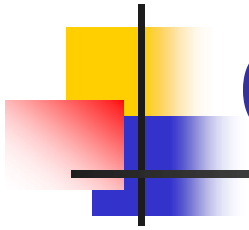


Origem de XML

- 1993: primeiros trabalhos sobre adaptação das técnicas SGML à Web (Sperberg).

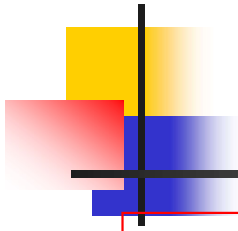
"HTML to the Max: A Manifesto for Adding SGML Intelligence to the World Wide Web"

- Junho 1996: criação de um grupo de trabalho no W3C
- 10 fev. 1998: publicação da recomendação para versão 1.0 da linguagem. http://www.w3.org/TR/REC-xml (2/98)



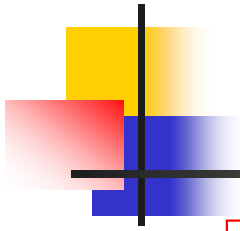
Origem de XML

- Trabalho cooperativo de um grande número de empresas e de pesquisadores reunidos no World Wide Web Consortium (W3C)
  - 400 colaboradores da indústria, entre os quais Oracle, IBM, Compaq, Xerox, Microsoft, etc..
  - Laboratórios de pesquisa: MIT - USA, INRIA - França, universidade de Keio - Japão
- Objetivo: definição de um formalismo para facilitar a troca de dados na Web



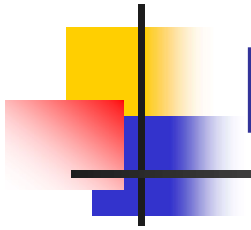
Mandamentos iniciais:

- XML deverá ser diretamente utilizável na Internet
- XML deverá suportar uma larga variedade de aplicações
- XML deverá ser compatível com SGML
- A criação de páginas XML deverá ser também o mais simples possível



Mandamentos iniciais(2)

- Os documentos XML deverão ser de grande legibilidade
- A criação de documentos deverá ser rápida
- A sintaxe deverá ser formal e concisa
- A concisão do código tem mínima importância



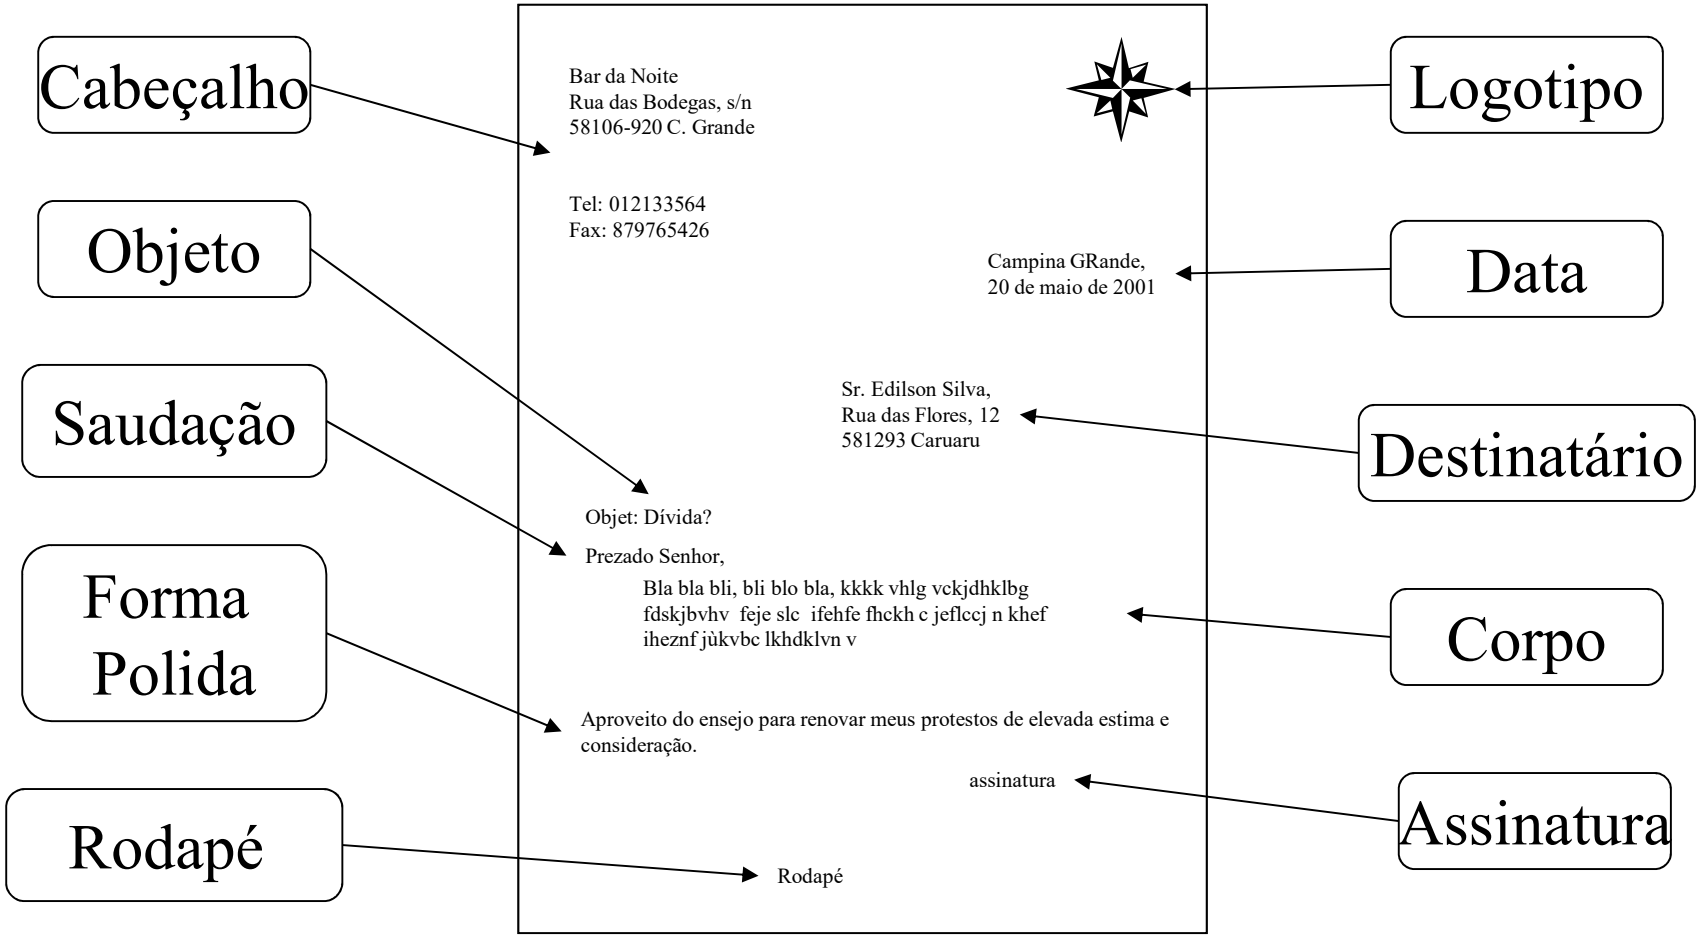
Resumindo: XML ...

XML é uma linguagem de

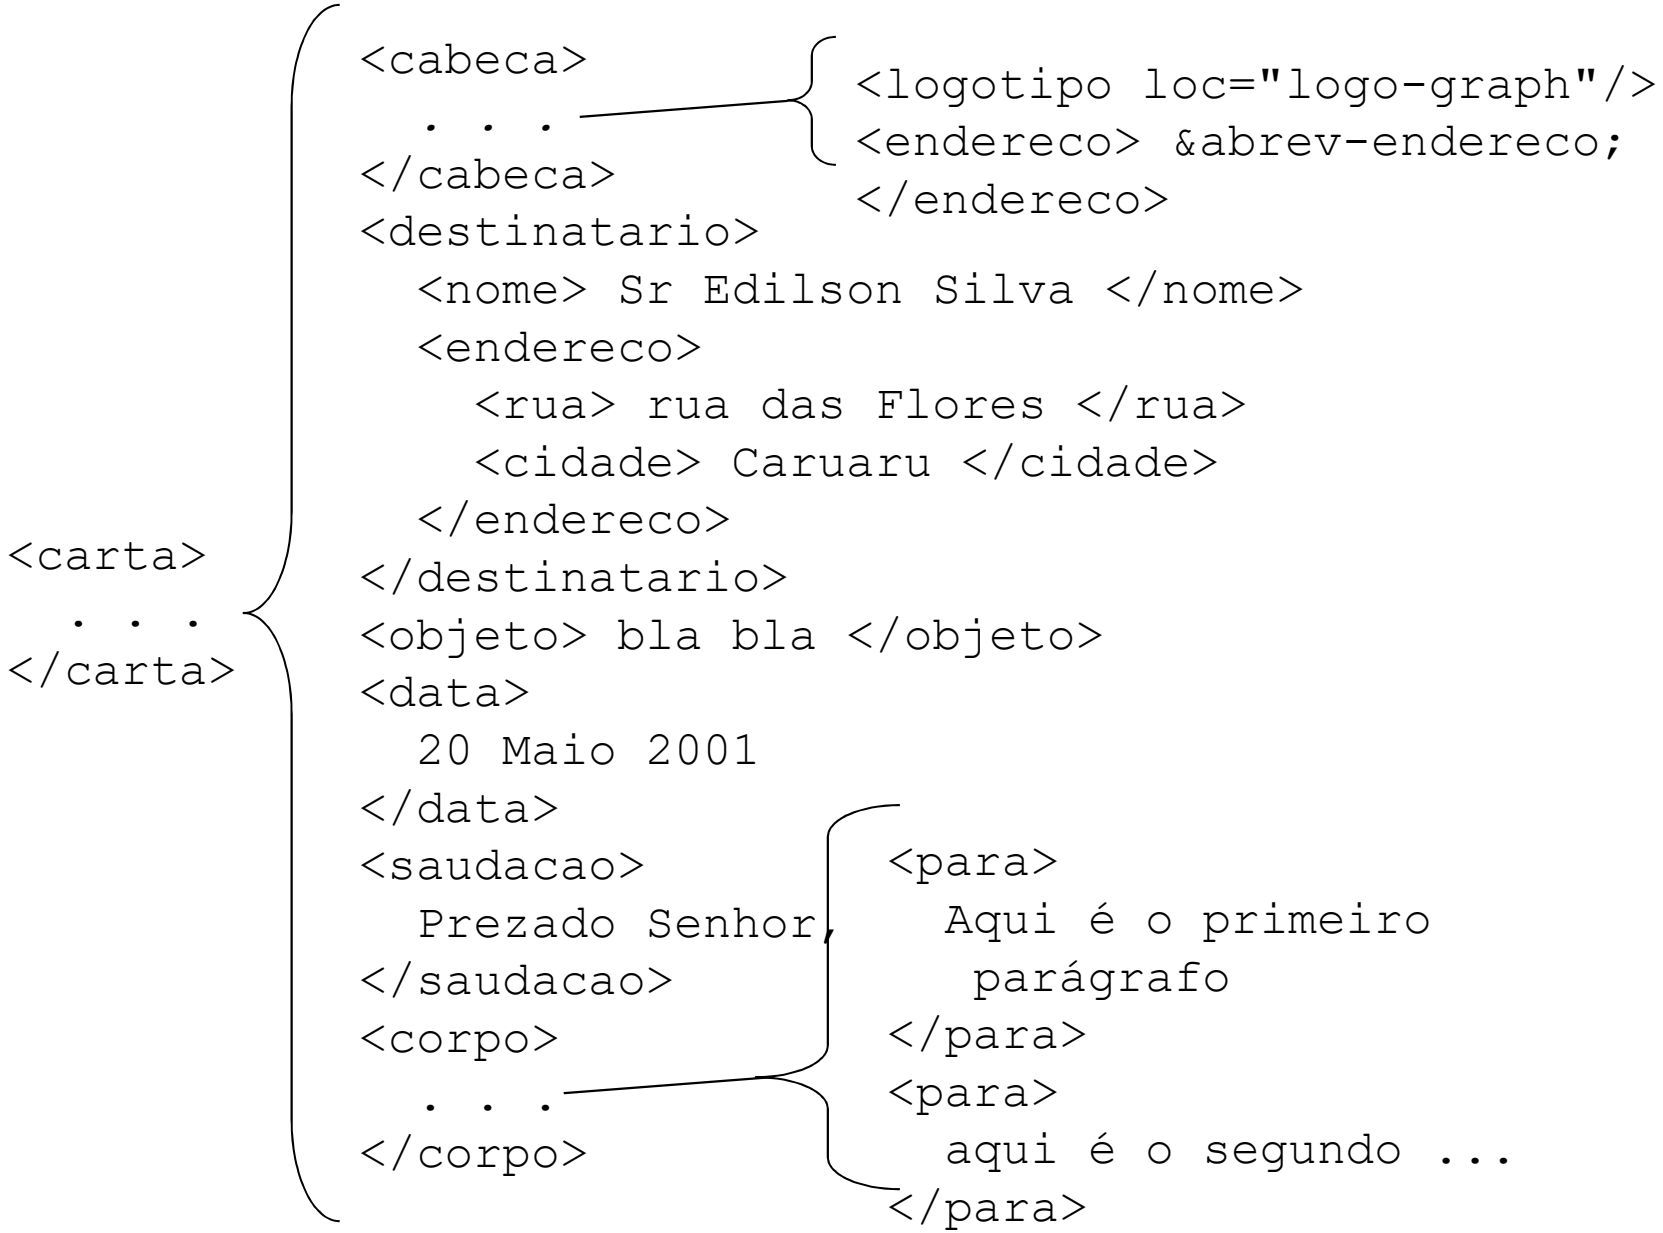
descrição e de troca de

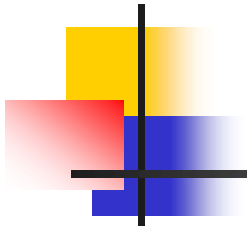
documentos (semi-)estruturados

Exemplo de um documento



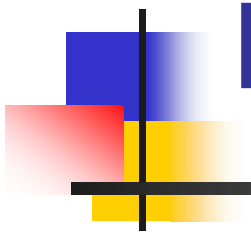
Representação XML





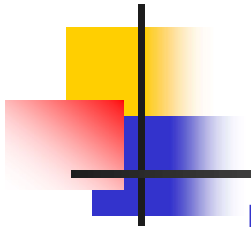
Pontos importantes

- A representação desta carta em XML não tem nenhuma indicação sobre a apresentação.
- As numerosas propriedades gráficas ou tipográficas estão ausentes da fonte XML.
- Estas propriedades serão definidas por intermédio de uma *folha de estilo*.
- Uma folha de estilo é um *conjunto de regras* para especificar a *realização concreta* de um documento sobre uma *mídia* particular.



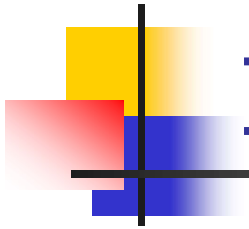
Descoberta de XML

Vantagens de XML



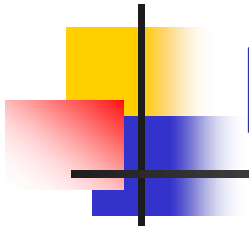
Estensibilidade e estrutura

- Em XML, um autor ou uma comunidade de autores inventam livremente as tags que lhes pareçam úteis para marcar os componentes de um documento.
- Exemplo: diversas formas de representar uma data
  - `<date> 5 janeiro 2000 </date>`
  - ```
    <date>
      <ano> 2000 </ano>
      <mes> 01 </mes>
      <dia> 05 </dia>
    </date>
    ```
  - `<date format='ISO-8601'> 2000-01-05 </date>`
- Grande liberdade de escolha das estruturas de dados facilita ***a troca de dados***
  - comércio eletrônico, transações financeiras e comerciais,
  - pesquisa e indústria de biotecnologias
  - multimídia
    ```



Interoperabilidade

- Todos os dados podem ser vistos como documentos XML e não mais como arquivos no formato X ou Y.
- Consequências:
  - Um servidor de documentos XML pode responder a um conjunto de necessidades de uma organização.
  - Um simples editor de textos pode tratar o conjunto de dados de uma organização.
  - A interoperabilidade dos utilitários está assegurada.



Modularidade e reutilização

- Cada usuário é livre para definir suas próprias estruturas de documento
- Um documento pode também estar conforme as estruturas tipadas, chamadas DTD
- Cada comunidade pode propor as estruturas normalizadas
- A validação a um DTD permite a automatização no tratamento dos dados e assegura uma possibilidade de controle de integridade

Entidades externas endereçadas por URL

- Exemplo

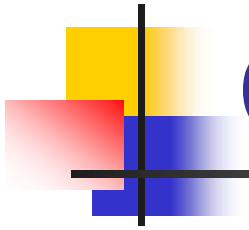
```
<?xml version='1.0' ?>
<!DOCTYPE livro [
  <!ENTITY capitulo1 SYSTEM "chap1.xml">
  <!ENTITY capitulo2 SYSTEM "chap2.xml">
  <!ENTITY autor "Maria Luiza Baptista">
]>
<livro>
  <titulo> XML para iniciantes </titulo>
  <autor> &autor; </autor>
  <intro> Era uma vez uma Web… </intro>
  &capitulo1;
  &capitulo2;
</livro>
```

- Restrição: as entidades externas devem ser documentos bem formados

XML 1.0: Exemplos

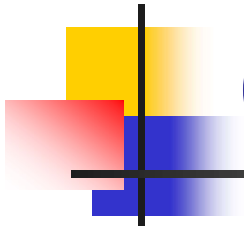
- Exemplo

```
<?xml version='1.0' ?>
<!DOCTYPE db [
  <!ELEMENT db (pessoa*)>
  <!ELEMENT pessoa (nome, idade, email)>
  <!ELEMENT nome (#PCDATA)>
  <!ELEMENT idade (#PCDATA)>
  <!ELEMENT email (#PCDATA)>
]>
<db>
  <pessoa> <nome> Pedro Maia </nome>
           <idade> 33 </idade>
           <email> maia@yahoo.com </email>
  </pessoa>
  <pessoa> <nome> Ana Maria </nome>
           <idade> 24 </idade>
           <email> ana.maria@uol.com.br </email>
  </pessoa>
  <pessoa> . . .  </pessoa>
</db>
```



CSV

- CSV é um formato de arquivo que significa “comma-separated-values” (valores separados por vírgulas).
- Isso significa que os campos de dados indicados neste formato normalmente são separados ou delimitados por uma vírgula.

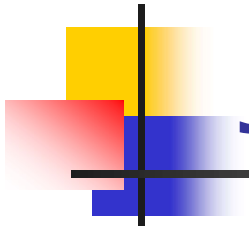


CSV

- Supondo a planilha a seguir:

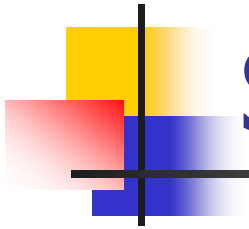
João	2018	Belo Horizonte
Maria	2019	Rio de Janeiro

- Os dados poderiam ser lidos num arquivo CSV no seguinte formato:
- João,2018,Belo Horizonte
- Maria,2019,Rio de Janeiro



Json

- O JSON é um formato que armazena informações estruturadas e é principalmente usado para transferir dados entre um servidor e um cliente.
- O arquivo é basicamente uma alternativa simples e mais leve ao **XML** (*Extensive Markup Language*), que tem funções similares.
- Desenvolvedores usam o JSON para trabalhar com **AJAX** (*Asynchronous JavaScript and XML*). Esses formatos trabalham juntos para conseguir um carregamento assíncrono de dados armazenados.
- Isso significa que um site pode atualizar suas informações sem precisar recarregar a página que você está visitando.



Sintaxe do JSON

- Para criar corretamente o formato json. Você tem que seguir exatamente a sua sintaxe.
- Existem dois elementos centrais em um objeto JSON: Keys (chaves) e Values (valores).
- Keys devem ser strings (linhas). Elas contêm uma sequência de caracteres cercadas por aspas.
- Values são um tipo válido de dados JSON. Eles podem ter um formato de array, object, string, boolean, number ou null.
- Um objeto JSON inicia e termina com chaves {}. Ele tem dentro dois ou mais pares de key/value, com uma vírgula para separá-los. Cada chave é seguida por dois pontos para diferenciar o valor.
- Exemplo:
- {"city":"New York", "country":"United States "}
- Temos dois pares de key/values aqui: city e country são as keys; New York e United States são os values.

Tipos de valores (Json)

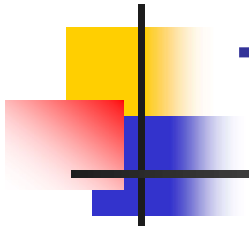
- **Array**
- Um array é uma coleção ordenada de valores. É cercado por **colchetes []** e cada valor dentro é separado por uma vírgula.

```
"students":[
{"firstName":"Tom", "lastName":"Jackson"},
{"firstName":"Linda", "lastName":"Garner"},
{"firstName":"Adam", "lastName":"Cooper"}
]
```

Tipos de valores (Json)

- **Object**
- Um objeto contém uma key e value. Tem dois pontos depois de cada key e uma vírgula depois de cada value, que também diferencia cada objeto. Ambos estão dentro de aspas.

```
“employees”: {"firstName":"Tom", "lastName":"Jackson”}
```



Tipos de valores (Json)

- **Strings**

  Uma string é uma sequência definida de zero ou mais caracteres Unicode. É colocado entre duas aspas duplas.

  "firstName":"Tom"

- **Number**

  Number em JSON deveria ser do tipo **inteiro** ou um tipo **fracionado**, como:

  {"age":"30"}

- **Boolean**

  Você pode usar as opções **true** (verdadeiro) ou **false** (falso) como valor, seguindo:

  {"married":"**false**")

- **Null**

  Esse formato mostra que não há informação.

  {"bloodType":"**null**"}