Ciência dos dados

Higor Alexandre Duarte Mascarenhas

Pergunta

- Alguém já usou alguma ferramenta para comparar preços de passagens aéreas ou produtos online? Ou já se perguntou como o Google consegue indexar trilhões de páginas da web em segundos?

Web Scraping

- "É a técnica de extrair dados de sites de forma automatizada. Em vez de copiar e colar informações manualmente, você usa um programa (um 'robô' ou 'bot') para fazer isso por você, em escala."

Exemplos práticos no dia a dia

- **Análise de mercado:** Coletar preços de concorrentes.
- **Jornalismo de dados:** Extrair informações de portais do governo para investigações.
- **Monitoramento de redes sociais:** Coletar dados públicos para análise de sentimento.

No Brasil...

- A prática do web scraping, embora poderosa, levanta questões legais importantes. É aqui que a **Lei Geral de Proteção de Dados (LGPD)** entra em cena.
- **Entendendo a LGPD**
- A **Lei nº 13.709/2018 (LGPD)** é a principal legislação brasileira que regula o tratamento de dados pessoais. Seu objetivo é proteger os direitos fundamentais de liberdade e de privacidade, garantindo que o tratamento de dados pessoais seja feito de forma segura e transparente.

Conceito Chave

- **Dado Pessoal:** Qualquer informação que identifique ou possa identificar uma pessoa natural. **Exemplos:** nome, CPF, e-mail, endereço IP, geolocalização.
- **Dado Pessoal Sensível:** Informações sobre origem racial, convicção religiosa, opinião política, saúde, vida sexual ou dados genéticos/biométricos. O tratamento desses dados exige cuidados ainda maiores.

Princípios Fundamentais:

- **Finalidade:** A coleta de dados deve ter um propósito legítimo, específico e claro.
- **Necessidade:** A coleta deve se limitar aos dados estritamente necessários para a finalidade informada.
- **Transparência:** O titular dos dados tem o direito de saber o que, como e por que seus dados estão sendo coletados.
- A pergunta central é: a LGPD se aplica ao web scraping? A resposta é sim, sempre que a prática envolver a coleta de **dados pessoais**.

A Legalidade do Web Scraping na Prática

- A legalidade do web scraping depende da **finalidade** da coleta e do **tipo de dado** extraído. A **LGPD** estabelece dez bases legais que podem justificar o tratamento de dados pessoais, sendo as mais relevantes para o web scraping:
- **Consentimento:** O titular dos dados autoriza de forma livre, informada e inequívoca a coleta. É a base mais segura, mas raramente aplicável a um grande volume de scraping.
- **Legítimo Interesse:** O controlador tem um interesse legítimo para a coleta que não sobrepõe os direitos e liberdades do titular dos dados.
- **Dados Manifestamente Públicos:** Permite o tratamento de dados que o titular tornou publicamente disponíveis. Contudo, essa base é complexa, pois a LGPD exige que a finalidade da coleta seja compatível com a finalidade original da disponibilização. Isso significa que você não pode simplesmente coletar e usar dados públicos de perfis em redes sociais para fins de marketing sem uma justificativa legal clara.

Análise de Casos

- **Caso 1: Scraping de Preços em E-commerce**
  - **Cenário:** Uma empresa de análise de mercado coleta preços de produtos, descrições e imagens de sites de varejo.
  - **Análise de Legalidade:** Geralmente legal. Os dados de produtos não são considerados dados pessoais, portanto, a LGPD não se aplica. O principal risco aqui é a violação dos **termos de serviço** do site.

Análise de Casos

- **Caso 2: Scraping de Perfis em Redes Sociais**
  - **Cenário:** Uma empresa coleta nomes, cargos e e-mails de profissionais em redes sociais para criar uma lista de prospecção.
  - **Análise de Legalidade:** Altamente questionável. Mesmo que os dados estejam "públicos", eles são **dados pessoais**. A finalidade da coleta (marketing) é diferente da finalidade original dos dados (networking), o que dificulta o enquadramento na base legal de "dados manifestamente públicos". Essa prática é arriscada e pode violar a LGPD.

Riscos do Scraping Ilegal

- As consequências de um web scraping ilegal, que viole a LGPD ou os termos de uso de um site, são sérias:
- **Multas da LGPD:** Podem chegar a **R$ 50 milhões por infração** ou 2% do faturamento da empresa.
- **Bloqueio/Eliminação dos Dados:** A Autoridade Nacional de Proteção de Dados (ANPD) pode exigir a eliminação dos dados coletados ilegalmente.
- **Processos Judiciais:** Por violação de direitos autorais ou termos de serviço.
- **Danos à Reputação:** A publicização da infração pode causar danos irreparáveis à imagem da empresa.

Melhores Práticas para o Web Scraping Ético

- Para mitigar os riscos e garantir a legalidade, siga estas recomendações:
- **Respeite o robots.txt:** Este arquivo, presente na maioria dos sites, informa aos "robôs" quais páginas eles podem ou não acessar. Sempre verifique e respeite suas diretivas.
- **Identifique-se:** Use um User-Agent descritivo para que o site saiba quem está acessando seu conteúdo.
- **Não Sobrecarregue o Servidor:** Faça requisições em intervalos razoáveis para não causar lentidão ou queda no site-alvo. Use time.sleep() em seu código.
- **Seja Transparente:** Se você coleta dados pessoais, tenha uma política de privacidade clara, explicando a finalidade e o tratamento desses dados.

Questões de legalidade e ética na prática de web scraping

Introdução

- Em 2010, o engenheiro de software Pete Warden desenvolveu um **web crawler para capturar dados do Facebook**.
- Ele compilou informações de cerca de **200 milhões de usuários da plataforma**, incluindo nomes, informações de localização, conexões de amizades e interesses.
- O **Facebook percebendo a informação, enviou ao engenheiro notificações de cessação e desistência**, às quais ele acatou.
- Questionado, Pete Warden respondeu: "Big Data? Barato. Advogados? Não tão barato assim."
- **OBS: Tais conceitos abordados nesta aula referem-se mais a Leis dos Estados Unidos.**

Introdução

- Existem três tipos básicos de propriedade intelectual:
- Marcas registradas
- Direitos autorais
- Patentes

Introdução (pantentes)

- **Patentes**: são utilizadas para declarar a propriedade sobre as invenções apenas. **Não é possível patentear imagens, texto ou qualquer tipo de informação em si**.
- Sendo importante lembrar que o que é patenteado é a coisa (ou técnica) em si. Como por exemplo um software e não os dados que o compõem.
- Principalmente em si tratando em técnicas de web scraping, é pouco provável que você infrinja uma patente.

Introdução (marca registrada)

- É improvável que marcas registradas sejam um problema.
- De acordo com o Departamento de Patentes e Marcas Registradas dos Estados Unidos: "uma marca registrada é uma palavra, frase, símbolo e/ou design que identifica e distingui a origem dos bens de uma empresa de outras."

Lei de Direitos Autorais

- Tanto **marcas registradas quanto patentes** têm algo em comum: para **serem reconhecidas, precisam ser formalmente registradas**.
- Ao contrário do que pensamos, não é o aviso descrito em músicas, imagens, ou textos descrito “todos os direitos reservados” .
- Ao criar cada obra é sujeita à Lei de Direitos Autorais.
- Logo, é evidente que a prática de web scraper é uma preocupação bastante discutida em direitos autorais.
  - Ex: Extrair informações do Blog de alguém e publicar no meu blog estou sujeito a processos judiciais.

Lei de Direitos Autorais

- **Maaas**, tenho camadas de proteção que podem tornar o projeto de scraping de blogs defensável.
- Proteção de direitos autorais se estende a obras criativas, ou seja, não abrange estatísticas ou fatos.
- O que procuramos se trata de estatísticas e fatos.

Lei de Direitos Autorais (exemplo)

- **Um web scraper que extrai poesia da internet e exibe essa poesia em seu site pode estar violando a Lei dos Direitos Autorais**.
- Porém, a coleta de informações sobre a **frequência de postagens de poesia ao longo do tempo não está**.
- A **média de palavras publicadas em poemas** em um site por mês constitui um dado factual, não uma obra criativa.

Lei de Direitos Autorais

- Dois pontos principais do web scraping:
- De acordo com porto seguro(Safe Harbor)se você coleta dados de uma fonte que acredita conter apenas material livre de direito autorais, mas que, na verdade, conta com material protegido por direitos autorais enviado por algum usuário, você estará protegido, desde que remova o material protegido por direitos autorais quando notificado.
- No entanto, é importante ressaltar que não é permitido contornar medidas de segurança (como proteção por senha) para coletar conteúdo.
- É importante nunca publicar diretamente material protegido por direitos autorais sem permissão do autor original ou detentor dos direitos autorais.

Direitos autorais e IA

- A **inteligência artificial generativa**, ou programas de IA que **produzem novas obras "criativas" com base em um conjunto de obras criativas** existentes, apresentam desafios únicos para a Lei de Direitos Autorais.
- Se o resultado do programa de IA generativa se assemelha a uma obra existente, pode haver uma questão de direitos autorais envolvida. Muitos casos têm sido utilizados como precedente para determinar o significado de "se assemelha" nesse contexto. Verificar se assemelha é uma tarefa desafiadora.
- Muitas das vezes não se sabe nem a origem destes dados, para verificar a semelhança.

Lei de Invasão de Bens Móveis

- A Lei de Invasão de Bens Móveis difere substancialmente do conceito de "leis de invasão", **pois se refere não a imóveis ou terrenos, mas sim a propriedades móveis, ou bens móveis em termos jurídicos**. Ela ocorre quando sua propriedade sofre interferência de alguma forma, impedindo seu acesso ou uso.
- Na era da computação em nuvem, é tentador não pensar nos servidores web como recursos reais e tangíveis. Eles não só consistem em componentes caros, mas também exigem armazenamento, monitoramento constante, refrigeração, limpeza e uma fonte contínua de energia elétrica.
- **Estudos apontam que cerca de 10% do consumo global de eletricidade é consumido por computadores**. Caso uma pesquisa com seus próprios dispositivos eletrônicos não seja suficiente, basta considerar as imensas fazendas de servidores do Google, todas elas conectadas a grandes usinas elétricas.

Lei de Invasão de Bens Móveis

- Três critérios precisam ser atendidos para que um web scraper viole a Lei de Invasão de Bens Móveis:
- **Falta de consentimento**: Dado que os servidores da web estão acessíveis a todos, eles em geral também "dão permissão" aos web scrapers. No entanto, muitos termos de serviço de sites proíbem expressamente o uso de scrapers. Além disso, qualquer notificação de cessar e desistir enviada a você pode revogar esse consentimento.
- **Danos reais**: Servidores são recursos dispendiosos. Além dos custos do próprio servidor, se os seus scrapers derrubarem um site ou restringirem sua capacidade de atender a outros usuários, isso pode aumentar o "dano" causado.
- **Intencionalidade**: Se você está escrevendo o código, você sabe o que ele faz. Alegar ausência de intenção provavelmente não seria eficaz ao defender seu web scraper.

Limitando a velocidade dos seus bots

- Um bot monitorado nunca conclui sua tarefa. Às vezes, é mais vantajoso deixar as **crawlers operando durante a noite do que durante o dia**, por algumas razões:
- Em aproximadamente 8 horas, mesmo a uma velocidade lenta de 2 segundos por página, é possível rastrear mais de 14.000 páginas. Quando o tempo é um fator menos crítico, você não se sente tentado a aumentar a velocidade dos seus crawlers.
- Se o público-alvo do site estiver na sua localização geral (ajuste conforme necessário para públicos-alvo remotos), é provável que o tráfego do site seja muito menor durante a noite, o que significa que seu rastreamento não irá agravar o congestionamento do horário de pico.
- Você economiza tempo dormindo, em vez de ficar constantemente verificando seus registros em busca de novas informações. Imagine a empolgação que sentirá ao acordar pela manhã e se deparar com dados novinhos em folha!

Limitando a velocidade dos seus bots

- Considere os seguintes cenários:
- Você tem um web crawler que percorre o site de Joe Schmo, coletando parte ou todos seus dados.
  - é mais vantajoso deixar o bot operando lentamente durante a noite.
- Você tem um web crawler que percorre centenas de sites pequenos, coletando parte ou todos seus dados.
- é mais vantajoso rastrear cada site em um esquema round-robins, em vez de rastreá-los lentamente, um de cada vez. Dependendo do número de sites que você está rastreando, é possível coletar os dados de acordo com a velocidade da conexão da sua internet e a capacidade do seu hardware, mantendo uma carga razoável para cada servidor remoto individual. Essa tarefa pode ser automatizada por meio da programação, seja utilizando múltiplas threads (em que cada thread individual rastreia um único site e pausa sua própria execução), ou utilizando listas em Python para manter o controle dos sites.

Limitando a velocidade dos seus bots

- Você tem um web crawler que percorre um site muito grande, como a Wikipédia.
- é improvável que a carga que sua conexão com a internet e sua máquina doméstica impõem a sites como a Wikipedia seja notada ou tenha grande impacto. No entanto, se você estiver utilizando uma rede distribuída de máquinas, a coisa muda de figura. É prudente agir com cautela e, sempre que possível, busque orientação junto a um representante da empresa.

A Lei de Fraude e Abuso de Computadores

- No início dos anos 1980, os computadores começaram a sair das universidades e entrar no mundo dos negócios. Pela primeira vez, vírus e worms passaram a ser vistos como mais do que apenas um incômodo (ou mesmo um passatempo divertido), tornando-se uma questão criminal séria que poderia causar danos financeiros.
- Em 1983, o filme War Games, estrelado por Matthew Broderick, também trouxe essa questão à tona para o público e para os olhos do presidente Ronald Reagan.
- Em resposta, em 1986, foi criada a Lei de Fraude e Abuso de Computadores (CFAA).

A Lei de Fraude e Abuso de Computadores

- Embora você possa pensar que a CFAA se aplica apenas àquela imagem estereotipada de um hacker malicioso lançando vírus, a lei também tem fortes implicações para web scrapers.
- Vamos imaginar um scraper que percorre a web em busca de formulários de **login com senhas fáceis de adivinhar**, ou que coleta informações confidenciais do governo deixadas acidentalmente em um local oculto, mas público. Todas essas atividades são ilegais (e com razão) de acordo com a CFAA.

A Lei de Fraude e Abuso de Computadores

- A lei define sete principais delitos criminais, que podem ser resumidos da seguinte forma:
- O acesso consciente não autorizado a computadores pertencentes ao governo dos EUA e a obtenção de informações desses sistemas.
- O acesso consciente não autorizado a um computador, com a finalidade de obter informações financeiras.
- O acesso consciente não autorizado a um computador pertencente ao governo dos EUA, que cause impacto no uso desse computador pelo governo.
- O acesso consciente a qualquer computador protegido com a intenção de cometer fraude.
- O acesso consciente a um computador sem autorização e que cause danos a esse computador.
- Compartilhar ou negociar senhas ou informações de autorização para computadores utilizados pelo governo dos EUA ou computadores que afetam o comércio interestadual ou internacional.
- Tentativas de extorquir dinheiro ou "qualquer coisa de valor" que causem danos ou ameacem causar danos a qualquer computador protegido.

Questões mais legais???

Arquivos robots.txt e termos de serviço

- Os termos de serviço de um site e os arquivos robots.txt se encontram em uma área interessante, do ponto de vista legal. Quando um site é acessível publicamente, surge a questão do direito do administrador do site de determinar quais softwares podem ou não acessá-lo.
- Dizer que "você pode utilizar seu navegador para visualizar este site, mas não pode utilizar um programa que você desenvolveu para visualizá-lo" é uma questão complicada.
- Na maioria dos sites, é possível encontrar um link para seus termos de serviço (Terms of Service, ou TOS) no rodapé de cada página. Além das regras para web crawlers e acesso automatizado, os TOS geralmente incluem informações sobre os tipos de dados que o site coleta, como eles são utilizados e uma declaração legal de que os serviços fornecidos pelo site não têm garantia expressa ou implícita.
- Se você está interessado em otimização de mecanismos de busca (Search Engine Optimization, ou SEO) ou tecnologia de mecanismos de busca, provavelmente já ouviu falar do arquivo robots.txt. Ao acessar praticamente qualquer site de grande porte e procurar pelo arquivo robots.txt, você o encontrará na pasta raiz do site: http://website.com/robots.txt.

Arquivos robots.txt e termos de serviço

- A sintaxe dos arquivos robots.txt foi desenvolvida em 1994 durante o boom inicial da tecnologia de mecanismos de busca na web. Foi nessa época que os mecanismos de busca que percorriam toda a internet, como AltaVista e DogPile, começaram a competir seriamente com listas simples de sites organizados por assunto, como aquelas mantidas pelo Yahoo! Esse crescimento da busca pela internet trouxe não apenas uma expansão no número de web crawlers, mas também na disponibilidade das informações coletadas por esses rastreadores para o público em geral.
- Embora hoje possamos considerar esse tipo de disponibilidade como padrão, na época alguns administradores de site ficaram chocados quando informações que publicaram nas áreas mais profundas da estrutura de arquivos de seus sites ficaram disponíveis na página principal dos resultados de busca em grandes mecanismos de busca. Em resposta, foi desenvolvida a sintaxe para arquivos robots.txt, chamada de **Protocolo de Exclusão de Robôs**.

Arquivos robots.txt e termos de serviço

- Não há meios legais ou técnicos para fazer cumprir um arquivo robots.txt. Ele é basicamente um aviso que diz "Por favor evite essas áreas do site".
- A sintaxe do Protocolo de Exclusão de Robôs é bastante simples. Assim como em Python (e muitas outras linguagens), os comentários começam com o símbolo **#**, terminam com uma nova linha e podem ser inseridos em qualquer parte do arquivo.
- A primeira linha do arquivo, sem considerar qualquer comentário, é iniciada com **User-agent**:, **que especifica o usuário ao qual as seguintes regras se aplicam**. Ela é seguida por um conjunto de regras, seja **Allow:** ou **Disallow:**, **dependendo de se o bot tem permissão nessa seção do site**. Um asterisco (*) **indica um caractere curinga e pode ser utilizado para descrever tanto um User-agent quanto uma URL**.

Arquivos robots.txt e termos de serviço

- Se uma regra sucede outra que parece contradizê-la, a última regra prevalece. Por exemplo:

```
#Ben-vindo ao meu arquivo robots.txt!

User-agent: *

Disallow:


User-agent: Googlebot

Allow: *

Disallow: /private
```

- Logo, todos os bots estão proibidos de acessar qualquer parte do site, exceto o Googlebot, que tem permissão para acessar qualquer lugar, com exceção do diretório / private.

Três casos envolvendo web scrapers

- eBay versus Bidder's Edge e a lei de Invasão de Bens Moveis
- Estados Unidos versus Auernheimer e a Lei de Fraude e Abuso de Computadores
- Field versus Google: direitos autorais e robots.txt

eBay versus Bidder's Edge e a Lei de Invasão de Bens Móveis

- Em 1997, o mercado de Beanie Babies estava em alta, o setor de tecnologia estava em ebulição e as casas de leilão online eram a grande novidade da internet. Uma empresa chamada **Bidder's Edge foi formada e criou um novo tipo de site de leilão**. Em vez de exigir que você saltasse de site em site comparando preços, **eles agregavam dados de todos os leilões em andamento para um produto específico** (como um novíssimo e popular boneco Furby ou uma cópia do filme Spice World) **e o redirecionavam para o site com o preço mais baixo**.
- A Bidder's Edge conseguiu isso com um **exército de web scrapers**, que constantemente faziam solicitações aos servidores web dos vários sites de leilão para obter informações de preço e produto. **Entre todos os sites de leilão, o eBay era o maior**, e o **Bidder's Edge acessava os servidores do eBay cerca de 100 mil vezes por dia**. Mesmo considerando os padrões atuais, essa é uma quantidade enorme de tráfego. **Segundo o eBay, isso correspondia a 1,53% de todo o tráfego da internet na época, algo que certamente não agradava**.

eBay versus Bidder's Edge e a Lei de Invasão de Bens Móveis

- Então, o **eBay enviou uma carta de cessar e desistir à Bidder's Edge**, acompanhada de uma proposta para licenciar seus dados. No entanto, as **negociações** para essa licença **fracassaram**, e a **Bidder's Edge continuou a rastrear o site do eBay**.
- O eBay tentou bloquear os endereços IP utilizados pela Bidder's Edge, bloqueando 169 endereços IP - embora a Bidder's Edge tenha conseguido contornar isso por meio de servidores proxy. Como você pode imaginar, essa solução se revelou frustrante e inviável para ambas as partes a Bidder's Edge estava constantemente buscando novos servidores proxy e adquirindo novos endereços IP enquanto os antigos eram bloqueados, enquanto o eBay era forçado a manter extensas listas de firewall (além de lidar com a sobrecarga computacionalmente dispendiosa de verificar cada pacote).
- Finalmente, em dezembro de 1999, o eBay processou a Bidder's Edge por invasão de bens móveis.
- Como os servidores do eBay eram recursos reais e tangíveis de sua propriedade, e a **empresa não apreciava o uso anormal realizado pela Bidder's Edge**, a **aplicação da Lei de Invasão de Bens Móveis** parecia ser a medida legal ideal. Na verdade, nos dias de hoje, essa lei está intimamente relacionada aos processos de web scraping e costuma ser mais considerada como uma lei de TI.

eBay versus Bidder's Edge e a Lei de Invasão de Bens Móveis

- Os tribunais decidiram que, para o eBay ganhar seu caso por invasão de bens móveis, a empresa tinha que mostrar duas coisas:
  - Que a Bidder's Edge tinha conhecimento explícito de que estava proibida de utilizar os recursos do eBay.
  - Que o eBay sofreu prejuízos financeiros como resultado das ações da Bidder's Edge.
- Considerando o histórico das cartas de cessar e desistir do eBay, junto a registros de TI mostrando o uso do servidor e os custos reais associados aos servidores, isso foi relativamente fácil para o eBay fazer. É claro que nenhuma grande batalha judicial termina facilmente: contraprocessos foram apresentados, muitos advogados foram pagos, e o assunto acabou sendo resolvido fora dos tribunais por uma quantia não revelada em março de 2001.

eBay versus Bidder's Edge e a Lei de Invasão de Bens Móveis

- Esse caso, então, nos mostra que qualquer uso não autorizado do servidor de outra pessoa automaticamente constitui uma violação da Lei de Invasão de Bens Móveis? Não necessariamente.
- **O caso da Bidder's Edge foi excepcional; ela estava consumindo tantos recursos do eBay que a empresa teve que comprar servidores adicionais, arcar com custos extras de eletricidade e, possivelmente, contratar mais pessoal. Embora o aumento de 1,53% possa não parecer muito, em empresas de grande porte isso pode representar uma quantia considerável**.

Estados Unidos versus Auernheimer e a Lei de Fraude e Abuso de Computadores

- Se as informações estiverem prontamente acessíveis na internet para um ser humano utilizando um navegador da web, é pouco provável que acessá-las da mesma forma de maneira automatizada o coloque em apuros com as autoridades federais. No entanto, por mais simples que seja para uma pessoa suficientemente curiosa encontrar uma pequena falha de segurança, essa pequena falha pode rapidamente se tornar muito maior e mais perigosa quando scrapers automatizados entram em cena.
- Em 2010, Andrew Auernheimer e Daniel Spitler descobriram uma **peculiaridade interessante nos iPads: ao visitá-los no site da AT&T, a empresa os redirecionaria para uma URL contendo o número de identificação exclusivo do seu iPad**:
- https://dcp2.att.com/OEPClient/openPage?ICCID=<idNumber>&IMEI=

Estados Unidos versus Auernheimer e a Lei de Fraude e Abuso de Computadores

- Essa página continha um formulário de login, com o endereço de e-mail do usuário cujo número de identificação estava na URL. Isso permitia que os usuários acessassem suas contas simplesmente inserindo suas senhas.
- Embora houvesse uma grande quantidade de números de identificação de iPads, era possível, com um web scraper, iterar pelos números potenciais, coletando endereços de e-mail durante o processo. Ao fornecer esse recurso de login conveniente aos usuários, a **AT&T basicamente tornou públicos os endereços de e-mail de seus clientes na web**.
- **Auernheimer e Spitler desenvolveram um scraper que coletou 114.000 desses endereços de e-mail, incluindo os endereços de e-mail privados de celebridades, CEOs e autoridades governamentais**. Então, Auernheimer enviou a lista e informações sobre como ela foi obtida para a Gawker Media, que publicou a história (mas não a lista) com a seguinte manchete: "A pior violação de segurança da Apple: 114.000 proprietários de iPad Expostos".

Estados Unidos versus Auernheimer e a Lei de Fraude e Abuso de Computadores

- Em junho de 2011, a casa de Auernheimer foi invadida pelo FBI devido à coleta de endereços de e-mail, embora ele tenha acabado por ser detido por acusações relacionadas a drogas. Posteriormente, em novembro de 2012, ele foi considerado culpado de fraude de identidade e conspiração por acessar um computador sem autorização, sendo então condenado a cumprir 41 meses de prisão federal e a pagar 73 mil dólares como restituição.
- Seu caso chamou a atenção do advogado de direitos civis Orin Kerr, que se juntou à sua equipe jurídica e levou o caso para o Tribunal de Apelações do Terceiro Circuito. Embora a condenação de Auernheimer tenha sido anulada apenas em recurso devido à falta de jurisdição, o Tribunal de Apelações do Terceiro Circuito se mostrou receptivo a esse argumento em uma nota de rodapé incluída em sua decisão:

Estados Unidos versus Auernheimer e a Lei de Fraude e Abuso de Computadores

- "Embora não seja necessário decidir se a conduta de Auernheimer envolveu tal violação, não há evidências apresentadas no julgamento de que o web scraper violou qualquer senha ou outra barreira baseada em código. O web scraper simplesmente acessou a parte publicamente acessível da tela de login e extraiu informações que a AT&T publicou acidentalmente."
- Apesar de Auernheimer não ter sido condenado sob a Lei de Fraude e Abuso de Computadores, sua casa foi invadida pelo FBI, ele gastou milhares de dólares em honorários advocatícios e passou três anos entre tribunais e prisões.

Field versus Google: direitos autorais e robots.txt

- Um advogado chamado Blake Field moveu uma **ação judicial contra a Google**, alegando que **seu recurso de cache de site violava a Lei de Direitos Autorais ao exibir uma cópia de seu livro após ele o ter removido de seu site**. A lei permite que o criador de uma obra criativa original tenha controle sobre a distribuição dessa obra. O argumento de Field foi que o cache do Google (após ele ter removido o livro de seu site) eliminou sua capacidade de controlar a distribuição.

Field versus Google: direitos autorais e robots.txt

- Conhecer o recurso de cache do Google e não tomar nenhuma medida não ajudou no caso de Field. Afinal, **ele poderia ter evitado que os Googlebots armazenassem em cache seu site simplesmente adicionando o arquivo robots.txt**, com instruções simples sobre quais páginas podem ou não ter os dados coletados por web scraping.
- Além disso, o tribunal determinou que a cláusula de porto seguro da DMCA permitia legalmente ao Google armazenar em cache e exibir sites como o de Field: "[um] provedor de serviços não será responsável por indenização financeira [...] por infração de direitos autorais em razão do armazenamento intermediário e temporário de material em um sistema ou rede controlado ou operado pelo ou para o provedor de serviços.

O cache web do Google

- Quando os web scrapers do Google (também conhecidos como Googlebots) rastreiam sites, eles fazem uma cópia do site e a hospedam na internet. Qualquer pessoa pode acessar esse cache, utilizando o formato de URL:
  - http://webcache.googleusercontent.com/search?q=cache:http://pythonscraping.com
- Se um site que você está procurando ou rastreando não estiver disponível, pode ser útil verificar essa URL para ver se existe uma cópia disponível.

Referências

- MITCHELL, Ryan. **Web Scraping com Python: Coletando mais dados da web moderna**. Novatec Editora, 2023.