Ciência dos dados

Higor Alexandre Duarte Mascarenhas

Aplicações do web scraping

Seu web scraper é “amplo” ou “direcionado”?

- Classificando projetos:
- Você estará coletando dados de um único site ou talvez até um conjunto fixo de páginas dentro desse site? Em caso afirmativo, este é um projeto de web scraping **altamente direcionado**.
- Você precisa coletar dados de um número específico de sites conhecidos? Essa abordagem ainda se enquadra em um scraper **bastante direcionado**, mas pode exigir que você escreva um pouco de código personalizado para cada site e dedique mais tempo à arquitetura do seu web scraper.

Seu web scraper é “amplo” ou “direcionado”?

- Classificando projetos:
- Você está coletando dados de um grande número de sites desconhecidos e descobrindo novos alvos dinamicamente? Você construirá um crawler que deve ser capaz de detectar e fazer suposições automaticamente sobre estrutura dos sites? Pode ser que você esteja escrevendo um scraper amplo ou não direcionado
- Você precisa executar o scraper apenas uma vez ou este será um trabalho contínuo que atualiza os dados ou está constantemente procurando por novas páginas para coletar informações?
- Um projeto de web scraping que será utilizado apenas uma vez pode ser rápido e barato de escrever. O código não precisa ser bonito! O resultado final desse projeto são os próprios dados você pode entregar para o cliente um arquivo Excel ou CSV e ele ficará satisfeito. O código é descartado quando o projeto é concluído.

Seu web scraper é “amplo” ou “direcionado”?

- Classificando projetos:
- Qualquer projeto que envolva monitoramento, nova varredura de dados ou atualização de dados exigirá um código mais robusto que possa ser mantido. Também pode demandar que sua própria infraestrutura de monitoramento identifique erros quando eles ocorrem, bem como falhas na execução ou quando se consome mais tempo ou recursos do que o previsto.
- Os dados coletados são seu produto final ou é necessária uma análise ou manipulação mais detalhada?
- Em casos de coleta simples de dados, o web scraper deposita os dados no banco de dados exatamente como os encontra, ou talvez com algumas linhas de limpeza simples (por exemplo, removendo sinais monetários dos preços dos produtos).
- Quando uma análise mais aprofundada é necessária, pode ser que você nem mesmo saiba quais dados serão importantes. Neste caso, é necessário dedicar mais atenção à arquitetura do seu scraper.

Tipos de web scrappers

- **E-commerce**: raspar dados de produtos e preços de sites de e-commerce.
- **Marketing**: em vez de passar horas navegando pelas redes sociais ou procurando pelo nome de uma empresa, você pode deixar que os web scrapers façam todo o trabalho pesado.
- **Pesquisa acadêmica**
- **Criação de produtos**: Tem uma ideia de negócio e só falta um banco de dados com informações públicas e de conhecimento geral para coloca-lo em prática? Não consegue encontrar uma fonte acessível e conveniente dessas informações por aí? Um web scraper pode ajudar.
- **Agências de viagens**: criar um site de viagens que encontra para os usuários as melhores ofertas de toda a web.

Tipos de web scrappers

- **Vendas**: para melhorar oferta de produtos, como por exemplo: oferta de suplementos para instrutores de academias.
- **Scraping de SERP ou scraping de páginas de resultados de mecanismos de busca**: é a prática de coletar dados úteis diretamente dos resultados dos mecanismos de busca sem acessar as páginas vinculadas em si.

Extração de dados para preguiçosos

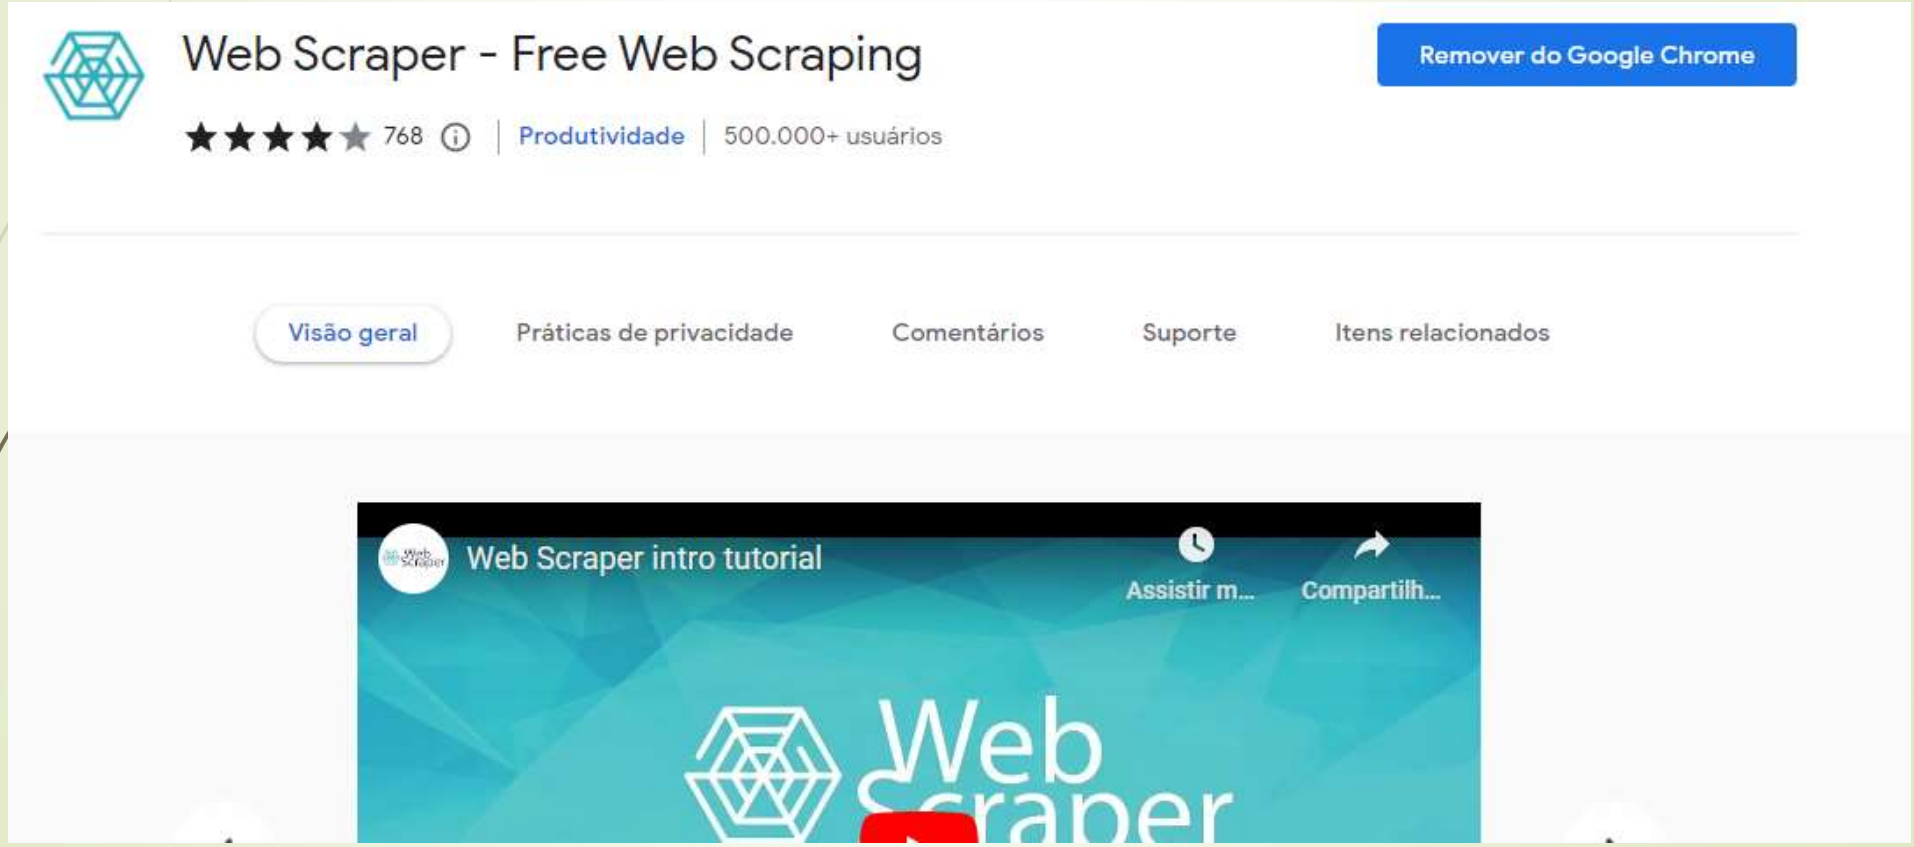
Web Scraper - Free Web Scraping

- Ferramenta de extração de dados da Web com uma interface fácil de apontar e clicar para a web moderna
- Ferramenta de extração de dados da Web gratuita e fácil de usar para todos.
- Possui uma interface simples de apontar e clicar, a capacidade de extrair milhares de registros de um site leva apenas alguns minutos de configuração do scraper.
- O Web Scraper utiliza uma estrutura modular composta por seletores, que instruem o raspador sobre como atravessar o site de destino e quais dados extrair. Graças a essa estrutura, a mineração de dados de sites modernos e dinâmicos, como Amazon, Tripadvisor, eBay, bem como de sites menos conhecidos, é fácil.

Web Scraper - Free Web Scraping

- A extração de dados é executada em seu navegador e não requer que nada seja instalado em seu computador. Você não precisa de experiência em codificação Python, PHP ou JavaScript para começar a extrair. Além disso, é possível automatizar completamente a extração de dados no Web Scraper Cloud.
- É um plug-in do Chrome.

Web Scraper - Free Web Scraping



Web Scraper - Free Web Scraping

Sitemaps | Sitemap extracao_instituicao | Create new sitemap

_root — Data preview

ID	Selector	type	Multiple	Parent selectors	Actions
municipio	td tr:contains('* Município:') td:nth-of-type(2)	SelectorText	no	_root	Element preview Data preview Edit Delete
estado	td tr:contains('* UF:') td:nth-of-type(2)	SelectorText	no	_root	Element preview Data preview Edit Delete
cep	td tr:contains('* CEP:') td:nth-of-type(2)	SelectorText	no	_root	Element preview Data preview Edit Delete
pais	td tr:contains('* País:') td:nth-of-type(2)	SelectorText	no	_root	Element preview Data preview Edit Delete
sigla_inst	td tr:contains('* Sigla da instituição:') td:nth-of-type(2)	SelectorText	no	_root	Element preview Data preview Edit Delete

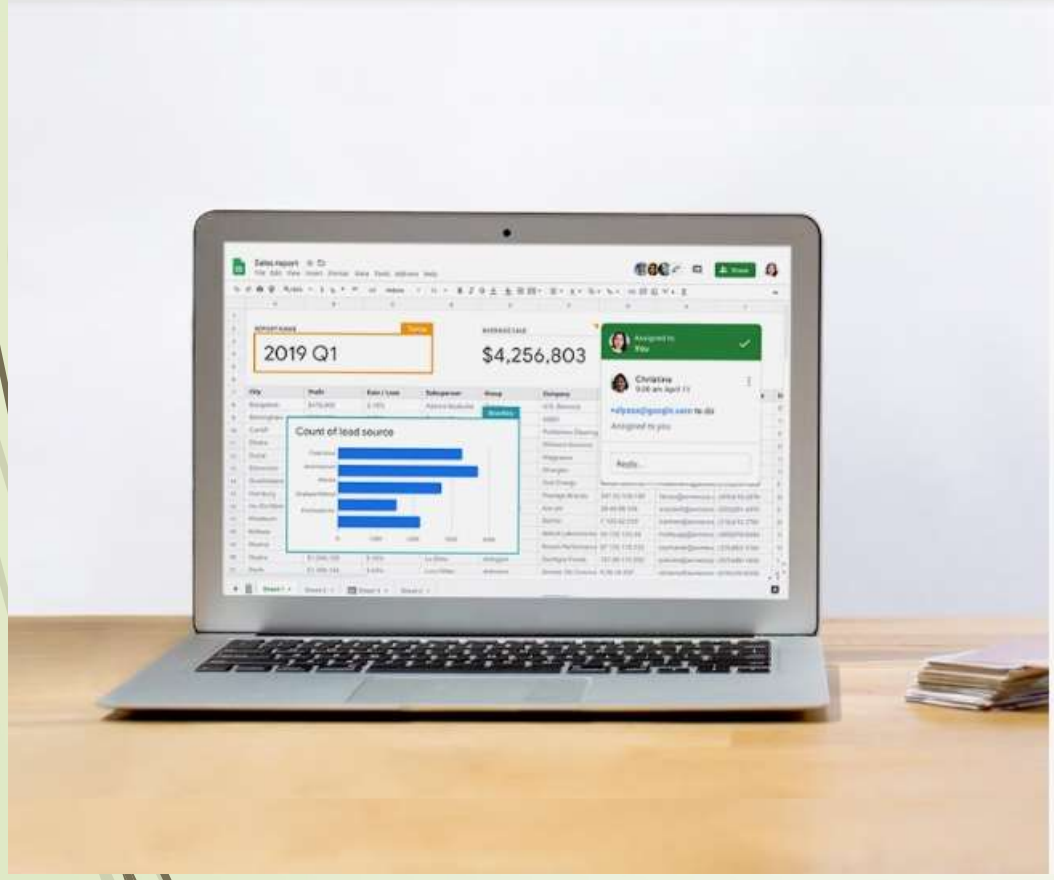
- Demonstração

Google sheets

- Criado para atender às necessidades das organizações que precisam de agilidade.
- Possui recursos de inteligência artificial, podendo acessar os insights certos para tomar decisões empresariais importantes.
- A arquitetura baseada na nuvem permite que você colabore com quem quiser, a qualquer hora e em qualquer lugar. A compatibilidade com sistemas externos, inclusive o Microsoft Office, simplifica o trabalho com várias origens de dados.

Google sheets

Google Workspace Soluções Produtos Setores Preços Recursos Admin Console Entre em contato com a equipe de vendas Iniciar agora



Planilhas

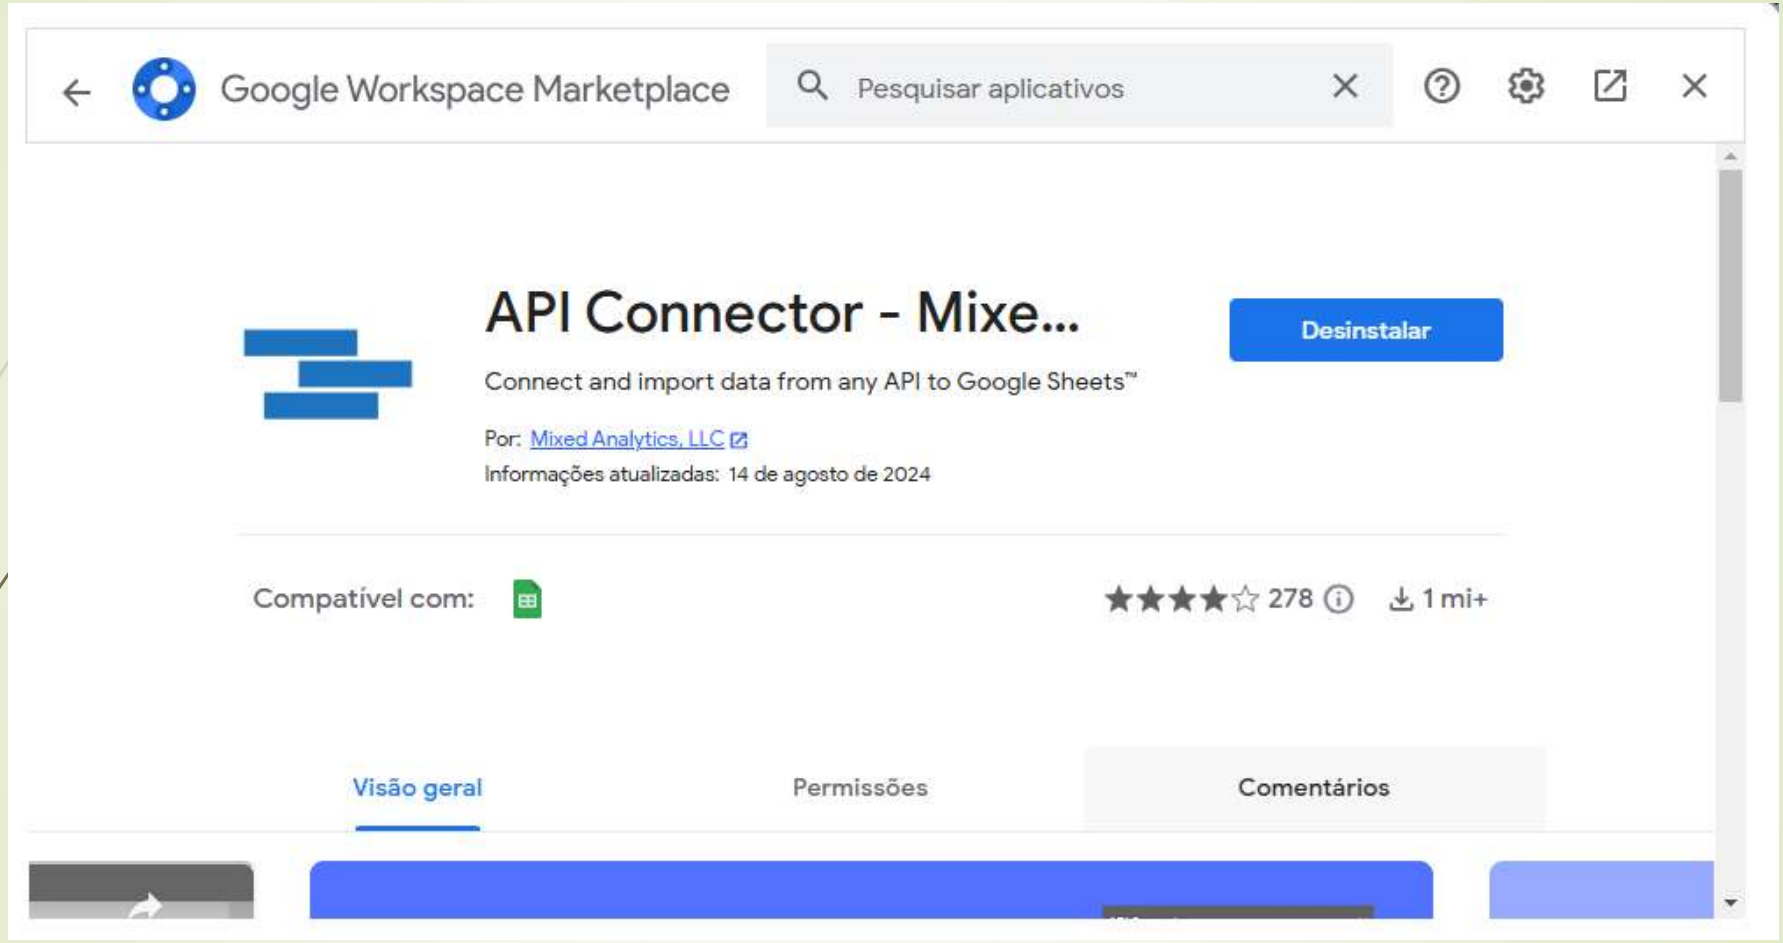
Planilhas colaborativas, inteligentes e seguras para organizações que precisam de agilidade

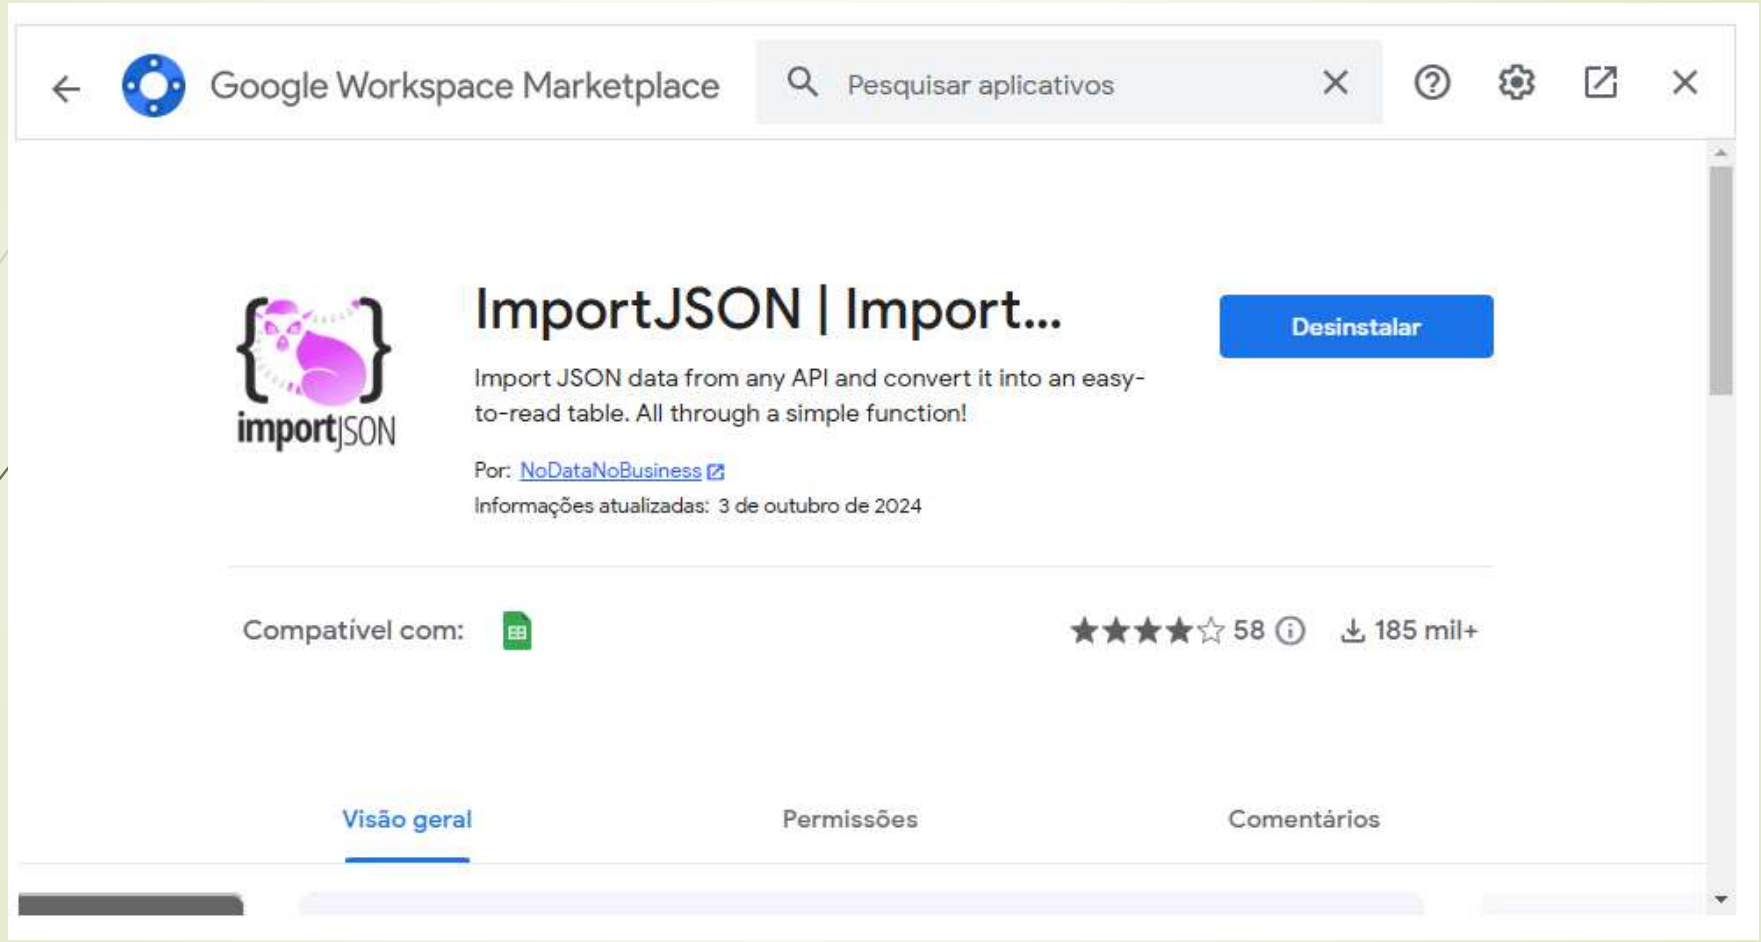
O Planilhas foi criado para atender às necessidades das organizações que precisam de agilidade. Com os recursos de inteligência artificial, você acessa os insights certos para tomar decisões empresariais importantes. A arquitetura baseada na nuvem permite que você colabore com quem quiser, a qualquer hora e em qualquer lugar. A compatibilidade com sistemas externos, inclusive o Microsoft Office, simplifica o trabalho com várias origens de dados. E como o Planilhas é integrado à infraestrutura do Google, você tem toda a liberdade para criar sem comprometer a segurança das suas informações.

Iniciar agora

Função para extrair dados

- IMPORTHTML
- IMPORTXML


Google Workspace Marketplace
Pesquisar aplicativos
API Connector - Mixe...
Desinstalar
Connect and import data from any API to Google Sheets™
Por: Mixed Analytics, LLC
Informações atualizadas: 14 de agosto de 2024
Compatível com:
278
1 mi+
Visão geral
Permissões
Comentários


Google Workspace Marketplace
Pesquisar aplicativos
importJSON
ImportJSON | Import...
Import JSON data from any API and convert it into an easy-to-read table. All through a simple function!
Por: NoDataNoBusiness
Informações atualizadas: 3 de outubro de 2024
Desinstalar
Compatível com:
58
185 mil+
Visão geral
Permissões
Comentários

- Demonstração

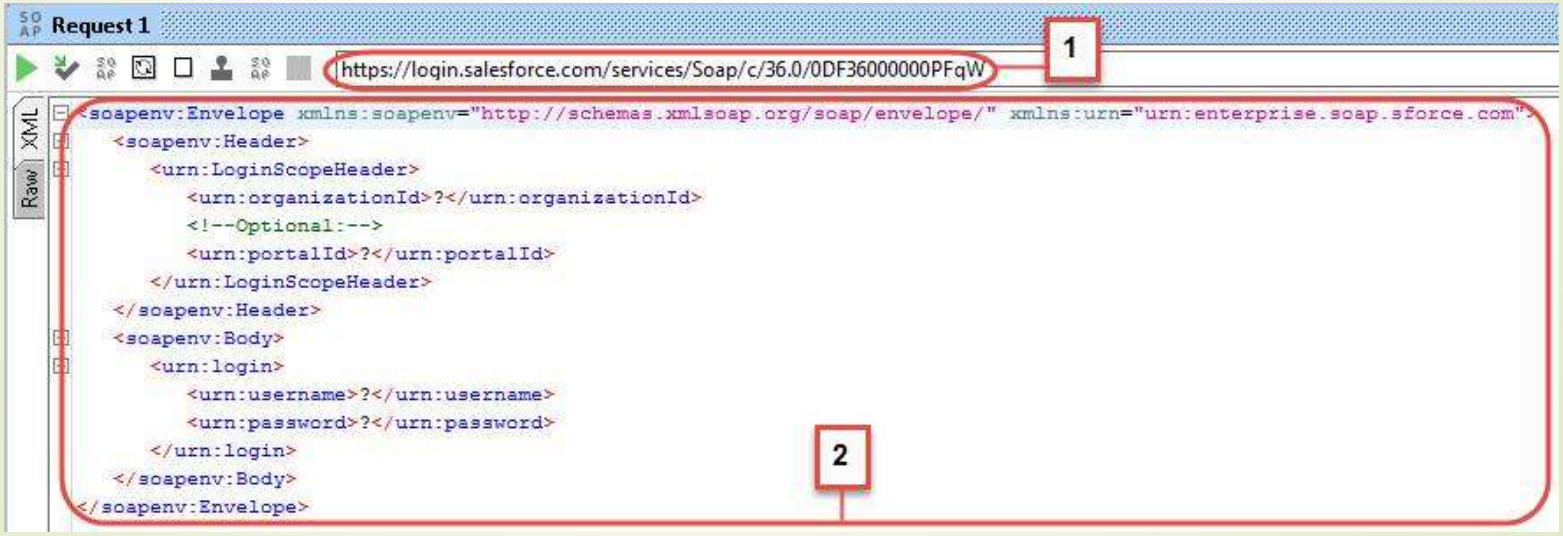
API (Application Programming Interface)

- No português corresponde a **Interface de Programação de Aplicações**;
- São uma forma de integrar sistema, possibilitando:
  - benefícios com a segurança dos dados;
  - facilidade no intercâmbio entre informações com diferentes linguagens de programação.
- Tipo de "ponte" que conectam aplicações, podendo ser utilizadas para os mais variados tipos de negócios, por empresas de diversos nichos de mercado ou tamanho.

Tipos de APIs

APIs SOAP

- Essas APIs usam o Simple Object Access Protocol (Protocolo de Acesso a Objetos Simples). Cliente e servidor trocam mensagens usando XML. Esta é uma API menos flexível que era mais popular no passado.



Tipos de APIs

APIs RPC

- Essas APIs são conhecidas como Remote Procedure Calls (Chamadas de Procedimento Remoto). O cliente conclui uma função (ou um procedimento) no servidor e o servidor envia a saída de volta ao cliente.

APIs WebSocket

- API Websocket é outro desenvolvimento de API da Web moderno que usa objetos JSON para passar dados. Uma API WebSocket oferece suporte à comunicação bidirecional entre aplicativos cliente e o servidor. O servidor pode enviar mensagens de retorno de chamada a clientes conectados, tornando-o mais eficiente que a API REST.

Tipos de APIs

APIs REST

- Essas são as APIs mais populares e flexíveis encontradas na Web atualmente. O cliente envia solicitações ao servidor como dados. O servidor usa essa entrada do cliente para iniciar funções internas e retorna os dados de saída ao cliente.

Maneiras de extrair dados da web

- Existem várias maneiras de **extrair informações da web**. O uso de APIs é provavelmente a melhor maneira de **extrair dados de um website**. Quase todos os grandes sites, como Twitter, Facebook, Google e StackOverflow fornecem APIs para acessar seus dados de maneira mais estruturada.
- Se você puder obter o que precisa por meio de uma API, quase sempre será a abordagem preferida em relação a extrair dados diretamente da web.

O que é web scraping?

- Corresponde a uma técnica de programação que permite extrair informações de páginas da web (websites).
- Essa técnica foca principalmente na transformação de dados não estruturados (formato HTML) da Web em dados estruturados (Banco de dados, JSON ou Planilha).
- Diversas são as maneiras de se extrair um grande conjunto de dados, por exemplo: APIs, Python, plug-in Web Scraper

Bibliotecas do Python para extrair dados

- **Requests:** Faz downloads de arquivos e de páginas web da Internet.
- **Urllib**: É um módulo Python que pode ser usado para buscar URLs. Ele define funções e classes para ajudar com ações de URL (autenticação básica e compilada, redirecionamentos, cookies, etc.).
- **BeautifulSoup**: É uma ferramenta incrível para extrair informações de uma página da web. Pode ser utilizada para extrair tabelas, listas, parágrafos e também pode colocar filtros para extrair, por exemplo, e-mails de páginas da web. Fazendo parse de HTML, que é o formato em que as páginas web são escritas.()
- **Selenium:** Inicia e controla um navegador web. O Selenium é capaz de preencher formulários e simular cliques de mouse nesse navegador.

Requests – Método GET

- O método o **GET**, que vai servir para pegar informações de uma API. Nesse exemplo você vai poder pegar o link abaixo que é o link da API de cotação de moedas para obter a cotação desejada.
- Utilização:
- Import requests
- link = https://economia.awesomeapi.com.br/last/USD-BRL,EUR-BRL,BTC-BRL
- content = requests.get(link)

urllib

- Assim como o requests, para se obter uma página, pode ser utilizado o urllib.
- O import dele é da seguinte maneira
- from urllib.request import urlopen
- urlopen("www.globo.com")

BeautifulSoup

- Beautiful Soup é uma biblioteca Python para extrair dados de arquivos HTML e XML.
- Ele funciona com seu analisador favorito para fornecer maneiras idiomáticas de navegar, pesquisar e modificar a árvore de análise.
- Geralmente economiza horas ou dias de trabalho dos programadores.

Seletor passado ao método select()	Corresponde a...
soup.select('div')	Todos os elementos de nome .
soup.select('#author')	O elemento com um atributo id igual a author.
soup.select('.notice')	Todos os elementos que utilizem um atributo class de CSS chamado notice.
soup.select('div span')	Todos os elementos de nome que estejam em um elemento chamado .
soup.select('div > span')	Todos os elementos de nome que estejam *diretamente* em um elemento chamado , sem que haja outros elementos intermediários.
soup.select('input[name]')	Todos os elementos de nome <input> que tenham um atributo name com qualquer valor.
soup.select('input[type="button"]')	Todos os elementos de nome <input> que tenham um atributo chamado type com o valor button.

BeautifulSoup

- find()
  - Podemos pesquisar qualquer coisa em nossa página da web. Digamos que queremos obter um título e o preço do produto com base em seus IDs.
  - title = soup.find(id="productTitle").get_text()
  - price = soup.find(id="priceblock_ourprice").get_text()
- get_text()
  - Para extrair a parte do texto dos elementos recém-encontrados title e price.
- find_all()
  - Para obter todos as tags passadas nesta função.

- Demonstração

Expressões Regulares

- Imagine que você tenha um problema e decida resolvê-lo utilizando expressões regulares. Bem, agora você tem dois problemas.
- Porém são extremamente úteis para web scraping
- Efetua a seleção de strings contendo um determinado padrão

Exemplo de Expressões Regulares

- **Aa*bbbbb(cc)*(d|e)**
- **aa*** => A letra a é escrita, seguida de a* (leia como a asterisco), que significa "qualquer quantidade de letras a, incluindo nenhuma". Dessa forma, podemos garantir que a letra a seja escrita pelo menos uma vez.
- **bbbbb** => Não há efeitos especiais nesse caso apenas cinco letras b seguidas.
- **(cc)*** => Qualquer número par de itens pode ser agrupado em pares. Portanto, para aplicar essa regra sobre itens pares, podemos escrever duas letras c, colocá-las entre parênteses e escrever um asterisco depois, o que significa que podemos ter qualquer quantidade de pares de letras c (é importante observar que isso pode significar nenhum par também).
- **(d|e)** => Adicionar uma barra no meio de duas expressões significa que pode ser "esta ou aquela". Nesse caso, estamos dizendo para "adicionar um **d** ou um **e**". Dessa forma, garantimos que haja exatamente um desses dois caracteres.

Expressões regulares

Símbolo (s)	Significado	Exemplo	Exemplo de correspondência
*	Faz a correspondência com o caractere, a subexpressão ou o caractere entre colchetes anterior, 0 ou mais vezes.	a*b*	aaaaaaaa, aaabbbbb, bbbbbb
+	Faz a correspondência com o caractere, a subexpressão ou o caractere entre colchetes anterior, 1 ou mais vezes.	a+b+	aaaaaaaab, aaabbbbb, abbbbbb
[]	Faz a correspondência com qualquer caractere entre colchetes (ou seja, "Selecione qualquer um desses itens").	[A-Z]*	APPLE, CAPITALS, QWERTY
()	Uma subexpressão agrupada (são avaliadas primeiro, na "ordem de operações" das expressões regulares).	(a*b)*	aaabaab, abaaab, ababaaaaab
{m, n}	Faz a correspondência com o caractere, a subexpressão ou o caractere entre colchetes anterior entre *m* e *n* vezes (inclusive).	a{2,3}b{2,3}	aabbb, aaabbb, aabb
[^]	Faz a correspondência com qualquer caractere único que *não* esteja entre colchetes.	[^A-Z]*	apple, lowercase, qwerty

Expressões regulares

|	Faz a correspondência com qualquer caractere, string de caracteres ou subexpressão, separado por I (observe que essa é uma barra vertical, ou *pipe*, e não a letra i maiúscula).	`b(a|i|e)d`	`bad, bid, bed`
.	Faz a correspondência com qualquer caractere único (incluindo símbolos, números, um espaço etc.).	`b.d`	`bad, bzd, b$d, b d`
^	Indica que um caractere ou subexpressão ocorre no início de uma string.	`^a`	`apple, asdf, a`
\	Um caractere de escape (permite utilizar caracteres especiais com seus significados literais).	`\^ \\ \\`	`^ \ \`
$	Utilizado com frequência no final de uma expressão regular, significa "faça a correspondência disso até o final da string". Sem ele, toda expressão regular tem um ".*" de fato ao final dela, aceitando strings nas quais somente a primeira parte dela seja correspondente. Pense nisso como análogo ao símbolo ^.	`[A-Z]*[a-z]*$`	`ABCabc, zzzyx, Bob`

Exemplo de padrão de email

- [A-Za-z0-9._+]+@[A-Za-z]+.(com/org/edu/net)

Regra nº 1 A primeira parte de um endereço de e-mail contém pelo menos um dos seguintes dados: letras maiúsculas, letras minúsculas, os números de 0-9, pontos (.), sinais de adição (+) ou underscores (_).	`[A-Za-z0-9._+]+` A expressão regular concisa é bastante inteligente. Por exemplo, ela sabe que "A-Z" significa "qualquer letra maiúscula, de A a Z". Ao colocar todas essas sequências e símbolos possíveis entre colchetes (em vez de parênteses), estamos dizendo que "este símbolo pode ser qualquer um desses dados que listamos entre os colchetes". É importante observar também que o sinal de + significa que "esses caracteres podem ocorrer quantas vezes for desejável, mas devem ocorrer pelo menos uma vez".
Regra nº 2 Depois disso, o endereço de e-mail contém o símbolo @.	`@` Essa regra é bem simples: o símbolo @ deve ocorrer no meio, e deve aparecer exatamente uma vez.
Regra nº 3 O endereço de e-mail então deve conter pelo menos uma letra maiúscula ou minúscula.	`[A-Za-z]+` Podemos utilizar apenas letras na primeira parte do nome do domínio, depois do símbolo @. Além disso, deve haver pelo menos um caractere.
Regra nº 4 Um ponto deve estar presente a seguir (.).	`.` Um ponto (.) deve ser incluído antes do domínio de nível mais alto.
Regra nº 5 Por fim, o endereço de e-mail termina com *com*, *org*, *edu* ou *net* (na verdade, há diversos domínios de nível mais alto possíveis, mas esses quatro devem ser suficientes para o exemplo).	`(com|org|edu|net)` Lista as possíveis sequências de letras que podem ocorrer após o ponto na segunda parte de um endereço de e-mail.