Ciência dos Dados

Higor Alexandre Duarte Mascarenhas

Introdução ao JS

- Ter pelo menos uma noção do que está acontecendo no código do qual você está coletando dados pode ser extremamente útil. Com isso em mente, é uma boa ideia ter familiaridade com o JavaScript.
- O JavaScript é uma linguagem de tipagem fraca, com uma sintaxe que muitas vezes é comparada à do C++ e do Java. Embora certos elementos da sintaxe, como operadores, loops e arrays, possam ser parecidos, a tipagem fraca e a natureza de script da linguagem podem torná-la difícil de lidar para alguns programadores.

Introdução ao JS

- Por exemplo, o código a seguir calcula valores da sequência de Fibonacci até 100 utilizando recursão, e os exibe no console do desenvolvedor no navegador:

```
<script>
function fibonacci(a, b){
var nextNum = a + b;
console.log(nextNum+" is in the Fibonacci sequence");
if(nextNum < 100) {
fibonacci(b, nextNum);
}
fibonacci(1, 1);
</script>
```

Bibliotecas de Js comuns

- **jQuery** é uma biblioteca muito popular, sendo utilizada por mais de 70% de todos os sites. Um site que utiliza jQuery é facilmente identificável porque conterá uma importação para jQuery em algum lugar do seu código:

```
<script src="http://ajax.googleapis.com/ajax/libs/jquery/1.9.1/jquery.min.js"></script>
```

- Se o jQuery for encontrado em um site, tenha cuidado ao fazer seu scraping. Essa biblioteca tende a criar conteúdo HTML de forma dinâmica, que só aparece depois que o JavaScript é executado. Se fizer scraping da página utilizando os métodos tradicionais, obterá apenas a página previamente carregada, exibida antes de o JavaScript ter criado o conteúdo.
- Além disso, é provável que essas páginas contenham animações, conteúdo interativo e mídia incorporada, o que pode tornar a coleta de dados mais desafiadora

Bibliotecas de Js comuns

- O **Google Analytics** é utilizado por cerca de 50% de todos os sites, o que talvez o torne a biblioteca JavaScript e a ferramenta de monitoramento de usuários mais popular na internet. Tanto http://pythonscraping.com como http://www.oreilly.com/ utilizam o Google Analytics.
- Determinar se uma página está utilizando o Google Analytics é fácil. Ela terá um código JavaScript no final, semelhante a este (extraído do site da O'Reilly Media):

Google Analytics

```
<!-- Google Analytics -->
<script type="text/javascript">
vargaqgaq || [];
_gaq.push(['setAccount', 'UA-4591498-1']);
_gaq.push(['setDomainName', 'oreilly.com']);
_gaq.push(['_addIgnoredRef', 'orellly.com']);
_gaq.push(['_setSiteSpeedSampleRate', 50]);
_gaq.push(['_trackPageview']);
(function() (var ga = document.createElement('script'); ga.type =
'text/javascript'; ga.async = true; ga.src = ('https:' ==
document.location.protocol ? 'https://ssl': 'http://www') + .google-
analytics.com/ga.js'; var s =
document.getElementsByTagName('script')[0]; s.parentNode.insertBefore(ga, s);
})();
</script>
```

Google Analytics

- Esse script trata cookies específicos do Google Analytics utilizados para rastrear o seu acesso de página em página. Às vezes, isso pode ser um problema para web scrapers projetados para executar JavaScript e tratar cookies (como aqueles que utilizam o Selenium).
- Se um site utiliza o Google Analytics ou um sistema semelhante de análise da web (web analytics), e você não quer que ele saiba que está sendo rastreado ou que seus dados estão sendo coletados, certifique-se de descartar todos os cookies utilizados para análise, ou mesmo todos os cookies.

Bibliotecas de Js comuns

- Se você já passou algum tempo na internet, é quase certo que já tenha visto o **Google Maps** incorporado a um site. Sua API torna extremamente fácil incorporar mapas com informações personalizadas em qualquer site.
- Se estiver coletando qualquer tipo de dados de localização, compreender como o Google Maps funciona facilitará obter coordenadas de latitude/longitude bem formatadas e até mesmo endereços. Uma das maneiras mais comuns de indicar uma localização no Google Maps é utilizando um marcador (também conhecido como pin).
- Marcadores podem ser inseridos em qualquer mapa do Google Maps por meio do código a seguir:

Google Maps

```
var marker = new google.maps.Marker({
position: new google.maps.LatLng(-25.363882,131.044922),
map: map,
title: 'Some marker text'
});
```

- O Python facilita a extração de todas as instâncias de coordenadas que estiverem entre google.maps.LatLng(e) para obter uma lista de coordenadas com latitudes/ longitudes.
- Utilizando a API Reverse Geocoding do Google (*https://developers.google.com/maps/documentation/javascript/examples/geocoding-reverse*), é possível converter esses pares de coordenadas em endereços bem formatados para armazenamento e análise.

Dicas de extração dos dados baseados em urls

Exemplos

- Sempre observe a url, para ver se cada página há um identificador diferente. Exemplo:
  - https://sucupira.capes.gov.br/programas/detalhamento/2099
- Sempre observe a url ao interagir com a página, a exemplo do link:
  - https://www.pricecharting.com/game/pokemon-destined-rivals/team-rocket%27s-mewtwo-ex-231#used-prices

Exemplos

1. **Sempre observe a estrutura da URL**

- Quando uma página muda de endereço conforme você clica em itens diferentes, normalmente **há um ID único por página**.
- Isso é ótimo para scraping porque você pode **iterar por uma lista de IDs**.
- https://sucupira.capes.gov.br/programas/detalhamento/2099
- O número 2099 representa um programa específico.
- Se você descobrir a lista de IDs, consegue acessar centenas de páginas só mudando esse número.

Exemplos

2. Observe a URL enquanto interage com a página

- Alguns sites não recarregam a página toda, mas modificam o conteúdo dinamicamente com JavaScript. Ainda assim, a URL pode mudar (com #, ?, ou **caminhos diferentes**).
- Isso ajuda a identificar se a navegação pode ser monitorada ou usada para scraping.
- https://www.pricecharting.com/game/pokemon-destined-rivals/team-rocket%27s-mewtwo-ex-231#used-prices
  - Aqui, **team-rocket%27s-mewtwo-ex-231** é o identificador do item.
  - O final **#used-prices** é uma âncora que muda o conteúdo visualizado, útil para saber o estado atual da página.

Exemplos

3. Entenda os parâmetros da URL

- Sites que usam **?** na URL geralmente estão enviando parâmetros para o servidor (muito comum em filtros de busca, paginação, etc.)
- https://exemplo.com/produtos?page=2&categoria=livros
- Isso permite navegar pelas páginas ou aplicar filtros automaticamente via scraping.

Atividade

- Você foi contratado para desenvolver um robô de coleta de dados que busca cursos disponíveis no site da Fundação Bradesco (https://www.ev.org.br/cursos). Sua tarefa será extrair, automaticamente, **todas as informações relevantes de cada curso listado**, de forma estruturada.
- Este exercício tem como objetivo simular um cenário real de **extração de dados úteis da web para fins de análise ou visualização**.

Continuação de atividade

- Utilizando técnicas de Web Scraping, seu script deverá acessar a página de cursos da plataforma e **extrair para cada curso**:
- Título do curso
- Área/tema (se disponível)
- Descrição/resumo
- Carga horária
- Nível de dificuldade (ex: básico, intermediário...)
- Link direto para a página do curso
- Conteúdo de cada curso
- Detalhes de cada curso
- Os dados devem ser armazenados em **arquivo JSON**,.

Executando Python com o Selenium

Seletores no Selenium

- Anteriormente selecionamos elementos da página utilizando seletores do **BeautifulSoup**, como **find** e **find_all**. O Selenium utiliza um conjunto de métodos muito parecido para selecionar elementos: **find_element** e **find_elements**.
- Com tantas maneiras possíveis de encontrar e selecionar elementos no HTML, você pode imaginar que o Selenium utiliza uma grande variedade de argumentos e parâmetros para esses métodos. No entanto, tanto para **find_element** quanto para **find_elements**, existem apenas dois argumentos: o objeto **By** e o **seletor de string**,
- O objeto **By** determina como a string do seletor deve ser interpretada, com a seguinte lista de opções:
- **By.ID**: Utilizado no exemplo; encontra elementos com base no atributo id do HTML.

Seletores no Selenium

- **By.NAME**: Encontra tags HTML com base em seu atributo name. É bastante útil para formulários HTML.
- **By.XPATH**: Utiliza uma expressão XPath para selecionar elementos correspondentes.
- **By.LINK_TEXT**: Encontra tags HTML <a> com base no texto que contêm. Por exemplo, um link rotulado como "Next" pode ser selecionado com (By.LINK_TEXT, 'Next').
- **By.PARTIAL_LINK_TEXT**: Semelhante a LINK_TEXT, mas faz a correspondência com uma parte da string.
- **By.TAG_NAME**: Encontra tags HTML com base no nome das tags.
- **By.CLASS_NAME**: Utilizado para encontrar elementos com base no atributo class do HTML. Por que essa função se chama CLASS_NAME, e não apenas CLASS? Utilizar object.CLASS causaria problemas na biblioteca Java do Selenium, pois class é um método reservado nela. Para manter a sintaxe do Selenium consistente entre as linguagens, utiliza-se CLASS_NAME.

Seletores no Selenium

- **By.CSS_SELECTOR:** Encontra elementos com base no nome de sua class, id ou tag, utilizando a convenção `#idName, .className, tagName`.

XPath

Seletores no Selenium

- A sintaxe do Xpath tem quatro conceitos principais
- ***Nós raiz versus nós que não são raiz***
  - /div selecionará o nó div apenas se estiver na raiz do documento.
  - //div seleciona todos os divs em qualquer parte do documento.
- ***Seleção de atributos***
  - //@href seleciona qualquer nó que tenha o atributo href.
  - //a[@href='http://google.com'] seleciona todos os links do documento que apontem para o Google.

Seletores no Selenium

- ***Seleção de nós com base na posição***
- //a[3] seleciona o terceiro link do documento.
- //table[last()] seleciona a última tabela do documento.
- //a[position() < 3] seleciona os dois primeiros links do documento.
- ***Asteriscos (*) fazem a correspondência com qualquer conjunto de caracteres ou nós e podem ser utilizados em várias situações***
- //table/tr/* seleciona todos os filhos de tags **tr** em todas as tabelas (útil para selecionar células que utilizem tags **th** e **td**).
- //div[@*] seleciona todas as tags **div** que tiverem qualquer atributo.