Inteligência Computacional - Atividade Prática 01

Análise e Pré-processamento de Dados (Adult Census Income)

João Paulo da Cunha Faria
(joaopaulo@example.com)

Engenharia de Computação

Orientador: Prof. Dr. Alisson Marques da Silva
Coorientadores: ,

CEFET-MG
2026

Objetivo do Trabalho

- Desenvolver um experimento contemplando análise e compreensão dos dados.
- Aplicar pré-processamento e definir uma metodologia experimental adequada.
- Comparar modelos de forma reprodutível e metodologicamente correta.

Contextualização do Problema

- **Descrição:** identificação do problema associado ao conjunto de dados.
- **Cenário:** predição de renda anual com dados do censo de 1994.
- **Objetivo do modelo:** prever se a renda anual supera 50 mil dólares.
- **Tipo de tarefa:** classificação binária.

Caracterização Geral da Base

- **Fonte:** UCI Machine Learning Repository.
- **Total de instâncias:** 32.561 registros.
- **Número de atributos:** 14 variáveis preditoras.
- **Atributos mistos:** variáveis categóricas, inteiras e reais.

age	workclass	fnlwgt	education
education-num	marital-status	occupation	relationship
race	sex	capital-gain	capital-loss
hours-per-week	native-country		

Tabela: Lista de atributos da base Adult Census Income.

EDA: Distribuição de Idade

- **Método:** histogramas para visualizar concentração dos dados.
- **Observação:** maior parte da amostra entre 20 e 50 anos.
- **Importância:** compreender a demografia e reduzir vieses geracionais.

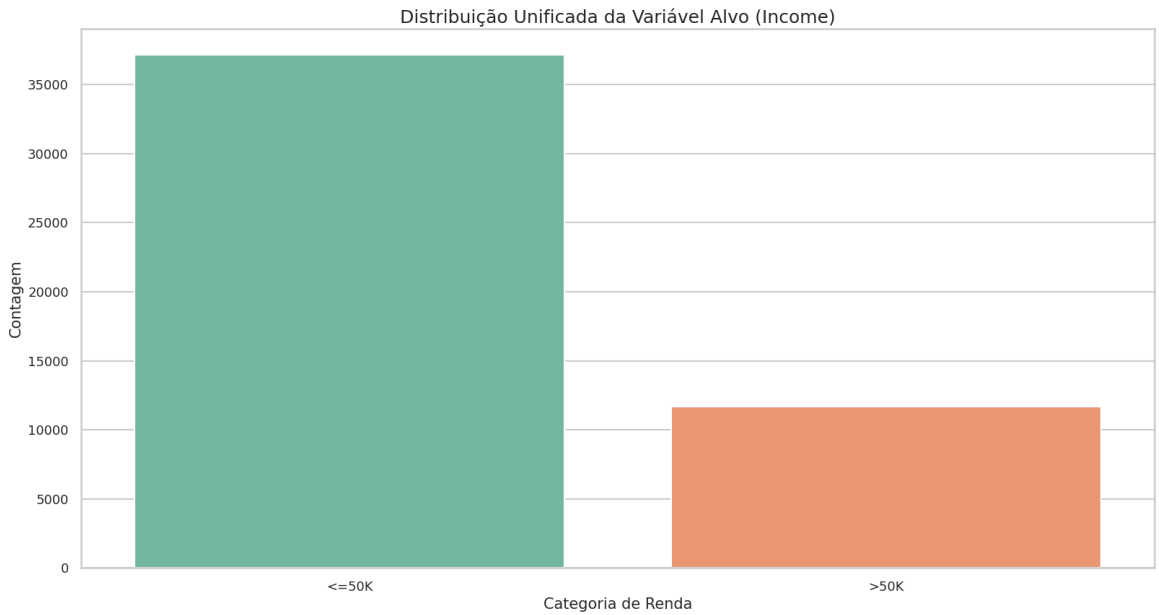


Figura: Histograma da variável idade.

EDA: Horas Trabalhadas e Renda

- **Método:** boxplots relacionando horas semanais e classe de renda.
- **Outliers:** casos extremos de até 99 horas por semana.
- **Tendência:** renda >50K tende a maior carga horária média.

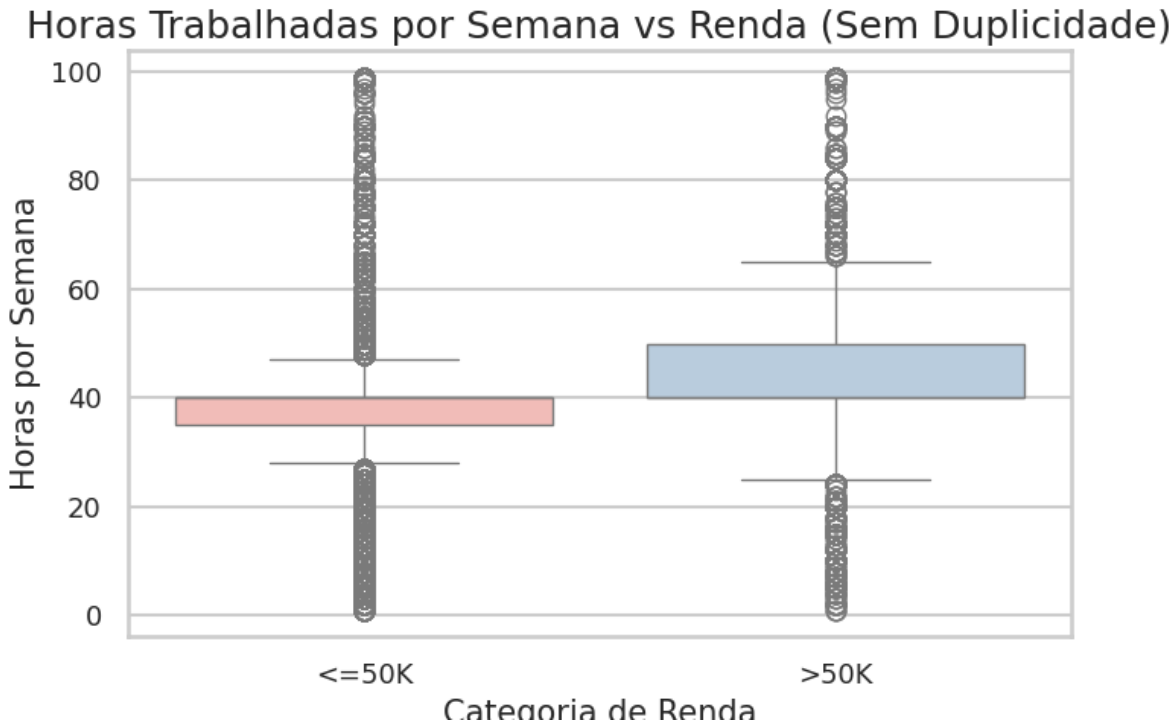


Figura: Distribuição de horas por semana por classe de renda.

Identificação de Problemas de Qualidade

- **Valores ausentes:** presença de "?" em colunas como workclass e occupation.
- **Ruídos de rótulo:** inconsistência entre "<=50K" e "<=50K.".
- **Desbalanceamento:** classe de menor renda representa aproximadamente 76%.
- **Redundância:** atributo education redundante em relação ao education-num.

Pré-processamento: Limpeza e Seleção

- **Tratamento de ausentes:** imputação pela moda para variáveis categóricas.
- **Seleção de atributos:** remoção de fnlwgt por baixa relevância para predição individual.
- **Redução de redundância:** descarte da coluna education, mantendo education-num.

Pré-processamento: Transformação de Dados

- **Codificação:** One-Hot Encoding para variáveis nominais.
- **Justificativa:** evita hierarquia artificial entre categorias nominais.
- **Normalização:** StandardScaler para padronizar escala dos atributos numéricos.

Metodologia Experimental

- **Estratégia de divisão:** hold-out com 80% para treino e 20% para teste.
- **Estratificação:** manutenção da proporção das classes em treino e teste.
- **Justificativa:** avaliação justa, simples e reprodutível.

Algoritmos Selecionados

- **Random Forest:** robusto para alta dimensionalidade após o encoding.
- **Regressão Logística:** baseline estatístico para comparação.
- **KNN (k=5):** avalia impacto da esparsidade no espaço de atributos.

Discussão: Por que o F1-Score?

- **Problema:** em bases desbalanceadas, acurácia pode ser enganosa.
- **Solução:** F1-Score equilibra Precisão e Recall.
- **Objetivo:** melhorar a identificação da classe minoritária (>50K).

$$F_1 = 2 \cdot \frac{\text{Precisão} \cdot \text{Recall}}{\text{Precisão} + \text{Recall}}$$

Resultados Obtidos

- **Desempenho:** Random Forest apresentou melhor equilíbrio entre as métricas.
- **Comparação:** KNN perdeu desempenho com alta dimensionalidade após encoding.
- **Leitura geral:** baseline linear ficou competitivo, porém abaixo do melhor modelo.

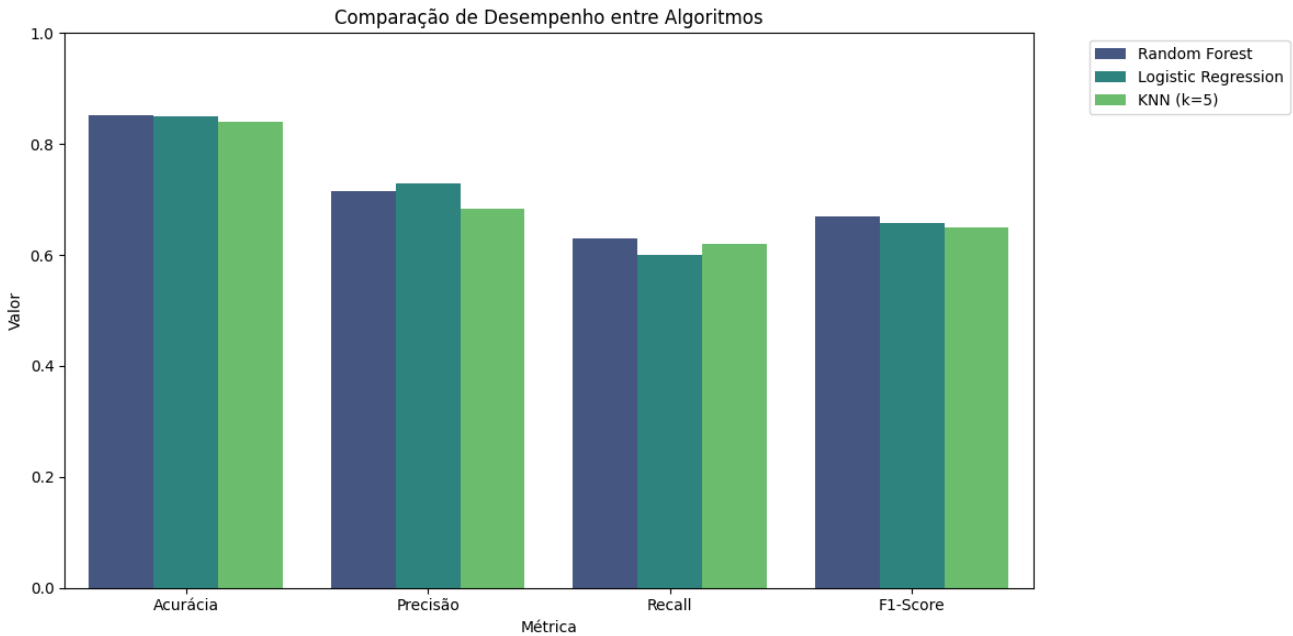


Figura: Comparação de desempenho entre os modelos avaliados.

Discussão e Conclusão

- **Resumo:** pré-processamento adequado foi decisivo para a qualidade final.
- **Desafios:** limpeza de strings ruidosas evitou criação de classes duplicadas.
- **Conclusão:** a metodologia adotada permitiu análise crítica consistente dos modelos.

Referências

- UCI Machine Learning Repository. Adult Census Income Dataset.
- Pedregosa et al. Scikit-learn: Machine Learning in Python.
- McKinney. Data Structures for Statistical Computing in Python (Pandas).
- Hunter. Matplotlib: A 2D Graphics Environment.
- Waskom. Seaborn: Statistical Data Visualization.
- Disciplina de Inteligência Computacional – Prof. Dr. Alisson Marques da Silva.